

ANNEXE D AU DOSSIER DE CERTIFICATION

C2.1.4 — Rapport des tests d'hypothèses (run 9)

Titre visé : Ingénieur en science des données spécialisé en infrastructure data ou en apprentissage automatique — RNCP 39586 (niveau 7)

Projet : Solution de gouvernance et d'archivage intelligent des données d'un ERP
PeopleSoft (Oracle EP92U038)

Livrable de la compétence C2.1.4 — rapport des tests d'hypothèses (run 9)
Pièce jointe au dossier « Bloc 2 — Analyser, organiser et valoriser des données »

Candidat : HAOUARI Salem

Mastère 2 — filière IA & Data · YNOV

Date : 29/07/2026

0. Méthode et conventions de lecture

0.1 Démarche appliquée à chaque hypothèse

1. Formuler H_0 (hypothèse nulle) et H_1 (alternative).
2. Vérifier les conditions d'application et retenir un test **non paramétrique** quand la normalité n'est pas tenable — ce qui est le cas de toutes les variables de volumétrie et de score, très asymétriques.
3. Calculer la statistique, la p-value **et une taille d'effet**.
4. Décider au seuil $\alpha = 0,05$, puis interpréter en termes métier.

0.2 Pourquoi une taille d'effet est reportée à chaque test

L'échantillon atteint 167 260 observations. À cette taille, la moindre différence devient statistiquement significative sans être nécessairement importante, et une p-value seule serait donc trompeuse. C'est la taille d'effet qui indique si le résultat compte en pratique.

Grille de lecture utilisée (conventions de Cohen) :

Mesure	Faible	Moyen	Fort
ϵ^2 (Kruskal-Wallis)	0,01	0,06	0,14
ρ (Spearman)	0,10	0,30	0,50
V de Cramér (tableau 7×2 , donc $\min(r-1, c-1) = 1$)	0,10	0,30	0,50
r rang-bisérial (Mann-Whitney)	0,10	0,30	0,50

0.3 Périmètres et effectifs

Les n diffèrent d'un test à l'autre parce que trois périmètres sont emboîtés :

Périmètre	Effectif	Contenu	Tests concernés
Catalogue complet	167 260	Records logiques PeopleSoft + tables physiques, tous classés	H3, H4
Actifs à structure connue	60 284	Nombre de colonnes renseigné	H1
Actifs à volumétrie mesurée	15 854	Taille en Mo mesurée	H2

Un record logique PeopleSoft n'a pas nécessairement de table physique associée, donc pas de taille mesurable : c'est ce qui explique l'écart entre les trois périmètres.

0.4 Synthèse des résultats

#	Hypothèse	Test	Statistique	Taille d'effet	p	Décision
H1	Complexité structurelle ~ domaine	Kruskal-Wallis	$H = 12\,783,3$	$\epsilon^2 = 0,212$ — fort	$< 0,001$	Rejet de H_0
H2	Taille ~ nombre de colonnes	Spearman	$\rho = 0,368$	$\rho = 0,368$ — modéré	$< 0,001$	Rejet de H_0

#	Hypothèse	Test	Statistique	Taille d'effet	p	Décision
H3	Description absente ~ domaine	χ^2 d'indépendance	$\chi^2 = 3\,681,5$	V = 0,148 — faible	< 0,001	Rejet de H_0
H4	Confiance règles vs modèle ML	Mann-Whitney U	U = 4 577 750 135	r = -0,674 — fort	< 0,001	Rejet de H_0
H5	Score d'archivabilité ~ domaine	—	—	—	—	Écartée avant test (§ 5)

0.5 Limites de méthode

1. **Pas de post-hoc sur H1.** Kruskal-Wallis conclut à « au moins un groupe diffère », non à des différences par paires. Comparer les médianes deux à deux, Finance à 17 contre Other à 4, demanderait formellement un test de Dunn avec correction de multiplicité, qui n'a pas été conduit. L'écart de rangs est trop marqué pour que la conclusion soit en jeu, mais l'inférence par paires n'est pas couverte.
2. **Groupes de H1 non indépendants du modèle.** Les sept domaines comparés sont des domaines prédits, et le nombre de colonnes compte parmi les features du classifieur. H1 décrit donc une séparation que le modèle a contribué à produire, et ne vaut pas validation indépendante de la classification.
3. **Pas de correction de multiplicité entre les quatre tests.** Sans conséquence ici, tous les p étant inférieurs à 0,001, très en dessous de n'importe quel seuil corrigé. L'absence est néanmoins signalée.
4. **Justesse du classifieur d'environ 75 %.** H3 et H4 portent sur des étiquettes prédites dont une sur quatre est fausse. Les tests restent valides : un bruit d'étiquetage tend à atténuer les associations mesurées, si bien que les effets réels sont au moins aussi forts que ceux rapportés. Mais l'interprétation domaine par domaine doit rester au niveau de l'ordre de grandeur.

1. H1 — La complexité structurelle (nombre de colonnes) diffère-t-elle selon le domaine métier ?

- **H0** : les distributions du nombre de colonnes sont identiques entre les 7 domaines.
- **H1** : au moins un domaine a une distribution différente.
- **Test : Kruskal-Wallis** — 7 groupes indépendants, variable non normale (asymétrie forte), $n = 60\,284$.
- **Justification du test** : l'ANOVA exigerait normalité et homoscédasticité, non vérifiées ici ; Kruskal-Wallis compare les rangs et ne fait pas ces hypothèses.
- **Résultat** : $H = 12\,783,3 \cdot \epsilon^2 = 0,212 \rightarrow$ **effet fort** (seuil « fort » = 0,14).
- **Décision** : $p < 0,001 < 0,05 \rightarrow$ **on REJETTE H0**.

Médianes du nombre de colonnes par domaine :

Domaine	Médiane
Finance & Contrôle	17
Ventes & Clients	16
Supply Chain / Logistique / Production	14
Achats & Fournisseurs	10
RH	8
IT & Sécurité	7
Other	4

Interprétation. Les tables Finance sont structurellement bien plus riches que celles d'IT ou d'« Other », avec un rapport de plus de 4 entre les médianes extrêmes.

Sur la modélisation métier, les objets Finance justifient des vues plus détaillées. Sur la priorisation de la documentation, l'effort y est plus coûteux à l'unité, donc à planifier plutôt qu'à improviser.

Une mise en garde s'impose enfin. On serait tenté de lire ce résultat comme une validation de la classification, au motif qu'un classifieur aléatoire n'aurait pas produit des profils aussi séparés. La lecture est circulaire : le nombre de colonnes compte parmi les features du modèle, si bien que la séparation observée est en partie construite par lui (§ 0.5, limite 2). Ce que le test établit garde son utilité pour la gouvernance, puisque les profils structurels des domaines tels que le système les restitue sont nettement distincts. Mais ce n'est pas une preuve de justesse.

2. H2 — La taille d'une table est-elle corrélée à son nombre de colonnes ?

- **H0** : il n'existe pas de corrélation monotone ($p = 0$).
- **H1** : il existe une corrélation monotone ($p \neq 0$).
- **Test : corrélation de Spearman**, $n = 15\,854$.
- **Justification du test** : les tailles suivent une loi très asymétrique (quelques très grosses tables) — un Pearson serait tiré par les valeurs extrêmes. Spearman travaille sur les rangs et résiste à ces points aberrants.
- **Résultat** : $p = 0,368 \rightarrow$ corrélation modérée.
- **Décision** : $p < 0,001 < 0,05 \rightarrow$ on REJETTE H0.

Interprétation. Le lien existe, mais il est imparfait : avec $p = 0,368$, on ne peut pas déduire la taille d'une table de son seul nombre de colonnes. Le nombre de lignes et le type de contenu pèsent au moins autant.

La conséquence porte sur la conception. Le scoring d'archivabilité ne peut pas se réduire à la largeur des tables ; il doit combiner plusieurs signaux, volumétrie, âge et lignage. Ce test a donc servi à écarter un raccourci de conception, pas seulement à constater une association.

3. H3 — L'absence de description dépend-elle du domaine métier ?

- **H0** : la présence d'une description est indépendante du domaine.
- **H1** : la présence d'une description dépend du domaine.
- **Test** : χ^2 d'indépendance, ddl = 6, $n = 167\,260$.

- **Justification du test** : deux variables catégorielles (domaine × description présente/absente), effectifs théoriques largement suffisants dans toutes les cases.
- **Résultat** : $\chi^2 = 3\,681,5$ · **V de Cramér** = **0,148** → **effet faible** (seuil « moyen » = 0,30 pour un tableau 7×2 ; le calcul retient $\min(r-1, c-1) = 1$, soit $V = \sqrt{\chi^2/n} = \sqrt{3\,681,5 / 167\,260} = 0,1484$).
- **Décision** : $p < 0,001 < 0,05$ → **on REJETTE H_0** .

Interprétation. La documentation est inégalement répartie entre domaines, mais l'association est faible et il faut le préciser : la p-value extrêmement basse pourrait laisser croire à un effet massif, alors que $V = 0,148$ indique une dépendance modeste.

Sur le plan opérationnel, cibler la complétion des métadonnées sur les domaines les moins couverts rapporte plus qu'un effort uniforme. La faiblesse de l'effet invite cependant à y voir un ordre de passage plutôt qu'une exclusion des autres domaines.

4. H4 — La confiance des règles mots-clés diffère-t-elle de celle du modèle ML ?

- **H_0** : les deux passes produisent des confiances de même distribution.
- **H_1** : les distributions de confiance diffèrent.
- **Test : Mann-Whitney U** — $n_{\text{règles}} = 44\,568$, $n_{\text{ML}} = 122\,692$.
- **Justification du test** : deux échantillons indépendants, variable continue non normale et bornée $[0, 1]$; un test t serait inadapté.
- **Résultat** : $U = 4\,577\,750\,135$ · **r rang-bisérial** = **-0,674** → **effet fort**. *Convention de signe : le signe est rapporté du point de vue du modèle ML pris comme groupe de référence — sa distribution de confiance est décalée vers le bas. La magnitude, $|r| = 0,674$, est la grandeur à interpréter.*
- **Décision** : $p < 0,001 < 0,05$ → **on REJETTE H_0** .

Médianes de confiance : règles mots-clés **0,833** · modèle (LinearSVC calibré) **0,680**.

Interprétation. Les deux passes ne sont pas interchangeables : quand une règle de nomenclature s'applique, elle est nettement plus sûre que le modèle statistique.

Ce test valide deux choix de conception. D'abord l'architecture en deux passes : les règles d'abord, avec une confiance élevée sur les cas où la nomenclature est explicite, puis le modèle en repli pour généraliser sur le reste. Ensuite la différenciation du seuil de revue par méthode : appliquer un seuil unique reviendrait à traiter avec la même règle de décision deux populations de confiance très différentes.

Note de périmètre : le modèle évalué ici est le LinearSVC calibré par Platt scaling sur features TF-IDF et numériques, celui qui a produit les 167 260 classifications du run 9 (colonne `model\_version` en base). Le transformeur XLM-RoBERTa de la page « Test du modèle » relève du Bloc 5 et n'intervient dans aucun chiffre de ce rapport.

5. H5 — Hypothèse écartée avant test, et pourquoi

Hypothèse envisagée : « le score d'archivabilité diffère selon le domaine métier ».

Motif de l'écartement. En périmètre Oracle seul, ce score est quasi constant : environ 90 % des actifs portent la valeur de base de 45,0, faute de signal de purge ou d'accès dans la source. Les statistiques d'accès aux tables ne sont pas exposées en lecture seule, et les dates de dernière modification métier ne sont pas fiables sur les tables techniques.

Le raisonnement. Un Kruskal-Wallis sur ces données aurait vraisemblablement retourné $p < 0,001$, par le seul effet de la taille de l'échantillon, alors que les médianes des groupes sont identiques. Publier un tel résultat comme une découverte aurait été trompeur : c'est précisément le cas de figure que la grille de tailles d'effet du § 0.2 sert à prévenir.

Statut retenu. Une limite du périmètre de données, et non un résultat. La lever suppose d'obtenir les statistiques d'accès aux tables, ce qui relève d'une évolution de l'autorisation d'accès à la source.

6. Évaluation de la pertinence de la simulation ROI

Complément au § 2.4.4 du dossier — la compétence C2.1.4 demande d'évaluer la pertinence des résultats des simulations.

Modèle. Simulation de **Monte-Carlo** projetant le coût de stockage sur 5 ans selon deux scénarios (sans action / avec archivage). Paramètre incertain : le taux de croissance annuel du volume, tiré autour d'une valeur centrale de **15 %/an avec une dispersion de ± 5 points**. Sortie : une distribution, dont on publie la **médiane et le quantile P10** ; le dashboard trace la bande P10–P90 correspondante.

Spécification incomplète. La loi de tirage, le nombre d'itérations et la graine aléatoire sont fixés dans `src/analytics/roi_projection.py`, mais ne sont pas figés par `run_id`. Contrairement aux quatre tests ci-dessus, les quantiles de cette simulation se rejouent donc à la dispersion d'échantillonnage près et non au chiffre près. Le correctif consiste à figer la graine dans la configuration du run ; il est porté par la recommandation R5 du dossier.

Résultats (run 9) :

Horizon	Volume sans action	Coût cumulé sans action	Coût cumulé avec archivage	Gain net cumulé (médiane)	P10
N+0	7,84 Go	1,66 \$	0,40 \$	1,26 \$	—
N+2	10,34 Go	5,76 \$	1,37 \$	4,39 \$	4,11 \$
N+3	11,88 Go	8,28 \$	1,94 \$	6,34 \$	5,72 \$
N+5	15,69 Go	14,50 \$	3,31 \$	11,19 \$	9,36 \$

La colonne « volume total sous archivage » du dashboard (7,84 Go à N+0, 11,92 Go à N+5) n'est pas reprise : sa trajectoire, soit une croissance effective de $\approx 8,7$ %/an, n'est pas reconstituable depuis les sorties publiées. Les coûts cumulés, eux, le sont, et c'est sur eux que porte la décision.

Trois réserves explicites :

1. **L'hypothèse de croissance est postulée, non mesurée.** Le 15 %/an est une hypothèse de place : le projet ne dispose pas d'un historique suffisant pour estimer une tendance. C'est la faiblesse principale du modèle ; l'intervalle P10–P90 la rend visible au lieu de la dissimuler derrière une courbe unique.
2. **La sensibilité croît avec l'horizon.** À N+2, le quantile P10 (4,11 \$) se situe 6 % sous la médiane (4,39 \$) ; à N+5, le P10 (9,36 \$) tombe 16 % sous la médiane (11,19 \$). L'incertitude relative est donc multipliée par plus de deux et demi entre deux et cinq ans, si bien que la projection est exploitable à deux ans et seulement indicative à cinq. Seule la borne basse est reportée : la distribution d'un cumul à croissance composée étant asymétrique à droite, une borne haute déduite par symétrie serait fausse.
3. **Le coût de l'archivage n'est pas simulé** (effort humain de revue, éventuelle réhydratation). Le gain affiché est un **gain brut de stockage**, donc un majorant du gain réel.

Verdict de pertinence. La simulation est **pertinente pour ordonner les scénarios** — elle établit que l'archivage divise le coût cumulé par $\approx 4,4$ à 5 ans (14,50 \$ contre 3,31 \$), et ce résultat tient jusqu'au quantile bas de la distribution. Elle **n'est pas pertinente comme prévision budgétaire**, pour trois raisons cumulées : le taux de croissance est postulé, la graine de tirage n'est pas figée, et le gain simulé est brut de tout coût de mise en œuvre (effort de revue, réhydratation, rétention minimale du palier archive).

7. Reproduction

```
python scripts/bloc2_hypothesis_tests.py --run-id 9
```

Le script relit les tables de la couche `serving` filtrées sur `run_id = 9`, exécute les quatre tests via `scipy.stats`, calcule les tailles d'effet et régénère ce rapport.

Portée de la reproductibilité. Les quatre tests d'hypothèses sont déterministes : un tiers disposant du dépôt et d'un accès en lecture à l'entrepôt retrouve les statistiques, les p-values et les tailles d'effet au chiffre près. La simulation Monte-Carlo du § 6 ne l'est pas encore, faute de graine figée.