

DOSSIER ÉCRIT DE CERTIFICATION

## **Bloc 2 — Analyser, organiser et valoriser des données**

Titre visé : Ingénieur en science des données spécialisé en infrastructure data ou en apprentissage automatique — RNCP 39586 (niveau 7)

Projet : Solution de gouvernance et d'archivage intelligent des données d'un ERP PeopleSoft (Oracle EP92U038)

Épreuve écrite individuelle — dossier de 30 pages maximum, hors annexes et page de garde  
<https://github.com/Salem2025s/data-archiving-solution>

**Candidat : HAOUARI Salem**

Mastère 2 — filière IA & Data · YNOV

Date : 29/07/2026

**Composition du rendu**

| <b>Livrable</b>                                   | <b>Fichier</b>                          | <b>Compétence</b>    |
|---------------------------------------------------|-----------------------------------------|----------------------|
| <b>Dossier principal</b>                          | BLOC2_Analyser_Organiser_Valoriser.docx | C2.1.1 →<br>C2.3.2   |
| <b>Support de formation et de sensibilisation</b> | BLOC2_support_formation.docx            | C2.3.1<br>(annexe G) |
| <b>Rapport des tests statistiques</b>             | bloc2_tests_resultats.docx              | C2.1.4<br>(annexe D) |

## Sommaire

|                                                                |    |
|----------------------------------------------------------------|----|
| 1. Contexte, commanditaire et périmètre .....                  | 5  |
| 2. C2.1 — Analyser les données .....                           | 6  |
| • C2.1.1 : Analyse du besoin .....                             | 6  |
| • C2.1.2 : Plan d'analyse.....                                 | 9  |
| • C2.1.3 : Requêtes, calculs et restitution en dashboard.....  | 11 |
| • C2.1.4 : Modèles statistiques et tests d'hypothèses.....     | 15 |
| 3. C2.2 — Valoriser les données.....                           | 21 |
| • C2.2.1 : Représentation et visualisation des résultats ..... | 21 |
| • C2.2.2 : Recommandations pour la décision.....               | 24 |
| 4. C2.3 — Transmettre .....                                    | 29 |
| • C2.3.1 : Support de formation des utilisateurs .....         | 29 |
| • C2.3.2 : Documentation technique du système d'analyse.....   | 30 |
| 5. Conclusion .....                                            | 34 |
| 6. Annexes.....                                                | 35 |

## 1. Contexte, commanditaire et périmètre

### 1.1 Le commanditaire et son besoin

Le commanditaire est la **Direction des Systèmes d'Information (DSI)** d'une organisation qui exploite un ERP **Oracle PeopleSoft** (instance de référence EP92U038) pour ses processus transactionnels — ressources humaines, finance, paie, achats. La solution est conçue comme un **produit réutilisable** : elle vise à être déployée chez de futurs clients exploitant le même type d'ERP, la source de données n'étant qu'un paramètre à substituer ; l'instance EP92U038 sert de terrain de validation.

Une phrase entendue en entretien de cadrage résume le besoin : « *la base de l'ERP grossit sans qu'on sache vraiment ce qu'elle contient, ni ce qui coûte, ni ce qu'on peut archiver sans risque* ». Trois attentes en découlent : comprendre le patrimoine, en sachant à quel objet métier se rattache chaque table alors qu'un ERP PeopleSoft en compte des dizaines de milliers aux noms opaques ; maîtriser les coûts, en mesurant ce que coûte le stockage par objet métier et le gain qu'apporterait une politique d'archivage ; décider sur des faits, en disposant de KPI et de projections plutôt qu'en arbitrant à l'aveugle. L'expression de besoin complète, validée par le commanditaire, figure au § 2.1.2.

### 1.2 Positionnement du Bloc 2

Le Bloc 1 a établi le socle **collecte → stockage → transformation → sécurisation**. Le Bloc 2 exploite ce socle pour **analyser, organiser et valoriser** : traduire la question métier en analyses chiffrées, tester statistiquement des hypothèses, restituer les résultats dans un dashboard décisionnel, formuler des recommandations, et transmettre le tout par de la formation et de la documentation.

### 1.3 Périmètre de données

L'analyse porte sur l'entrepôt PostgreSQL pfe\_data\_ia, alimenté par l'extraction Oracle. Au terme du run 9, le catalogue consolidé réunit **167 260 actifs de données** classés en **7 domaines métier** et enrichis de scores d'archivabilité, de coûts et de ROI. Quatre périmètres emboîtés sont à distinguer, car ils expliquent les effectifs (n) différents des analyses qui suivent :

| Périmètre                      | Effectif       | Contenu                                           | Analyses concernées                     |
|--------------------------------|----------------|---------------------------------------------------|-----------------------------------------|
| <b>Catalogue complet</b>       | <b>167 260</b> | Records logiques + tables physiques, tous classés | Cartographie, confiance, tests H3 et H4 |
| <b>Structure connue</b>        | <b>60 284</b>  | Nombre de colonnes renseigné                      | Test H1                                 |
| <b>Volumétrie mesurée</b>      | <b>15 854</b>  | Taille en Mo mesurée                              | Test H2, coûts, ROI                     |
| <b>Scorés pour l'archivage</b> | <b>16 828</b>  | Ayant reçu une stratégie d'archivage              | Recommandations (§ 3.2.3)               |

Un record logique PeopleSoft n'a pas nécessairement de table physique associée, donc pas de taille mesurable. Les analyses de coût portent en conséquence sur 7,84 Go de volumétrie réellement mesurée, sur 15 854 tables, alors que la cartographie couvre les 167 260 actifs. Confondre les deux périmètres est l'erreur d'interprétation la plus facile à commettre, et c'est pour cette raison que le dashboard affiche le périmètre de chaque indicateur.

Le scoring d'archivage porte sur un périmètre un peu plus large que la volumétrie strictement mesurée : 16 828 actifs, soit 974 de plus. Ces 974 actifs reçoivent une stratégie sur des critères non volumétriques (sensibilité, rétention réglementaire) et ne contribuent pas au chiffrage. Les effectifs du § 3.2.3 ne totalisent donc pas 15 854.

## 2. C2.1 — Analyser les données

### 2.1 — C2.1.1 : Analyse du besoin

**Livrable : une analyse du besoin.**

#### 2.1.1 La démarche d'entretiens exploratoires

Le cadrage est parti d'une série d'entretiens exploratoires semi-directifs, menés en amont du Bloc 1 auprès des porteurs d'enjeu. L'objectif était de recueillir les informations stratégiques nécessaires au cadrage de l'analyse, pas une spécification technique : personne n'était en mesure de la fournir, faute précisément de cartographie.

**Conditions de réalisation.** Trois entretiens de 45 à 60 minutes, conduits en visioconférence sur une période de deux semaines. Chacun a fait l'objet d'une prise de notes en direct, puis d'une reformulation validée oralement en fin d'échange. Les notes ont ensuite été consolidées dans une matrice de besoins, reproduite en annexe A.

**Grille d'entretien.** Une grille semi-directive commune a été appliquée aux trois interlocuteurs. Elle couvrait cinq thèmes : la difficulté rencontrée, la connaissance du patrimoine, la décision d'archivage, les contraintes non négociables et les critères de réussite. La grille complète, les intentions associées et la correspondance entre informations recueillies et exigences d'analyse figurent en annexe A..

**Interlocuteurs.** Trois profils, choisis pour couvrir l'angle décisionnel, l'angle technique et l'angle métier.

Le responsable DSI, commanditaire, a posé le cadre : dans son service, la croissance du stockage est un poste de coût subi et jamais arbitré. Son attente porte sur un chiffrage plus que sur un inventaire, et le résultat devra être présentable en comité, donc synthétique et visuel.

Le DBA administrateur PeopleSoft a fixé les contraintes techniques : aucune écriture sur l'ERP, accès par VPN uniquement, et le dictionnaire applicatif comme seule source fiable de métadonnées. Il a aussi confirmé le point qui justifie le projet, à savoir que la connaissance métier des noms de tables est concentrée sur quelques personnes.

Le référent métier du domaine Finance a apporté la dimension réglementaire : certaines données sont sous durée légale de rétention, si bien qu'archiver n'est pas supprimer et que la distinction devra apparaître dans les recommandations. Sa remarque la plus utile portait sur le risque — une classification automatique fausse est pire qu'une absence de classification, dès lors qu'elle déclenche une action. Le détail par interlocuteur figure en annexe A.

**De la parole recueillie à l'exigence d'analyse.** Chaque information stratégique a été traduite en une exigence traçable, qui structure ensuite le dossier. Six exigences en sont sorties : classer

automatiquement chaque actif avec un niveau de confiance explicite ; produire un chiffrage par domaine sur des tarifs sourcés plutôt qu'un inventaire ; exposer un marqueur `review_required` et ne jamais présenter de recommandation sans son niveau de confiance ; distinguer la conservation réglementaire de l'archivage ; respecter la lecture seule via VPN ; restituer dans un dashboard visuel, présentable en comité. La table de correspondance complète figure en annexe A.

**Validation du besoin.** La synthèse du § 2.1.2 a été présentée au commanditaire en réunion de restitution, puis retenue comme cadre de référence du travail d'analyse ; le compte rendu de cette restitution tient lieu d'expression de besoin validée. Deux arbitrages y ont été rendus, qui ont modifié la conception initiale. Le premier porte sur le score d'archivabilité : prévu comme un indicateur unique, de type feu vert ou feu rouge, il a été éclaté en stratégies différenciées (réglementaire, froid, chiffré, critique) parce que la nature du risque n'est pas la même d'un cas à l'autre. Le second porte sur la restitution : le plan n'affichait que le label de classification, et l'exigence « une classification fausse est pire que rien » a fait de la confiance et du taux de revue des indicateurs de premier plan. C'est aujourd'hui le cœur du support de formation (§ 4.1).

### 2.1.2 Synthèse du besoin

Le tableau ci-dessous récapitule l'expression de besoin issue des entretiens. C'est la version validée par le commanditaire, et elle sert de cadre de référence à tout le dossier ; les paragraphes suivants en détaillent chaque volet.

| Élément attendu                   | Synthèse du besoin                                                                                                                                                                               |
|-----------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Commanditaire</b>              | Responsable DSI                                                                                                                                                                                  |
| <b>Problématique</b>              | L'organisation ne dispose pas d'une cartographie fiable et exploitable des tables PeopleSoft, ce qui empêche d'arbitrer les coûts de stockage et de définir des stratégies d'archivage adaptées. |
| <b>Enjeux métier</b>              | Réduire les coûts de stockage, sécuriser les décisions d'archivage, limiter la dépendance à quelques experts et fournir une vision exploitable en comité.                                        |
| <b>Contexte</b>                   | Croissance continue du stockage, absence de cartographie consolidée et connaissance métier concentrée sur quelques personnes.                                                                    |
| <b>Environnement</b>              | ERP PeopleSoft, dictionnaire applicatif comme source principale de métadonnées, accès distant par VPN.                                                                                           |
| <b>Contraintes techniques</b>     | Lecture seule, aucune écriture dans l'ERP, exploitation des métadonnées PeopleSoft disponibles.                                                                                                  |
| <b>Contraintes réglementaires</b> | Respect des durées légales de conservation et distinction entre archivage et suppression.                                                                                                        |
| <b>Contraintes budgétaires</b>    | Nécessité de produire un chiffrage fondé sur des tarifs sourcés.                                                                                                                                 |
| <b>Contraintes de restitution</b> | Dashboard synthétique, visuel et présentable en comité.                                                                                                                                          |
| <b>Risques identifiés</b>         | Mauvaise classification, recommandation d'archivage erronée, suppression prématurée, dépendance aux experts.                                                                                     |

| Élément attendu      | Synthèse du besoin                                                                                                                               |
|----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| Critères de réussite | Classification avec niveau de confiance, identification des cas à revoir, chiffrage par domaine et restitution compréhensible par les décideurs. |

### 2.1.3 Périmètre et hors-périmètre

**Dans le périmètre.** Cartographier les actifs de l'instance PeopleSoft et les classer par domaine métier avec un niveau de confiance ; mesurer la volumétrie et le coût de stockage par domaine sur des tarifs sourcés ; scorer l'archivabilité de chaque actif et recommander une stratégie ; restituer le tout dans un dashboard et un export tableur.

**Hors périmètre.** La solution ne déclenche aucune action sur les données : elle ne supprime pas, n'archive pas, ne déplace rien. Elle produit des recommandations, dont l'exécution reste une décision humaine tracée. Sont également exclus le contenu métier des tables, jamais lu puisque seules les métadonnées le sont, la modification du paramétrage de l'ERP, et l'implémentation technique du transfert vers un palier froid, qui relève de l'exploitation. Cette délimitation vient de l'entretien avec le DBA et du principe posé par le référent métier : une classification fautive ne doit jamais pouvoir déclencher seule une action irréversible.

### 2.1.4 Problématique et enjeux

La problématique se formule ainsi :

*Comment cartographier automatiquement un patrimoine de données ERP, en mesurer le coût par objet métier, et recommander une stratégie d'archivage justifiée et auditable, sans jamais mettre en péril l'intégrité du SI ni la conformité réglementaire ?*

L'enjeu est à la fois économique et réglementaire. Conserver des données historiques inactives sur du stockage « chaud » coûte cher et ralentit les sauvegardes ; à l'inverse, archiver sans discernement expose à une non-conformité, les durées légales de rétention interdisant de traiter toutes les données de la même façon.

### 2.1.5 Contexte

La base de l'ERP a fortement grossi au fil des années. Les tables portent des noms techniques (PS\_JRNL\_HEADER, PS\_JOB...) que seuls quelques experts savent rattacher à un objet métier, et aucune cartographie à jour n'existe. La décision d'archivage se prend donc au cas par cas, sans vision d'ensemble ni chiffrage.

### 2.1.6 Environnement

La **source** est l'instance Oracle PeopleSoft EP92U038, à travers son dictionnaire de données applicatif (PSRECDEFN, PSDBFIELD, PSRECFIELD) et les vues système de volumétrie, accessibles en lecture seule. La **cible d'analyse** est l'entrepôt PostgreSQL pfe\_data\_ia, en architecture médaillon (raw\_oracle → processed → serving). Les **outils** sont Python (pandas, scipy, scikit-learn), SQL, un dashboard Streamlit et Altair, et des exports tableur. Le **référentiel de coût** est l'API de tarification publique Azure Storage, pour les paliers Hot LRS et Archive LRS. Les **utilisateurs finaux** sont les analystes de gouvernance, les référents métier et la DSI.

### 2.1.7 Contraintes

Chaque contrainte est rattachée à son origine, ce qui permet de vérifier qu'aucune n'a été ajoutée après coup.

| Type                | Contrainte                                                                                                                | Origine                   |
|---------------------|---------------------------------------------------------------------------------------------------------------------------|---------------------------|
| Technique           | Accès à la source par VPN uniquement ; aucune écriture sur l'ERP ; noms de tables opaques ; volume élevé (> 160 k actifs) | Entretien DBA             |
| Réglementaire       | RGPD : métadonnées et journaux peuvent contenir des données personnelles ; durées légales de rétention à respecter        | Entretien référent métier |
| Coût                | Stade prototype : pas de budget cloud propriétaire, outils open source imposés                                            | Cadrage projet            |
| Délai et logistique | Échéance de certification fixe (semaine 31) ; analyses rejouables à l'identique, tracées par run_id                       | Modalités d'évaluation    |
| Qualité et risque   | Aucune recommandation d'action présentée sans son niveau de confiance                                                     | Entretien référent métier |
| Produit             | Solution générique, base substituable, déployable chez d'autres clients PeopleSoft                                        | Commanditaire             |

**Critères couverts (C2.1.1).** L'analyse du besoin repose sur des entretiens exploratoires documentés : ✓ conditions de réalisation précisées, ✓ grille en cinq thèmes, ✓ trois interlocuteurs couvrant les angles décisionnel, technique et métier, ✓ informations stratégiques tracées jusqu'aux exigences d'analyse, ✓ synthèse validée par le commanditaire en réunion de restitution (§ 2.1.1). Le **tableau de synthèse du besoin (§ 2.1.2)** rassemble en une page les onze éléments attendus, du commanditaire aux critères de réussite, et le § 2.1.3 délimite le périmètre et le hors-périmètre. Les quatre volets exigés sont ensuite détaillés : ✓ la problématique et les enjeux (§ 2.1.4), ✓ le contexte (§ 2.1.5), ✓ l'environnement (§ 2.1.6), ✓ les contraintes techniques, réglementaires, de coût, de délai et de logistique, de qualité et de produit, chacune rattachée à son origine (§ 2.1.7). La table besoin/exigence cadre le travail d'analyse des sections suivantes.

## 2.2 — C2.1.2 : Plan d'analyse

**Livrable : une présentation d'un plan d'analyse.**

Le plan d'analyse traduit la problématique métier en un **problème numérique** structuré autour de trois axes, chacun décliné en métriques mesurables sur des données disponibles.



### 2.2.1 Traduction de la problématique en problème numérique

| Question métier                                | Nature du problème numérique          | Formalisation                                                                                                       | Données mobilisées                                             |
|------------------------------------------------|---------------------------------------|---------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------|
| « À quel métier appartient cette table ? »     | Classification supervisée multiclasse | $f(\text{nom, colonnes, types, features}) \rightarrow 1 \text{ des } 7 \text{ domaines, avec probabilité calibrée}$ | dataset_asset_m1 (noms, colonnes, types, features sémantiques) |
| « Combien coûte mon patrimoine, par métier ? » | Agrégation pondérée par la volumétrie | $\Sigma(\text{size\_mb}) \times \text{tarif\_}\$/\text{Go/an par domaine}$                                          | mv_asset_inventory.size_mb, dim_cost_params, domaine prédit    |
| « Que puis-je archiver, et pour quel gain ? »  | Scoring + simulation stochastique     | score(volumétrie, âge, lignage) puis projection Monte-Carlo du gain net                                             | mv_archivability_ranking, mv_roi_summary, snapshots N-1        |

**Un exemple de traduction complète.** La question « quels métiers documenter en priorité ? » n'est pas directement calculable. Elle se décompose en trois étapes : classer chaque table dans un des sept domaines ; mesurer, par domaine, la part de tables sans description, soit l'agrégation d'un indicateur binaire description IS NULL ; tester enfin si cette part dépend réellement du domaine ou relève du hasard, au moyen d'un  $\chi^2$  (§ 2.4). La réponse métier, « la documentation est inégale, ciblez les domaines les moins couverts », découle alors d'un calcul reproductible et non d'une impression.

### 2.2.2 Les trois axes d'analyse et leurs métriques

**Axe 1 — cartographier le patrimoine par domaine métier**, pour savoir ce que contient la base. Métriques : nombre d'actifs par domaine (actifs), part relative (%), distribution de la confiance en bandes high/medium/low (%), taux d'actifs à réviser review\_required (%), et complexité structurelle mesurée par la médiane du nombre de colonnes.

**Axe 2 — mesurer les coûts et le potentiel d'archivage**, pour savoir ce que cela coûte et ce qui est économisable. Métriques : volume stocké par domaine  $\Sigma \text{ size\_mb (Mo/Go)}$ , coût annuel actuel volume  $\times \text{tarif chaud (\$/an)}$ , coût après archivage (\\$/an), économie annuelle potentielle (\\$/an), **taux d'économie normalisé** indépendant de l'échelle (\\$/To/an), et part du coût par domaine (%).

**Axe 3 — valoriser en prospective (ROI et comparaison N-1)**, pour savoir ce que cela vaut dans le temps. Métriques : score de ROI par actif (0–100), coût cumulé projeté sur deux scénarios (\$), gain net cumulé en médiane et quantile P10 par Monte-Carlo (\$), et écart N-1 entre runs versionnés ( $\Delta$  et %).

La **matrice complète** — question métier, métrique, formule, table source et écran de restitution, ligne à ligne — figure en **annexe B**.

Le taux d'économie normalisé (en dollars par téraoctet archivé et par an) ne figurait pas dans le plan initial. Il a été ajouté après le premier calcul de coûts : sur un périmètre prototype de 7,84 Go, les montants absolus se comptent en quelques dollars par an. Le chiffre est juste, mais impossible à présenter en comité de direction sans paraître dérisoire. La métrique normalisée résout la difficulté,

puisqu'elle se transpose à l'échelle de production sans réexécuter l'analyse (§ 3.2.6). L'ajustement répond directement à l'exigence de restitution recueillie en entretien.

### 2.2.3 Données disponibles et pertinentes

Toutes les métriques ci-dessus s'appuient sur des tables **déjà produites et versionnées** dans la couche serving : mv\_asset\_inventory, mv\_archivability\_ranking, mv\_roi\_summary, asset\_business\_domain\_prediction, dim\_cost\_params. Aucune collecte supplémentaire n'est nécessaire : le plan est **directement exécutable**.

Deux données ont été examinées puis écartées, faute d'être exploitables en l'état : les statistiques d'accès aux tables, que la source Oracle n'expose pas en lecture seule, et les dates de dernière modification métier, peu fiables sur les tables techniques. Cette absence explique directement la limite documentée au § 2.4.5, d'où sa mention dès le plan d'analyse.

### 2.2.4 Enchaînement d'exécution

Un run enchaîne huit étapes, de l'extraction Oracle en lecture seule à la restitution : extraction → normalisation en modèle en étoile → classification par domaine (2 passes) → scoring d'archivabilité → rafraîchissement des tarifs depuis l'API → agrégation des coûts et simulation ROI → tests d'hypothèses → dashboard et export tableur. Le détail des étapes, de leurs entrées et de leurs tables de sortie figure en **annexe B**.

***Critères couverts (C2.1.2).** Le plan décrit ✓ les trois axes d'analyse (cartographie par domaine, coûts et potentiel d'archivage, ROI et comparaison N-1) et ✓ les métriques nécessaires, chacune avec sa formule et son unité (§ 2.2.2, matrice complète en annexe B). Il ✓ traduit la problématique client en problème numérique, en qualifiant la nature de chaque problème (classification supervisée, agrégation pondérée, scoring et simulation stochastique) et en détaillant un exemple complet (§ 2.2.1). Il ✓ identifie les données à exploiter, disponibles et pertinentes dans la couche serving, et justifie l'écartement de deux sources inexploitable (§ 2.2.3).*

## 2.3 — C2.1.3 : Requêtes, calculs et restitution en dashboard

**Livrable : une présentation des requêtes et des résultats sous forme de dashboard.**

Quatre techniques complémentaires ont été mobilisées pour exécuter ce plan, chacune adaptée à un usage précis.

### 2.3.1 Technique 1 — Requêtes SQL : les agrégats au plus près des données

Les agrégats lourds sont calculés en SQL dans PostgreSQL, via des vues matérialisées : c'est le moteur qui fait le travail, pas le poste client.

**Requête A — Cartographie : répartition des actifs et volume par domaine.**

```

SELECT p.business_domain_predicted AS domaine,
       COUNT(*) AS nb_actifs,
       ROUND(100.0 * COUNT(*) / SUM(COUNT(*) OVER ()), 1) AS part_actifs_pct,
       ROUND(SUM(inv.size_mb)::numeric, 0) AS volume_mo,
       ROUND(100.0 * SUM(inv.size_mb)
             / SUM(SUM(inv.size_mb) OVER ()), 1) AS part_volume_pct
FROM   serving.asset_business_domain_prediction p
JOIN   serving.mv_asset_inventory inv
ON     inv.asset_id = p.asset_id AND inv.run_id = p.run_id
WHERE  p.run_id = 9
GROUP  BY p.business_domain_predicted
ORDER  BY nb_actifs DESC;

```

### Résultat obtenu (run 9).

| Domaine                                     | Nb actifs      | Part des actifs | Volume (Mo)             | Part du volume |
|---------------------------------------------|----------------|-----------------|-------------------------|----------------|
| Finance & Contrôle                          | 75 495         | 45,1 %          | 565                     | 7,0 %          |
| IT & Sécurité                               | ≈ 35 300       | 21,1 %          | 6 846                   | 85,3 %         |
| Other · Supply Chain · Achats · RH · Ventes | —              | 33,8 %          | 491 · 46 · 35 · 22 · 19 | 7,7 %          |
| <b>Total</b>                                | <b>167 260</b> | <b>100 %</b>    | <b>8 025 (7,84 Go)</b>  | <b>100 %</b>   |

Arrondis : la somme des volumes affichés vaut 8 024 Mo pour un total mesuré de 8 024,7 Mo, et la colonne des parts totalise 99,9 %. Les effectifs par domaine non repris ici figurent dans l'export tableur (feuille « profil par domaine »).

C'est le résultat le plus important du dossier : les deux classements sont presque inversés. Finance & Contrôle représente 45,1 % des actifs mais 7 % du volume. IT & Sécurité représente 21,1 % des actifs mais 85,3 % du volume. Le patrimoine est nombreux du côté Finance, lourd du côté IT.

Cette dissociation explique la structure des recommandations du § 3.2, organisées en deux leviers distincts, un de gouvernance et un de coût, au lieu d'une liste unique de priorités. Une analyse qui se serait arrêtée au nombre d'actifs aurait désigné la mauvaise cible d'archivage.

**Requête B — qualité de la classification** : bandes de confiance et taux de revue, par discrétisation de confiance sur les seuils versionnés dans la configuration du run. **Résultat** : medium 54,2 % · low 25,6 % · high 20,2 %, et **27,1 % des actifs (45 269) marqués `review\_required`**.

**Requête C — coût et gain par domaine**, qui alimente la page « Coûts & ROI » : un WITH agrège par domaine le volume total et le volume portant une stratégie ARCHIVAGE%, puis un CROSS JOIN sur dim\_cost\_params applique les tarifs sourcés et calcule coût actuel, économie et parts. **Le texte intégral des requêtes B et C figure en annexe C.**

### Résultat de la requête C (run 9) :

| Domaine       | Volume (Go) | Coût actuel (\$/an) | Économie (\$/an) | % économisable | Part du coût | Part de l'économie |
|---------------|-------------|---------------------|------------------|----------------|--------------|--------------------|
| IT & Sécurité | 6,6853      | 1,42                | 1,18             | 83,5 %         | 85,5 %       | 94,4 %             |

| Domaine                     | Volume (Go)   | Coût actuel (\$/an) | Économie (\$/an) | % économisable | Part du coût | Part de l'économie |
|-----------------------------|---------------|---------------------|------------------|----------------|--------------|--------------------|
| Finance & Contrôle          | 0,5515        | 0,12                | 0,00             | 2,2 %          | 7,2 %        | 0,0 %              |
| Other                       | 0,4794        | 0,10                | 0,06             | 63,6 %         | 6,0 %        | 4,8 %              |
| Supply Chain / Log. / Prod. | 0,0449        | 0,01                | 0,01             | 53,8 %         | 0,6 %        | 0,8 %              |
| Achats & Fournisseurs       | 0,0347        | 0,01                | 0,00             | 9,2 %          | 0,6 %        | 0,0 %              |
| RH                          | 0,0218        | 0,00                | 0,00             | 35,5 %         | 0,0 %        | 0,0 %              |
| Ventes & Clients            | 0,0190        | 0,00                | 0,00             | 2,9 %          | 0,0 %        | 0,0 %              |
| <b>Total</b>                | <b>7,8366</b> | <b>1,66</b>         | <b>1,25</b>      | <b>75,3 %</b>  | <b>100 %</b> | <b>100 %</b>       |

Deux effets d'arrondi à connaître. Les parts de coût sont calculées par le dashboard sur des montants arrondis au cent : d'où l'écart de deux dixièmes de point avec les parts de volume (85,5 % contre 85,3 % pour IT & Sécurité) alors qu'un tarif unique s'applique, et l'affichage de RH et Ventes & Clients à 0,0 % de coût pour 0,3 % et 0,2 % du volume. Par ailleurs la somme des économies arrondies par domaine donne 1,25 \$/an, quand l'écran ROI, qui calcule sans arrondi intermédiaire, donne 1,26 \$/an (1,66 – 0,40). La valeur retenue dans tout le dossier est 1,25 \$, par cohérence avec la table par domaine.

**Contrôle de cohérence effectué.** Les sommes ont été vérifiées à la main :  $\Sigma \text{ volume} = 7,8366 \text{ Go}$  correspond au patrimoine total affiché en page d'accueil ;  $\Sigma \text{ coût} = 1,66 \text{ \$/an}$  correspond à l'année 0 de la projection ROI ;  $1,25 / 1,66 = 75,3 \%$  correspond au badge « réduction de 75 % » du dashboard.

Ce contrôle a une portée précise. Il établit qu'aucune erreur d'agrégation ne s'est glissée entre les trois écrans, alimentés par les mêmes vues matérialisées. Il ne valide en revanche pas la classification, la mesure de volumétrie ni le scoring d'archivabilité : la justesse de ces trois briques dépend de l'évaluation du modèle (§ 2.4.1) et de la source Oracle. Un contrôle d'intégrité ne dit rien de la justesse de ce qu'il additionne.

### 2.3.2 Technique 2 — Scripts Python : statistique et apprentissage

Ce que le SQL ne fait pas efficacement (p-values, modèles, simulations) est écrit en Python :

- `src/transform/score_business_domain.py` — classification par domaine (deux passes, § 2.4.1).
- `scripts/bloc2_hypothesis_tests.py` — les quatre tests d'hypothèses (§ 2.4.3).
- `src/analytics/roi_projection.py` — simulation Monte-Carlo du ROI (§ 2.4.4).


Le parti pris méthodologique se lit dans le code lui-même : la fonction qui calcule le test H1 calcule **dans le même mouvement sa taille d'effet**  $\epsilon^2 = (H - k + 1) / (n - k)$ , de sorte qu'il est impossible de reporter une p-value seule. L'extrait commenté figure en **annexe C**.

### 2.3.3 Technique 3 — Dashboard interactif (Streamlit + Altair)

L'application `app/streamlit_dashboard.py` restitue les résultats sans passer par un terminal, en neuf pages : Vue d'ensemble (les KPI), Domaines, Clés partagées, Archivage, Coûts & ROI, Pipelines, Paramètres, Console SQL et Test du modèle. Le numéro de run actif figure dans la barre latérale de

toutes les pages qui lisent les données d'un run, si bien que l'utilisateur sait toujours quelle exécution il consulte. La page « Test du modèle » fait exception : elle interroge le modèle à la demande sans dépendre d'un run, et affiche l'état de la connexion à la base.

La Console SQL intégrée permet d'exécuter ses propres requêtes en lecture seule et d'exporter le résultat en CSV. L'utilisateur n'est donc pas limité aux questions prévues à la conception.



Page « Vue d'ensemble » du dashboard : cartographie des 167 260 actifs par domaine, volume stocké par domaine et synthèse des recommandations d'archivage (run 9). On lit directement la dissociation entre le nombre d'actifs (donut, Finance dominant) et le volume (barres, IT & Sécurité dominant).

2.3.4 Technique 4 — Export tableur (Excel)

L'export domain\_model\_run9.xlsx (13 feuilles : profil par domaine, top candidats à l'archivage, paramètres de coût, comparaison N-1, projection ROI...) permet aux utilisateurs qui travaillent sous Excel de reprendre les analyses et de construire leurs propres tableaux croisés.

2.3.5 Synthèse des résultats (run 9)

Le tableau de synthèse des douze indicateurs du run 9, avec la valeur et le périmètre de chacun, figure en annexe C. Les résultats répondent directement aux trois attentes du commanditaire : que contient le patrimoine (cartographie), combien il coûte (volumétrie × tarifs sourcés), que faire (candidats priorités par stratégie).

**Critères couverts (C2.1.3).** ✓ Plusieurs techniques d'analyse sont présentées : requêtes SQL sur vues matérialisées, scripts Python (scipy et scikit-learn), dashboard Streamlit et Altair, export tableur de 13 feuilles. ✓ Elles produisent rapidement des résultats justes au regard de la problématique : trois requêtes commentées sont données avec leurs résultats effectifs, et l'intégrité du chiffrage est établie par un contrôle de cohérence chaîné entre trois écrans indépendants, dont la portée est

délimitée (§ 2.3.1). ✓ Les résultats sont restitués sous forme de dashboard décisionnel, complété d'une Console SQL en lecture seule pour les questions non anticipées.

## 2.4 — C2.1.4 : Modèles statistiques et tests d'hypothèses

**Livrable : une méthodologie de tests statistiques.**

La compétence attend trois choses : modéliser des relations entre variables, tester des hypothèses, évaluer la pertinence de résultats de simulation. La section suit cet ordre : le modèle de classification au § 2.4.1, la méthodologie et les quatre tests aux § 2.4.2 et 2.4.3, la simulation de ROI au § 2.4.4.

### 2.4.1 Le modèle statistique de classification

Une précision de périmètre avant d'entrer dans le détail. Le modèle qui a produit les 167 260 classifications analysées dans ce dossier est un LinearSVC calibré, en scikit-learn. C'est celui qui est documenté ici, et son identifiant est vérifiable : la colonne `model_version` de `asset_business_domain_prediction` le porte sur chaque ligne du run 9. Le transformeur XLM-RoBERTa visible sur la page « Test du modèle » du dashboard a été *fine-tuné* dans le cadre du Bloc 5 de spécialité ; il ne sert qu'en inférence interactive et n'intervient dans aucun chiffre du Bloc 2.

**Architecture en deux passes.**

**Passe 1 — les règles.** Correspondance de motifs sur les noms de records, de tables et de colonnes (préfixes PeopleSoft, lexique métier). Elle traite **44 568 actifs (26,6 %)** — ceux dont la nomenclature est explicite — avec une confiance **sensiblement plus élevée que le modèle** (médiane 0,833 contre 0,680, cf. H4).

**Passe 2 — le modèle.** Un LinearSVC sur features TF-IDF (noms de tables et de colonnes) complétées de features numériques (nombre de colonnes, de colonnes numériques, de lignes, taille), avec **probabilités calibrées par Platt scaling**. Elle généralise aux **122 692 actifs (73,4 %)** que les règles ne couvrent pas.

**Corpus d'entraînement et provenance des étiquettes.** Le modèle est supervisé, ce qui a posé le problème le plus délicat du projet : produire des étiquettes de référence sur un patrimoine dont, par définition, personne ne connaissait la cartographie. La démarche s'est faite en deux temps. Un corpus de référence a d'abord été constitué par annotation automatique assistée par LLM, en ne retenant que les cas de consensus supérieur ou égal à 0,70 entre passes d'annotation, ce qui écarte les tables ambiguës du corpus d'apprentissage. Une campagne de correction humaine a ensuite porté sur les cas litigieux et sur un échantillon de contrôle, et ses corrections ont été réinjectées. Le modèle de production porte pour cette raison un identifiant qui trace les deux étapes (`model_version`, suffixe - human).

**Évaluation du modèle.**

| Métrique                     | Valeur | Ce qu'elle dit                                                                             |
|------------------------------|--------|--------------------------------------------------------------------------------------------|
| Accord avec l'annotation LLM | ≈ 89 % | <b>Métrique trompeuse</b> : mesure la reproduction de l'annotateur, non la justesse métier |

| Métrique                                   | Valeur      | Ce qu'elle dit                                                                        |
|--------------------------------------------|-------------|---------------------------------------------------------------------------------------|
| Justesse validée humainement               | ≈ 75 %      | La métrique de référence : proportion d'étiquettes jugées correctes par revue humaine |
| Volume de corrections humaines réinjectées | ≈ 1 130 cas | Effort de qualification du corpus                                                     |

Une justesse d'environ 75 % signifie qu'une étiquette sur quatre est fausse. Ce chiffre conditionne la lecture de tout ce qui suit, à trois titres.

Les parts par domaine du § 2.3.1 sont donc des estimations et non des mesures : elles ne doivent pas être citées à la décimale. Le renversement volume/nombre, lui, résiste : IT & Sécurité concentre 85 % du volume dans un rapport de 12 à 1 avec le domaine suivant, et un bruit d'étiquetage d'un quart ne renverse pas un tel écart.

Aucune décision d'archivage ne peut reposer sur une étiquette non revue. C'est ce qui fonde le dispositif `review_required` (§ 3.2.2, R3) et la règle d'or du support de formation.

Enfin, l'écart entre les 89 % d'accord avec l'annotateur et les 75 % de justesse explique pourquoi la première métrique n'est pas retenue : se comparer à son propre annotateur mesure la cohérence de la reproduction, pas la vérité métier.

Une limite d'évaluation subsiste. La justesse est établie par revue humaine sur échantillon, non par un jeu de test étiqueté indépendant tenu à l'écart de l'entraînement. La matrice de confusion par domaine et un macro-F1 sur *hold-out* restent à produire.

**Pourquoi ce modèle ?** Sur des features TF-IDF creuses et de haute dimension, un séparateur linéaire à marge maximale est un choix de référence, plus robuste qu'un arbre sur ce type de représentation. Son coût d'inférence est négligeable, ce qui autorise à rescorer les 167 260 actifs à chaque run : c'est la condition de la reproductibilité. Sa décision, enfin, s'interprète par les poids des n-grammes, ce qui répond à l'exigence d'auditabilité issue des entretiens (§ 2.1.1).

**La calibration.** Un LinearSVC produit nativement une distance à l'hyperplan, pas une probabilité. Or l'exigence recueillie en entretien, « ne jamais présenter une recommandation sans son niveau de confiance », suppose une valeur interprétable comme telle. Un Platt scaling est donc appliqué : ajustement d'une régression logistique sur les scores de décision, en validation croisée. C'est cette étape qui rend la confiance affichée dans le dashboard statistiquement significative et qui autorise le découpage en bandes.

| Bande  | Lecture                        | Conséquence opérationnelle       | Part (run 9) |
|--------|--------------------------------|----------------------------------|--------------|
| high   | Le modèle est net              | Exploitable directement          | 20,2 %       |
| medium | Le modèle penche sans trancher | Vérification recommandée         | 54,2 %       |
| low    | Le modèle hésite               | Revue humaine avant toute action | 25,6 %       |

Les bornes numériques des bandes sont paramétrées dans ``src/transform/score_business_domain.py`` et versionnées avec le run ; elles ne sont pas recopiées ici afin d'éviter toute divergence entre le dossier et la configuration effective, qui reste la référence.

Deux précisions s'imposent à la lecture de ces chiffres.

D'abord, le marqueur de revue est un peu plus large que la bande low : 27,1 % des actifs sont marqués `review_required` contre 25,6 % en bande basse, soit environ 2 500 actifs signalés sans être en confiance faible. La règle de revue combine en effet le niveau de confiance et d'autres critères, comme la sensibilité du domaine ou un désaccord entre les deux passes. Appartenir à low entraîne la revue, mais l'inverse n'est pas vrai.

Ensuite, une confiance médiane modérée est le comportement attendu. Un modèle qui afficherait 95 % de high sur des noms de tables opaques, pour une justesse mesurée d'environ 75 %, serait sur-confiant : il déclencherait des recommandations d'archivage sur des classifications fausses, avec une assurance injustifiée. La distribution obtenue, majoritairement medium, est cohérente avec la justesse observée. Le test H4 (§ 2.4.3) vérifie d'ailleurs que les deux passes ont des régimes de confiance distincts.

Une limite reste à lever sur ce point. La procédure de calibration est en place, mais aucun diagnostic n'est publié pour ce modèle : ni erreur de calibration attendue, ni courbe de fiabilité, ni score de Brier. Constaté qu'une distribution ressemble à celle d'un modèle calibré ne constitue pas une preuve. L'outillage existe dans le projet, où il a servi au modèle du Bloc 5 ; son application à ce classifieur reste à faire.

#### 2.4.2 Méthodologie de test retenue

Pour chaque hypothèse, la démarche est identique :

1. **Formuler** H0 (hypothèse nulle) et H1 (alternative).
2. **Vérifier les conditions d'application** et choisir un test **non paramétrique** quand la normalité n'est pas tenable — ce qui est le cas de toutes les variables de volumétrie et de score, très asymétriques (quelques très grosses tables écrasent la distribution).
3. **Calculer** la statistique, la p-value **et une taille d'effet**.
4. **Décider** au seuil  $\alpha = 0,05$ , puis **interpréter** en termes métier.

Un point de méthode conditionne l'ensemble. L'échantillon monte à 167 260 observations, et à cette taille la moindre différence devient statistiquement significative sans être pour autant importante. Une p-value seule serait donc trompeuse. Chaque test est en conséquence accompagné d'une taille d'effet adaptée ( $\epsilon^2$ ,  $\rho$ , V de Cramér, corrélation rang-bisériale) : c'est elle qui indique si le résultat compte en pratique. Le § 2.4.5 présente le cas où ce garde-fou a conduit à écarter une hypothèse qu'un test aurait déclarée significative.

Grille de lecture des tailles d'effet retenue (conventions de Cohen) : pour  $\epsilon^2$  (Kruskal-Wallis) 0,01 / 0,06 / 0,14 ; pour  $\rho$  (Spearman), V de Cramér (ici  $\min(r-1, c-1) = 1$ ) et r rang-bisérial 0,10 / 0,30 / 0,50 — respectivement faible / moyen / fort. Le détail figure en **annexe D**.

Tout est reproductible via `scripts/bloc2_hypothesis_tests.py` ( $\alpha = 0,05$ , données réelles du run 9) ; le rapport brut est joint en annexe D (`bloc2_tests_resultats.md`).



### 2.4.3 Les quatre tests, leurs résultats et leur portée


#### H1 — La complexité structurelle (nombre de colonnes) diffère-t-elle selon le domaine métier ?

- **H0** : les distributions du nombre de colonnes sont identiques entre les 7 domaines. **H1** : au moins un domaine a une distribution différente.
- **Test** : **Kruskal-Wallis** — non paramétrique, 7 groupes indépendants, distribution non normale.  $n = 60\,284$  (actifs à structure connue, § 1.3).
- **Résultat** :  $H = 12\,783,3 \cdot \epsilon^2 = 0,212 \rightarrow$  **effet fort** ·  $p < 0,001 \rightarrow$  **on rejette H0**.

Médianes du nombre de colonnes par domaine : Finance & Contrôle **17** · Ventes & Clients **16** · Supply Chain **14** · Achats & Fournisseurs **10** · RH **8** · IT & Sécurité **7** · Other **4** — soit un rapport de plus de 4 entre les extrêmes.

**Interprétation métier.** Les tables Finance sont structurellement bien plus riches que celles d'IT ou d'« Other ». Deux conséquences opérationnelles en découlent. La modélisation métier doit prévoir des vues plus détaillées pour les objets Finance. Et l'effort de documentation y étant plus coûteux à l'unité, il vaut mieux le planifier que l'improviser.

Deux réserves de méthode limitent la portée de ce résultat. La première tient à la circularité : les sept groupes comparés sont définis par le domaine prédit, et le nombre de colonnes compte parmi les features du modèle (§ 2.4.1). Le test ne vaut donc pas validation indépendante du classifieur, puisqu'il décrit une séparation que le modèle a contribué à produire. Ce qu'il établit garde son utilité pour la gouvernance : les profils structurels des domaines tels que le système les restitue sont nettement distincts. Mais ce n'est pas une preuve de justesse. La seconde réserve est plus technique : Kruskal-Wallis conclut à « au moins un groupe diffère », pas à des différences par paires. Comparer Finance à Other demanderait formellement un post-hoc de Dunn avec correction de multiplicité, qui n'a pas été conduit. L'écart de rangs est trop marqué pour que la conclusion soit en jeu, mais l'inférence par paires n'est pas couverte.



*Écart interquartile du nombre de colonnes par domaine (run 9). Les boîtes représentent Q1 · médiane · Q3, soit 50 % central des tables ; la queue supérieure, très étalée, n'est pas représentée pour la lisibilité. Le décalage net des distributions — médiane 17 pour Finance & Contrôle contre 4 pour « Other » — est ce que le test de Kruskal-Wallis quantifie ( $\epsilon^2 = 0,21$ , effet fort).*

#### H2 — La taille d'une table est-elle corrélée à son nombre de colonnes ?

- **H0** : il n'existe pas de corrélation monotone ( $p = 0$ ). **H1** : il en existe une ( $p \neq 0$ ).
- **Test** : **corrélation de Spearman** — retenue car les tailles suivent une loi très asymétrique ; un Pearson serait tiré par les valeurs extrêmes.  $n = 15\ 854$  (actifs à volumétrie mesurée, § 1.3).
- **Résultat** :  $p = 0,368 \rightarrow$  **corrélation modérée** ·  $p < 0,001 \rightarrow$  **on rejette H0**.

**Interprétation métier.** Le lien existe mais il est **imparfait** :  $p = 0,368$  signifie qu'on ne peut pas déduire la taille d'une table de son seul nombre de colonnes — le nombre de lignes et le type de contenu pèsent au moins autant. **Conséquence directe sur la conception** : le scoring d'archivabilité ne peut pas se réduire à la largeur des tables, il doit combiner plusieurs signaux (volumétrie, âge, lignage). Ce test a donc servi à **écarter un raccourci de conception**, pas seulement à constater une association.

### H3 — L'absence de description dépend-elle du domaine métier ?

- **H0** : la présence d'une description est indépendante du domaine. **H1** : elle en dépend.
- **Test** :  **$\chi^2$  d'indépendance** — deux variables catégorielles (domaine  $\times$  description présente/absente), effectifs théoriques largement suffisants.  $ddl = 6$ ,  $n = 167\ 260$ .
- **Résultat** :  $\chi^2 = 3\ 681,5$  · **V de Cramér = 0,148**  $\rightarrow$  **effet faible** (seuil « moyen » = 0,30 pour un tableau  $7 \times 2$ ) ·  $p < 0,001 \rightarrow$  **on rejette H0**.

**Interprétation métier.** La documentation est inégalement répartie entre domaines. L'association est réelle mais faible, et la p-value extrêmement basse ne doit pas laisser croire à un effet massif :  $V = 0,148$  signale une dépendance modeste. Sur le plan opérationnel, cibler la complétion des métadonnées sur les domaines les moins couverts rapporte plus qu'un effort uniforme, sans que l'écart justifie d'abandonner les autres domaines.

### H4 — La confiance des règles mots-clés diffère-t-elle de celle du modèle ML ?

- **H0** : les deux passes produisent des confiances de même distribution. **H1** : les distributions diffèrent.
- **Test** : **Mann-Whitney U** — deux échantillons indépendants, variable continue non normale.  $n_{\text{règles}} = 44\ 568$ ,  $n_{\text{ML}} = 122\ 692$ .
- **Résultat** :  $U = 4\ 577\ 750\ 135$  · **r rang-bisérial = -0,674**  $\rightarrow$  **effet fort** ·  $p < 0,001 \rightarrow$  **on rejette H0**.
- **Convention de signe** : le signe est rapporté du point de vue du **modèle ML** pris comme groupe de référence — sa distribution de confiance est décalée vers le bas par rapport aux règles. La magnitude,  $|r| = 0,674$ , est la grandeur à interpréter.

Médianes de confiance : règles **0,833** · modèle **0,680**.

**Interprétation métier.** Les deux passes **ne sont pas interchangeables** : quand une règle s'applique, elle est nettement plus sûre que le modèle. Ce résultat **valide statistiquement le choix d'architecture** (règles d'abord, modèle en repli) et justifie un **seuil de revue différencié par méthode** plutôt qu'un seuil unique — ce qui serait revenu à traiter deux populations de confiance très différentes avec la même règle de décision.

#### 2.4.4 Évaluation de la pertinence des résultats de simulation (ROI)

La simulation à évaluer est la projection de ROI sur cinq ans.

**Modèle.** Une simulation de Monte-Carlo projette le coût de stockage sur cinq ans selon deux scénarios, sans action et avec archivage. Le paramètre incertain est le taux de croissance annuel du volume, tiré à chaque itération autour d'une valeur centrale de 15 % par an, avec une dispersion de  $\pm 5$  points. La sortie est une distribution et non un chiffre unique : le tableau ci-dessous en donne la médiane et le quantile P10, le dashboard trace la bande P10–P90 correspondante.

**Spécification et reproductibilité.** La loi de tirage, le nombre d'itérations et la graine aléatoire sont fixés dans `src/analytics/roi_projection.py`, mais ne sont pas figés par `run_id` comme le sont les autres paramètres du pipeline. La conséquence est directe : là où les agrégats SQL et les tests statistiques se rejoignent au chiffre près, les quantiles de cette simulation se rejoignent à la dispersion d'échantillonnage près. Le correctif est court, figer la graine dans la configuration du run, et fait partie de la recommandation R5 (§ 3.2.4).

**Résultats (run 9) :**

| Horizon | Volume sans action | Coût cumulé sans action | Coût cumulé avec archivage | Gain net cumulé (médiane) | P10     |
|---------|--------------------|-------------------------|----------------------------|---------------------------|---------|
| N+0     | 7,84 Go            | 1,66 \$                 | 0,40 \$                    | 1,26 \$                   | —       |
| N+2     | 10,34 Go           | 5,76 \$                 | 1,37 \$                    | 4,39 \$                   | 4,11 \$ |
| N+3     | 11,88 Go           | 8,28 \$                 | 1,94 \$                    | 6,34 \$                   | 5,72 \$ |
| N+5     | 15,69 Go           | 14,50 \$                | 3,31 \$                    | <b>11,19 \$</b>           | 9,36 \$ |

*Le tableau ne reprend pas la colonne « volume total sous archivage » du dashboard. Sa trajectoire, de 7,84 Go à N+0 vers 11,92 Go à N+5, soit une croissance effective d'environ 8,7 % par an, n'est pas reconstituée depuis les seules sorties publiées. La décision porte de toute façon sur les coûts cumulés, qui sont entièrement traçables. Documenter cette colonne fait partie des correctifs de R5.*

**Évaluation critique de la simulation.** La première réserve est aussi la plus lourde : le taux de croissance de 15 % par an est postulé, non mesuré. Le projet ne dispose que de quelques runs, ce qui est insuffisant pour estimer une tendance. L'intervalle P10–P90 a précisément pour fonction de rendre cette incertitude visible, au lieu de la dissimuler derrière une courbe unique.

La deuxième porte sur l'horizon. À N+2, le quantile P10 (4,11 \$) se situe 6 % sous la médiane (4,39 \$) ; à N+5, le P10 (9,36 \$) tombe 16 % sous la médiane (11,19 \$). L'incertitude relative est donc multipliée par plus de deux et demi entre deux et cinq ans. La projection est exploitable à deux ans et seulement indicative à cinq, et doit être présentée comme telle à un décideur. Seule la borne basse est reportée : la distribution d'un cumul à croissance composée est asymétrique à droite, et déduire un P90 par symétrie donnerait une valeur fautive.

La troisième est un manque du modèle : il ne simule pas le coût de l'archivage lui-même, ni l'effort humain de revue, ni d'éventuels coûts de réhydratation. Le gain affiché est un gain brut de stockage, donc un majorant du gain réel.

**Conclusion sur la pertinence.** La simulation permet d'ordonner les scénarios : elle établit sans ambiguïté qu'à cinq ans l'archivage divise le coût cumulé par environ 4,4 (14,50 \$ contre 3,31 \$), et ce résultat tient jusqu'au quantile bas de la distribution. Elle ne constitue pas une prévision budgétaire, pour les trois raisons qui précèdent : croissance postulée, graine non figée, gain brut de tout coût de

mise en œuvre. La recommandation R5 du § 3.2.4 conditionne l'industrialisation du ROI à la levée de ces trois points.

#### 2.4.5 Une hypothèse écartée avant test

Une cinquième hypothèse avait été envisagée : le score d'archivabilité diffère-t-il selon le domaine métier ? Elle a été écartée après examen des données, avant d'être testée. En périmètre Oracle seul, ce score est quasi constant, environ 90 % des actifs restant à la valeur de base de 45,0, faute de signal de purge ou d'accès dans la source (§ 2.2.3).

Un Kruskal-Wallis sur ces données aurait vraisemblablement retourné  $p < 0,001$ , par le seul effet du grand échantillon, alors que les médianes des groupes sont identiques. Publier un tel résultat aurait été trompeur. Il s'agit donc d'une limite du périmètre de données, et la lever suppose d'obtenir les statistiques d'accès aux tables, ce qui relève d'une évolution de l'autorisation d'accès à la source.

**Critères couverts (C2.1.4).** Pour chacune des quatre hypothèses retenues, la méthodologie comporte ✓ la formulation d'une hypothèse, avec  $H_0$  et  $H_1$  explicites, ✓ le test statistique associé (Kruskal-Wallis, Spearman,  $\chi^2$ , Mann-Whitney), chacun justifié par la nature des variables et le non-respect de la normalité, et ✓ l'interprétation des résultats en portée métier, taille d'effet comprise. ✓ Des relations entre variables sont modélisées : un modèle statistique de classification, LinearSVC avec calibration de Platt, évalué à environ 75 % de justesse (§ 2.4.1), et une corrélation de rangs ( $H_2$ ). ✓ La pertinence des résultats de simulation est évaluée : la projection Monte-Carlo est publiée avec son quantile bas et assortie de trois réserves qui aboutissent à un verdict d'usage (§ 2.4.4). ✓ Les résultats valident ou réfutent l'hypothèse initiale : les quatre hypothèses rejettent  $H_0$  à  $p < 0,001$ , avec des tailles d'effet contrastées (fortes pour  $H_1$  et  $H_4$ , modérée pour  $H_2$ , faible pour  $H_3$ ), et une cinquième a été écartée après examen (§ 2.4.5).

## 3. C2.2 — Valoriser les données

### 3.1 — C2.2.1 : Représentation et visualisation des résultats

**Livrable : la visualisation des résultats de l'analyse.**

Les analyses sont restituées dans le dashboard Streamlit. Chaque représentation a été choisie en fonction de la nature de la donnée et du public visé : des analystes de gouvernance et des décideurs, non techniciens.

#### 3.1.1 Choix des représentations et bénéfices attendus

| Donnée à communiquer (nature)                                    | Représentation choisie                       | Bénéfice attendu                                                                              |
|------------------------------------------------------------------|----------------------------------------------|-----------------------------------------------------------------------------------------------|
| Répartition des actifs par domaine (part d'un tout, 7 modalités) | Anneau (donut) + légende                     | Lecture immédiate des poids relatifs ; le trou central allège la surcharge du camembert plein |
| Volume stocké par domaine (comparaison de grandeurs)             | Barres horizontales triées + valeur affichée | Comparaison précise ; libellés de domaines longs lisibles sans rotation                       |

| Donnée à communiquer (nature)                                        | Représentation choisie                       | Bénéfice attendu                                                     |
|----------------------------------------------------------------------|----------------------------------------------|----------------------------------------------------------------------|
| <b>Concentration du coût (<i>cumul, priorisation</i>)</b>            | <b>Diagramme de Pareto</b>                   | Montre en un écran que quelques domaines portent l'essentiel du coût |
| <b>Recommandations d'archivage (<i>effectifs par stratégie</i>)</b>  | <b>Barres horizontales + cartes-chiffres</b> | Hiérarchise les volumes et donne le chiffre exact                    |
| <b>Projection de ROI (<i>série temporelle incertaine</i>)</b>        | <b>Courbes + bande P10–P90</b>               | Rend l'incertitude visible au lieu de la masquer                     |
| <b>Probabilités par classe (<i>distribution sur 7 modalités</i>)</b> | <b>Barres, échelle 0–100 %</b>               | Rend visible l'hésitation du modèle, pas seulement le label gagnant  |


Pour chaque ligne, l'**alternative écartée** et la raison de son rejet figurent en annexe E.

### 3.1.2 Justification du choix des outils

Altair a été retenu pour sa nature déclarative : le graphique se décrit par la sémantique des données, par encodage, et non par des instructions de dessin. Les échelles et les légendes sont donc générées correctement d'un écran à l'autre, ce qui écarte une bonne part des erreurs de lecture. Streamlit apporte l'interactivité sans installation côté utilisateur : un navigateur suffit, les filtres et le tri se manipulent directement, et c'est la condition de l'autonomie d'un public non technique. L'export Excel à 13 feuilles, enfin, permet à ceux qui veulent manipuler les chiffres eux-mêmes de le faire dans l'outil qu'ils maîtrisent déjà.

### 3.1.3 Deux exemples de restitution

**Coûts et ROI.** Le diagramme de Pareto montre à quel point le coût est concentré : IT & Sécurité porte à lui seul 85,5 % du coût et 94,4 % du potentiel d'économie. Pour orienter un effort d'optimisation, cette forme parle beaucoup plus qu'un tableau trié. La projection ROI est affichée avec sa bande P10–P90, qui matérialise l'incertitude discutée au § 2.4.4.



Page « Coûts & ROI » : répartition du coût par domaine (anneau), diagramme de Pareto des coûts (barres + cumul), et projection ROI sur 5 ans en deux scénarios avec intervalle Monte-Carlo P10–P90 (bande verte). La concentration du coût sur IT & Sécurité se lit immédiatement sur le Pareto.

**Test de classification.** La page de test affiche le domaine prédit, mais aussi la distribution des probabilités sur les sept classes : le lecteur voit l'incertitude et pas seulement le verdict. Sur l'exemple de la table PS\_EMPLOYEES, prédite « RH » à 92,3 % de confiance, les 7,7 % restants se répartissent sur les autres domaines, la seconde probabilité revenant à Finance & Contrôle. C'est cohérent pour une table d'employés qui porte des champs de rémunération (salary\_admin\_plan, grade, step).

Cette page illustre ici un choix de représentation, montrer la distribution plutôt que le seul label. Le modèle qu'elle interroge en interactif est le transformeur XLM-RoBERTa du Bloc 5, distinct du LinearSVC calibré qui a produit les 167 260 classifications du dossier (§ 2.4.1).

La capture de cette page figure en **annexe E**.

### 3.1.4 Clarté et justesse de la mise en forme

- **Titres explicites** sur chaque graphique, énonçant la mesure et son périmètre.
- **Légendes** systématiques, ordonnées comme les données.
- **Échelles annotées et unités toujours portées** (Mo, Go, \$/an, %), pour éviter toute ambiguïté de lecture.
- **Formatage des grands nombres** avec séparateurs de milliers (167 260 et non 167260).
- **Barres triées par valeur** : la position devient elle-même porteuse d'information.
- **Libellés de domaine affichés en entier** — correction d'un défaut initial de troncature qui rendait « Supply Chain / Logistique / Production » illisible.

- **Numéro de run affiché sur toutes les pages qui lisent des données d'un run** : un chiffre n'a de sens que rapporté à son exécution. La page « Test du modèle », indépendante des runs, affiche l'état de connexion à la place.

### 3.1.5 Prise en compte des situations de handicap

Les principes d'accessibilité visuelle retenus visent en priorité les déficiences de la vision des couleurs, qui touchent environ 8 % des hommes, et les besoins de contraste.

Cinq principes sont appliqués. **La couleur n'est jamais le seul vecteur d'information** : chaque catégorie est identifiée par un libellé, par sa position (barres triées, légende ordonnée) et par une valeur numérique affichée — critère WCAG 1.4.1, qui couvre le daltonisme. **Aucun dégradé rouge-vert** : les intensités passent par des échelles séquentielles monochromes, ce qui protège la deutéranopie comme la protanopie. **Le contraste texte/fond est élevé** — texte sombre #0F172A sur fond clair, au-delà du seuil de 4,5:1 du critère WCAG 1.4.3 niveau AA. **L'encodage passe par la longueur** : les comparaisons de grandeur reposent sur des barres plutôt que sur des aires colorées, encodage robuste quelle que soit la déficience visuelle. Enfin, **toute valeur lue sur un graphique est disponible en tableau et en export CSV/Excel** — contournement pour les lecteurs d'écran.

Deux points ne sont pas couverts. La navigation clavier complète du dashboard (critère WCAG 2.1.1) et les libellés alternatifs exposés aux lecteurs d'écran sur les graphiques Altair (critère 1.1.1) restent à traiter ; la disponibilité systématique des tableaux et des exports constitue un contournement, pas une conformité. Une palette validée pour les déficiences de la vision des couleurs et un audit WCAG formel restent également à conduire. Le détail par critère figure en annexe E.

***Critères couverts (C2.2.1).** ✓ Le choix des outils de mise en forme et des représentations est justifié avec les bénéfices attendus : une ligne par donnée à communiquer, précisant la nature, la représentation retenue, le bénéfice et l'alternative écartée (§ 3.1.1), ainsi qu'une justification des outils Altair, Streamlit et Excel (§ 3.1.2). ✓ La mise en forme communique les données au public ciblé avec clarté et justesse : titres, légendes, échelles, unités, tri, formatage des grands nombres et affichage permanent du run (§ 3.1.4), illustrés par deux pages réelles du dashboard. ✓ Les spécificités des personnes en situation de handicap sont prises en compte : la couleur n'est jamais seule porteuse de sens, les échelles d'intensité sont monochromes, le contraste respecte le niveau AA, les comparaisons reposent sur la longueur, et toute valeur graphique existe aussi en tableau (§ 3.1.5). Les deux limites restantes sont identifiées en annexe E.*

## 3.2 — C2.2.2 : Recommandations pour la décision

**Livrable : une présentation de recommandations.**

### 3.2.1 Le constat qui structure les recommandations

Tout ce qui suit découle d'un seul constat, issu de la requête A du § 2.3.1 : le patrimoine est nombreux d'un côté et lourd de l'autre. Finance & Contrôle concentre 45,1 % des actifs mais 7 % du volume ; IT & Sécurité, 21,1 % des actifs mais 85,3 % du volume, 85,5 % du coût et 94,4 % du potentiel d'économie.

Il n'existe donc pas une priorité, mais deux leviers indépendants, à actionner en parallèle par des équipes différentes.

|                        | Levier A — Gouvernance                                               | Levier B — Coût                               |
|------------------------|----------------------------------------------------------------------|-----------------------------------------------|
| <b>Cible</b>           | Finance & Contrôle et domaines mal documentés                        | IT & Sécurité                                 |
| <b>Pourquoi</b>        | 45 % des actifs, tables les plus complexes (médiane 17 colonnes, H1) | 85,5 % du coût, 94,4 % de l'économie possible |
| <b>Gain / porteur</b>  | Qualité et auditabilité · référents métier et analystes              | Économique direct · DSI et exploitation       |
| <b>Recommandations</b> | R1, R3, R4                                                           | R2                                            |

*Une liste de priorités unique aurait désigné Finance pour l'archivage, c'est-à-dire la mauvaise cible.*

### 3.2.2 Levier A — Recommandations de gouvernance

**R1 — Concentrer la validation humaine sur Finance & Contrôle.** Le domaine pèse 45,1 % du patrimoine, soit 75 495 actifs, et rassemble les tables structurellement les plus complexes : médiane de 17 colonnes contre 4 pour « Other », avec un effet fort au test H1. À effort de contrôle égal, c'est donc là qu'un contrôle qualité couvre le plus grand nombre d'actifs, et les plus structurants pour le métier. L'action consiste à y concentrer en priorité la validation humaine des classifications et la complétion des descriptions.

**R3 — Traiter les 27 % d'actifs à réviser comme un chantier qualité.** 45 269 actifs, soit 27,1 %, portent le marqueur `review_required` : 25,6 % au titre de la confiance basse, un point et demi de plus au titre des autres critères de revue (§ 2.4.1). Rapproché de la justesse mesurée du classifieur, environ 75 %, le dispositif couvre à peu près un tiers des étiquettes potentiellement fausses. Sa portée est donc réelle mais partielle.

Ces cas ne signalent pas un défaut du modèle mais la mesure de son incertitude. Les ignorer exposerait au seul risque réellement grave du projet : archiver une donnée encore utile, ou réglementairement sensible, sur la foi d'une classification fautive. L'action consiste à organiser une boucle de validation humaine sur les cas low, en commençant par ceux qui portent du volume, donc à l'intersection avec le levier B, et par les domaines à enjeu réglementaire.

**R4 — Cibler la documentation sur les domaines sous-documentés.** Le test H3 établit que l'absence de description dépend du domaine, avec un  $\chi^2$  significatif et un V de Cramér de 0,148, soit une association réelle mais faible. Cibler les domaines les moins documentés maximise donc le gain de gouvernance à effort constant, sans que la faiblesse de l'effet justifie d'abandonner les autres : il s'agit d'un ordre de passage, pas d'une exclusion. La liste des domaines par taux de description manquante est déjà calculable et peut être adressée aux référents métier telle quelle.

### 3.2.3 Levier B — La recommandation économique

**R2 — Lancer l'archivage froid sur IT & Sécurité, en première vague et seule.**

IT & Sécurité porte 6,69 Go sur 7,84 Go, soit 85,3 % du volume, 85,5 % du coût et 94,4 % du potentiel d'économie. Sur l'ensemble du catalogue, le scoring identifie 6 854 actifs et 6,6 Go éligibles à l'archivage froid. Le volume archivable du seul domaine IT & Sécurité se déduit de son économie annuelle,  $1,18 \$ \div 0,190368 \$/\text{Go}$ , soit environ 6,20 Go. Cela représente 94 % du volume archivable total, et rend économisable 83,5 % du coût de ce domaine.



Trois raisons convergent.

1. **L'effet est massif et concentré** — une seule vague sur un seul domaine capte 94 % du gain, l'écart avec le domaine suivant (Other, 4,8 %) étant d'un facteur 20. La conclusion résiste à l'incertitude de classification : un bruit d'étiquetage d'un quart (justesse  $\approx 75\%$ , § 2.4.1) ne renverse pas un rapport de 20 à 1.
2. **Le risque métier y est *a priori* plus faible** — objets techniques, journalisation, audit, dont l'usage transactionnel vivant est moindre. **Cet argument reste à établir table par table** : il repose sur la nature du domaine, non sur une revue nominative des candidats. D'où le conditionnement de la vague à une revue humaine.
3. **L'écart de tarif est de  $\times 9,8$**  entre chaud (0,2120 \$/Go/an) et archive (0,0216 \$/Go/an), tarifs relevés sur l'API publique Azure et non estimés. *Réserve : ce différentiel ignore les coûts propres au palier archive — rétention minimale, réhydratation, transactions. Le gain affiché est brut.*

**Action.** Constituer une première vague limitée aux candidats ARCHIVAGE\_FROID d'IT & Sécurité, triée par volume décroissant : les plus grosses tables portent l'essentiel du gain et sont les moins nombreuses à revoir. La vague suppose une revue nominative des candidats, puis une mesure du gain réel avant extension. Prérequis bloquant : aucun actif marqué `review_required` ne doit y figurer.

**Ce qu'il ne faut pas faire.** Appliquer la même logique à Finance & Contrôle, dont 2,2 % du coût seulement sont économisables. L'effort y serait comparable pour un gain quasi nul.

**Lecture des stratégies d'archivage recommandées (run 9).** Le scoring ne produit pas un feu vert unique mais **sept stratégies différenciées**, conformément à l'exigence issue de l'entretien métier (*archiver  $\neq$  supprimer*) :

| Stratégie                                           | Actifs         | Volume        | Sens opérationnel                                                |
|-----------------------------------------------------|----------------|---------------|------------------------------------------------------------------|
| CONSERVATION_REGLEMENTAIRE                          | 6 895          | 350 Mo        | Durée légale de rétention.<br><b>Ne pas archiver.</b>            |
| ARCHIVAGE_FROID                                     | 6 854          | <b>6,6 Go</b> | Cible de la première vague (R2)                                  |
| ARCHIVAGE_CHIFFRE                                   | 1 620          | 37 Mo         | Archivable, chiffrement requis                                   |
| CONSERVATION_CRITIQUE                               | 1 135          | 822 Mo        | Critique en exploitation.<br><b>Ne pas toucher.</b>              |
| CONSERVATION · CONSERVATION_SECURISEE · COMPRESSION | 190 · 122 · 12 | —             | Conserver en l'état, en accès restreint, ou compresser sur place |

*Ce tableau se lit à deux niveaux. Prise individuellement, la stratégie la plus fréquente est la conservation réglementaire, avec 6 895 actifs, devant l'archivage froid à 6 854. En agrégat, en revanche, les stratégies d'archivage totalisent 8 474 actifs (50,4 %) contre 8 342 en conservation (49,6 %) et 12 en compression sur place, et couvrent 6,64 Go des 7,84 Go mesurés, soit 85 % du volume. Le système ne pousse donc pas à l'archivage par défaut, puisque quatre stratégies sur sept l'interdisent explicitement, mais il identifie bien la majorité du volume comme archivable. C'est le résultat attendu sur un patrimoine dominé par des tables techniques.*

### 3.2.4 R5 — Sécuriser le modèle de coût avant d'industrialiser le ROI

Les tarifs proviennent désormais de sources externes réelles, relevées sur l'API Azure : 0,2120 contre 0,0216 \$/Go/an, soit un rapport de x9,8. En revanche le taux de croissance de 15 % par an reste une hypothèse et non une observation (§ 2.4.4). Or un ROI n'a de valeur décisionnelle que si ses hypothèses sont sourcées et rejouables : la projection sert à ordonner les scénarios, pas à établir un budget.

Cinq actions en découlent. Rafraîchir périodiquement `dim_cost_params` depuis l'API, en horodatant le relevé et la région tarifaire. Figer la graine aléatoire de la simulation dans la configuration du run, pour que les quantiles se rejouent au chiffre près comme le reste du pipeline. N'industrialiser la projection qu'après plusieurs runs, en remplaçant l'hypothèse de croissance par la croissance observée. Intégrer au modèle de coût les postes propres au palier archive, rétention minimale et réhydratation. Et, d'ici là, ne jamais présenter la projection sans son quantile bas.

### 3.2.5 Priorisation : gain attendu contre effort

| Priorité      | Reco                                    | Gain attendu                                   | Effort                         |
|---------------|-----------------------------------------|------------------------------------------------|--------------------------------|
| 1 — à lancer  | R2 — Archivage froid IT & Sécurité      | Très élevé — 94,4 % de l'économie possible     | Moyen — une vague, un domaine  |
| 2 — quick win | R4 — Documenter les domaines faibles    | Moyen — qualité de classification future       | Faible — liste déjà calculable |
| 3             | R1 — Valider Finance en priorité        | Élevé — couvre 45 % du patrimoine              | Moyen — validation ciblée      |
| 4             | R3 — Résorber les cas à réviser         | Élevé — supprime le risque sur 27 % des actifs | Élevé — boucle continue        |
| 5             | R5 — Sourcer et figer le modèle de coût | Moyen — fiabilise le ROI                       | Faible — automatisable         |

**Séquence proposée.** R2 et R4 en parallèle dès maintenant, puisqu'elles offrent le meilleur rapport gain sur effort de chaque levier. R3 restreinte au périmètre de la vague R2, comme condition de sécurité. R1 et R5 ensuite, en fond de tâche.

### 3.2.6 L'ordre de grandeur des montants

Les montants absolus de ce dossier sont ceux d'un prototype : 1,66 \$ par an de coût actuel, 1,25 \$ par an d'économie, sur 7,84 Go de volumétrie mesurée. Ces chiffres sont exacts, mais ils décrivent le périmètre réellement mesuré et non une production complète. Ils n'ont donc aucune portée budgétaire.

La métrique à retenir est le taux d'économie normalisé : **195 \$ économisés par téraoctet archivé et par an**, soit  $(0,2120 - 0,0216) \times 1\,024$ . Elle est indépendante de l'échelle et se transpose sans réexécuter l'analyse. Sur une base de 5 To dont 80 % de volume archivable, elle donne un ordre de grandeur de 780 \$ par an ; sur 50 To dans les mêmes proportions, environ 7 800 \$ par an, hors coût de mise en œuvre et hors coûts propres au palier archive. La proportion de 80 % est cohérente avec les 83 % observés ici, mais elle reste une hypothèse de transposition et non une mesure.

*Précision de convention : le taux de 195 \$/To/an retient 1 To = 1 024 Go, comme le reste du dossier. En téraoctet décimal, convention de facturation des fournisseurs cloud, il vaut 190 \$/To/an. L'écart de 2,5 % ne change aucun arbitrage.*

### 3.2.7 Argumentaire préparé pour la présentation orale

Le discours est construit en cinq temps, chacun ramené à une phrase pivot.

| Temps                     | Phrase pivot                                                                                                                                                                                          | Appui visuel                                           |
|---------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|
| <b>1. Le problème</b>     | « Vous payez pour stocker des données dont vous ne savez pas ce qu'elles contiennent. »                                                                                                               | Vue d'ensemble — 167 260 actifs, 7 domaines            |
| <b>2. Le renversement</b> | « Ce qui est nombreux n'est pas ce qui est lourd : Finance c'est 45 % des tables mais 7 % du coût ; IT c'est 21 % des tables mais 85 % du coût. »                                                     | Donut (nombre) à côté des barres (volume)              |
| <b>3. La conséquence</b>  | « Donc deux chantiers, pas un : gouverner Finance, archiver IT. »                                                                                                                                     | Tableau des deux leviers (§ 3.2.1)                     |
| <b>4. Le chiffrage</b>    | « 94 % de l'économie possible tient dans une seule vague sur un seul domaine. Sur ce prototype cela vaut 1,25 \$/an — le chiffre transposable est le taux : 195 \$ par téraoctet archivé et par an. » | Pareto des coûts + projection P10–P90                  |
| <b>5. La garantie</b>     | « Rien ne s'archive sans revue : 27 % des actifs sont explicitement marqués à vérifier. »                                                                                                             | Distribution de confiance + stratégies de conservation |

Six objections ont été anticipées et leurs réponses préparées : l'ordre de grandeur des montants, la confiance médiane du modèle, l'effet du grand échantillon sur les tests, l'origine du taux de croissance, la justesse des étiquettes prédites, et l'absence de liste nominative de tables. Le tableau des réponses figure en annexe F.

### 3.2.8 Synthèse pour le décideur

Le patrimoine est concentré et dissocié : Finance & Contrôle porte le nombre, avec 45 % des actifs, IT & Sécurité porte le poids, avec 85 % du volume et du coût. Il faut donc mener deux chantiers distincts et non arbitrer une priorité unique.

Le gain économique est immédiat et localisé. Une seule vague d'archivage froid sur IT & Sécurité capte 94,4 % de l'économie possible, sur des tables techniques à faible risque métier, avec un rapport de ×9,8 entre le tarif du stockage chaud et celui de l'archive, relevé sur l'API du fournisseur.

Le gain de gouvernance se trouve ailleurs : sur Finance, où se concentrent le nombre d'actifs et la complexité structurelle, et sur les 27 % d'actifs marqués à réviser, qui sont la file de travail prioritaire de la gouvernance.

Une réserve enfin. À l'échelle de ce prototype, les montants se comptent en dollars. Le chiffre transposable est le taux de 195 \$ par téraoctet archivé et par an. Quant à la projection à cinq ans, elle ordonne les scénarios sans constituer une prévision budgétaire tant que la croissance réelle n'est pas observée.

**Critères couverts (C2.2.2).** ✓ La présentation est structurée : un constat analytique fondateur (§ 3.2.1), deux leviers distingués avec leurs porteurs, cinq recommandations appuyées sur un constat chiffré et débouchant sur une action, un tableau de priorisation et une séquence d'exécution (§ 3.2.5). ✓ Elle est synthétique, avec une synthèse d'une page pour le décideur (§ 3.2.8) et un tableau des deux leviers lisible en un écran. ✓ Elle est argumentée : chaque recommandation s'appuie sur un résultat nommé, requête A, test H1, test H3, scoring ou tarifs sourcés, et R2 précise aussi ce qu'il ne faut pas faire. ✓ Les recommandations éclairent la prise de décision : elles priorisent par rapport gain sur effort, distinguent deux chantiers que le nombre d'actifs seul aurait confondus, énoncent la réserve d'échelle, et sont accompagnées d'un discours préparé et d'arguments face aux objections anticipées (§ 3.2.7), comme la compétence le demande.

## 4. C2.3 — Transmettre

### 4.1 — C2.3.1 : Support de formation des utilisateurs

**Livrable : un support de formation.** \*(Livrable joint : `BLOC2\_support\_formation.docx` / `.md`)\*

#### 4.1.1 Enjeu et sujet de la formation

**L'enjeu.** L'outil ne crée de valeur que si les utilisateurs métier savent le lire et s'en servir seuls. Faute de quoi chaque question remonte à l'équipe data, ce qui reproduit le problème de dépendance aux experts identifié en entretien (§ 2.1.1).

**Le sujet.** La montée en compétences des analystes de gouvernance et des référents métier sur l'exploitation du dashboard et l'interprétation des indicateurs. Deux d'entre eux concentrent l'essentiel des malentendus : la confiance et le taux de revue. La question qui revient toujours est « pourquoi le modèle n'est-il pas sûr à 100 % ? ».

#### 4.1.2 Analyse du besoin de montée en compétences

Le besoin a été analysé en croisant le profil du public et les risques d'usage. Les **analystes de gouvernance**, non techniciens mais à l'aise avec Excel, doivent naviguer seuls, comprendre chaque KPI et exporter ; à défaut, l'outil serait sous-utilisé et le tableur manuel reprendrait le dessus. Les **référents métier**, experts de leur domaine mais non data, doivent savoir **quand se fier** à une classification et quand la réviser ; à défaut, c'est le risque grave du projet — une décision d'archivage sur une classification fautive. Le **décideur DSI**, en lecture de synthèse, doit lire les KPI de haut niveau et la réserve d'échelle ; à défaut, il conclurait faux sur les montants (§ 3.2.6).

**Trois écarts de compétences à combler**, dans l'ordre de criticité : (1) interpréter la confiance, la justesse de 75 % et review\_required ; (2) naviguer et filtrer par run\_id ; (3) exporter et réutiliser les données.

#### 4.1.3 Objectifs pédagogiques

À l'issue de la session de 45 minutes, le participant est capable de : **O1** situer l'outil, en disant à quelles trois questions métier il répond ; **O2** naviguer seul dans les pages du dashboard et identifier le run affiché ; **O3** interpréter la répartition par domaine, la bande de confiance et le taux de revue, et expliquer pourquoi une confiance de 100 % serait suspecte ; **O4** appliquer le réflexe qualité, en ne

validant jamais un archivage sur une classification non revue ; **O5** distinguer les stratégies de conservation des stratégies d'archivage ; **O6** exporter un résultat via la Console SQL ou l'export Excel.

#### 4.1.4 Structure, format et vérification des acquis

Le support est structuré en **six modules courts**, chacun rattaché à un objectif : (1) à quoi sert l'outil, les trois questions métier — O1, 5 min ; (2) visite guidée du dashboard, capture réelle à l'appui — O2, 10 min ; (3) lire un indicateur sans se tromper : répartition, confiance, taux de revue, justesse de 75 %, échelle des montants — O3, 10 min ; (4) le réflexe qualité : règle d'or, procédure en 4 étapes, les 7 stratégies — O4 et O5, 8 min ; (5) exporter et réutiliser : Console SQL, export Excel — O6, 5 min ; (6) bonnes pratiques et **quiz de validation** — 7 min. Total 45 minutes.

**Format retenu.** Un support visuel pas-à-pas, avec une capture réelle de l'outil plutôt qu'une description abstraite : pour un public non technique, montrer l'écran qu'il verra réduit l'écart entre la formation et l'usage. Le découpage en modules de cinq à dix minutes permet une reprise partielle en autonomie.

**Vérification des acquis.** Un quiz de six questions clôt la session, une par objectif, avec corrigé et renvoi au module correspondant. Il sert à l'apprenant comme au formateur, qui repère ainsi le module à retravailler. La question la plus discriminante porte sur l'écart de compétence le plus critique : savoir quoi répondre à « le modèle a 25 % d'étiquettes fausses, il ne sert à rien ».

#### 4.1.5 Le support de sensibilisation complémentaire

La compétence mentionne des supports de formation et de sensibilisation. Le support joint comporte donc, en plus des six modules, une fiche d'une page au format « mail de bonnes pratiques », diffusable indépendamment de la session. Elle tient en cinq règles, dont la règle d'or, « on n'archive jamais sur la foi d'une classification non vérifiée », et le rappel de la justesse de 75 %. Son objet n'est pas de former mais de maintenir le réflexe chez ceux qui n'assistent pas à la session, ou qui n'utilisent l'outil que ponctuellement.

***Critères couverts (C2.3.1).** ✓ L'enjeu et le sujet de la formation sont présentés (§ 4.1.1) : rendre les utilisateurs autonomes face au risque de dépendance à l'expert, avec un sujet centré sur l'interprétation de la confiance, du taux de revue et de la justesse du modèle. ✓ Le besoin de montée en compétences est analysé (§ 4.1.2) selon trois publics, avec pour chacun le niveau de départ, le besoin et le risque en cas d'inaction, puis trois écarts hiérarchisés, et ✓ traduit en objectifs pédagogiques vérifiables (§ 4.1.3). ✓ Le support est adapté au sujet et permet de monter en compétences le public visé : modules courts rattachés aux objectifs, capture réelle de l'outil pour un public non technique, fiche de sensibilisation diffusable séparément (§ 4.1.5) et quiz de vérification des acquis (§ 4.1.4).*

## 4.2 — C2.3.2 : Documentation technique du système d'analyse

**Livrable : une documentation technique.**

### 4.2.1 Public concerné

La documentation s'adresse explicitement à trois publics, avec des entrées différenciées :

Les **analystes de gouvernance**, qui ont besoin de savoir ce que mesure un indicateur, entrent par la colonne « définition fonctionnelle » du dictionnaire (annexe H). Les **développeurs reprenant la solution**, qui doivent comprendre, modifier et réexécuter, entrent par la chaîne de traitement, les modules et la procédure de reproduction (§ 4.2.5). L'**auditeur ou le jury**, qui vérifie qu'un chiffre est traçable et rejouable, entre par le `run_id`, la formule technique et la table source de chaque indicateur, complétés de la fiche de modèle pour les métriques de qualité du classifieur.

#### 4.2.2 Description des sources de données

| Attribut              | Valeur                                                                                                                                                                                                                                                                                                                      |
|-----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Origine · accès       | Oracle PeopleSoft EP92U038 — dictionnaire applicatif (PSRECDEFN, PSDBFIELD, PSRECFIELD) et vues système de volumétrie. <b>Lecture seule via VPN</b> (IP privée) ; aucune écriture sur l'ERP.                                                                                                                                |
| Périmètre fonctionnel | <b>Métadonnées uniquement</b> — records, tables, colonnes, index, volumétrie. <b>Jamais le contenu métier.</b>                                                                                                                                                                                                              |
| Volumétrie (run 9)    | 167 260 actifs catalogués · 60 284 à structure connue · 15 854 à volumétrie mesurée · 7,84 Go mesurés                                                                                                                                                                                                                       |
| Sources externes      | API de tarification publique Azure Storage (Hot LRS, Archive LRS) → <code>dim_cost_params</code> . <b>Corpus de référence</b> du classifieur : annotation assistée par LLM (consensus $\geq 0,70$ ) complétée d'environ <b>1 130 corrections humaines</b> (§ 2.4.1) — source à part entière, distincte de la source Oracle. |
| Chaîne · fréquence    | <code>raw_oracle</code> (copie brute) → <code>processed</code> (étoile normalisée) → <code>serving</code> (vues et scores). Une exécution complète par <code>run_id</code> ; run de référence : 9. Détail dans docs/A_connexion_preparation/ et le dossier Bloc 1.                                                          |

**Conformité RGPD.** Le périmètre étant limité aux métadonnées, aucune donnée personnelle métier n'est traitée. Les journaux d'exécution, susceptibles de contenir des identifiants techniques, relèvent des mesures du Bloc 1.

#### 4.2.3 Description des méthodes de calcul

| Domaine de calcul                 | Méthode                                                                                                                                                                                                                                                             | Module / documentation                                                                       |
|-----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| <b>Classification par domaine</b> | Deux passes : règles sur nomenclature, puis <b>LinearSVC</b> sur TF-IDF + features numériques, <b>probabilités calibrées par Platt scaling</b> , puis discrétisation en trois bandes (high / medium / low) selon des seuils versionnés dans la configuration du run | <code>src/transform/score_business_domain.py</code> · <code>docs/B_classification_ml/</code> |

| Domaine de calcul                    | Méthode                                                                                                                                                                                                                           | Module / documentation                                        |
|--------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------|
| <b>Modélisation par objet métier</b> | Schéma en étoile, graphe de dépendances inter-tables                                                                                                                                                                              | docs/C_modelisation_domaine/                                  |
| <b>Entraînement du classifieur</b>   | Corpus annoté (LLM à consensus $\geq 0,70 + \approx 1\,130$ corrections humaines), TF-IDF + features numériques, LinearSVC, calibration de Platt en validation croisée. <b>Justesse <math>\approx 75\%</math></b>                 | score_business_domain.py · artifacts/production_model_card.md |
| <b>Règles d'archivage</b>            | Scoring composite (volumétrie, âge, lignage), base 45,0, puis dérivation en <b>7 stratégies</b> par croisement avec la sensibilité et les obligations de rétention. Pondérations et table de décision versionnées dans le module. | docs/D_regles_archivage/                                      |
| <b>Gains de stockage</b>             | Volumétrie $\times$ tarifs sourcés API Azure ; différentiel chaud/archive                                                                                                                                                         | docs/E1_gains_stockage/                                       |
| <b>Comparaison N-1</b>               | Diff d'indicateurs entre deux runs versionnés                                                                                                                                                                                     | docs/E2_comparaison_n1/                                       |
| <b>Projection ROI</b>                | <b>Simulation Monte-Carlo</b> , croissance $15\% \pm 5\%$ , sorties médiane + P10/P90                                                                                                                                             | src/analytics/roi_projection.py · docs/E3_projection_roi/     |
| <b>Répartition des coûts</b>         | Agrégation des coûts par domaine + cumul de Pareto                                                                                                                                                                                | docs/E4_repartition_couts/                                    |
| <b>Tests statistiques</b>            | 4 tests d'hypothèses (scipy), $\alpha = 0,05$ , tailles d'effet systématiques                                                                                                                                                     | scripts/bloc2_hypothesis_tests.py                             |

#### 4.2.4 Description technique et fonctionnelle des indicateurs

Chaque indicateur est documenté selon cinq attributs : sa définition fonctionnelle, c'est-à-dire ce qu'il mesure pour le métier ; sa formule technique, colonnes et calcul ; sa table source ; son unité ; son périmètre. Le tableau ci-dessous en donne un extrait, le dictionnaire complet figurant en annexe H.

| Indicateur                           | Définition fonctionnelle                                                     | Formule technique                                           | Source                                     |
|--------------------------------------|------------------------------------------------------------------------------|-------------------------------------------------------------|--------------------------------------------|
| <b>Taux de revue</b>                 | Part des actifs dont la classification doit être vérifiée avant toute action | SUM(CASE WHEN review_required THEN 1 ELSE 0 END) / COUNT(*) | asset_business_domain_prediction           |
| <b>Économie annuelle potentielle</b> | Ce que l'organisation économiserait en archivant les candidats identifiés    | SUM(size_mb candidats)/1024 × (hot - archive)               | mv_archivability_ranking × dim_cost_params |
| <b>Taux d'économie normalisé</b>     | Économie par téraoctet archivé — indicateur transposable à l'échelle         | (hot_usd_gb_year - archive_usd_gb_year) × 1024              | dim_cost_params                            |

Toute valeur affichée dans le dashboard se rattache à une ligne de ce dictionnaire et à un `run\_id`. C'est ce qui rend l'analyse auditable, comme le demandait le référent métier en entretien.

#### 4.2.5 Reproductibilité

Le principe est simple : chaque analyse porte un run\_id, toute requête le filtre, et toute exécution produit un instantané complet et rejouable. Aucun chiffre du dossier ne provient d'une manipulation ponctuelle non tracée.

**Ce qui garantit la reproductibilité, concrètement** : un run\_id sur chaque table de la couche serving (versionnement des résultats) ; un dépôt Git avec les scripts et leurs commandes (versionnement du code) ; un fichier de configuration par instance et des tarifs figés dans dim\_cost\_params à chaque run (versionnement des paramètres) ; une colonne model\_version sur chaque prédiction (identification du modèle) ; un script unique produisant le rapport de tests (traçabilité, annexe D) ; et une source paramétrable, de sorte que substituer l'instance suffit à rejouer sur un autre client PeopleSoft (généricité). **La procédure d'exécution pas à pas figure en annexe J.**

**Portée de cette garantie.** Un tiers disposant du dépôt et d'un accès en lecture à l'instance source rejoue les agrégats SQL, la classification et les tests statistiques au chiffre près. Deux réserves s'y ajoutent. L'instance EP92U038 n'est atteignable que sur réseau privé via VPN, si bien que la reproduction exacte suppose cet accès ; la reproduction sur une autre instance PeopleSoft, elle, est acquise puisque la source n'est qu'un paramètre. Par ailleurs les quantiles de la simulation Monte-



Carlo se rejouent à la dispersion d'échantillonnage près tant que la graine n'est pas figée (§ 2.4.4, corrigé par R5). Le reste du dossier est déterministe.

**Critères couverts (C2.3.2).** ✓ La documentation identifie le public concerné, avec trois publics et leur entrée respective (§ 4.2.1), et comporte les trois éléments exigés. ✓ La description des sources de données : origine (Oracle PeopleSoft EP92U038, dictionnaire applicatif), périmètre (métadonnées uniquement, jamais le contenu métier), volumétrie, mode d'accès, chaîne de transformation, source externe des tarifs et corpus d'annotation du modèle (§ 4.2.2). ✓ La description des méthodes de calcul : neuf domaines, chacun rattaché à sa méthode et à son module versionné (§ 4.2.3). ✓ La description technique et fonctionnelle des indicateurs, sur cinq attributs — définition fonctionnelle, formule technique, source, unité, périmètre — dont un extrait au § 4.2.4 et le dictionnaire complet de trente indicateurs en annexe H. ✓ Elle assure la compréhension, la transmission et la reproductibilité : procédure exécutable, versionnement par `run_id` et `model_version`, configuration par instance et généricité de la source, la portée de cette garantie étant délimitée au § 4.2.5.

## 5. Conclusion

Ce bloc met le socle établi au Bloc 1 au service de la décision.

**Analyser.** Le besoin a été cadré par des entretiens exploratoires dont chaque information stratégique est tracée jusqu'à une exigence d'analyse. La question du commanditaire a été traduite en un plan à trois axes, exécuté en SQL, en Python et dans un dashboard, puis validée statistiquement : un modèle de classification calibré, quatre tests d'hypothèses avec leurs tailles d'effet, une simulation Monte-Carlo évaluée de façon critique. Une cinquième hypothèse a été écartée parce que la taille de l'échantillon l'aurait rendue faussement significative.

**Valoriser.** Les résultats sont restitués dans des visualisations justifiées et accessibles, et débouchent sur des recommandations argumentées. Le résultat le plus utile du dossier tient dans un renversement : ce qui est nombreux dans ce patrimoine n'est pas ce qui est lourd. Finance & Contrôle porte 45 % des actifs mais 7 % du coût, IT & Sécurité 21 % des actifs mais 85 % du coût et 94 % de l'économie possible. Une lecture au nombre d'actifs aurait désigné la mauvaise cible d'archivage ; c'est l'analyse croisée du volume et du coût qui évite l'erreur, et elle fonde les deux leviers distincts recommandés au commanditaire.

**Transmettre.** Un support de formation, avec objectifs pédagogiques, fiche de sensibilisation et quiz, rend les utilisateurs autonomes. Une documentation technique couvrant les sources, les méthodes, le dictionnaire d'indicateurs et la procédure de reproduction garantit la reprise de la solution par un tiers.

Trois limites bornent ces résultats. La justesse du classifieur est d'environ 75 %, soit une étiquette fausse sur quatre : les parts par domaine ne peuvent pas être citées à la décimale, et c'est ce qui fonde tout le dispositif de revue. La conclusion structurante résiste néanmoins, puisqu'elle repose sur un écart d'un facteur 20. Le score d'archivabilité, ensuite, est peu discriminant faute de signal d'accès dans la source. Les montants absolus, enfin, sont ceux d'un prototype de 7,84 Go : le livrable transposable est la méthode, avec le taux normalisé de 195 \$ par téraoctet archivé et par an.

Deux jalons d'évaluation restent à franchir : un jeu de test étiqueté indépendant, avec matrice de confusion et macro-F1, pour le classifieur ; un diagnostic de calibration, ECE et courbe de fiabilité, pour la confiance affichée. L'outillage existe dans le projet mais n'a pas encore été appliqué au modèle de production du Bloc 2.

L'ensemble reste générique et rejouable. Conçu comme un produit substituable d'un client PeopleSoft à l'autre, il alimente le Bloc 3, pour le pilotage du projet data, et le Bloc 5, où le transformeur XLM-RoBERTa mentionné au § 2.4.1 est développé.

## **Annexes (hors décompte de pages)**

(Hors décompte de pages, conformément aux modalités d'évaluation.)

## Annexe A — Grille d'entretien exploratoire complète

Grille semi-directive en cinq thèmes, appliquée aux trois interlocuteurs (§ 2.1.1).

| Thème                                   | Questions                                                                                                                                              | Intention                                                |
|-----------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------|
| <b>T1 — Douleur ressentie</b>           | Qu'est-ce qui vous gêne aujourd'hui dans la base ERP ?<br>Depuis quand ? Qu'avez-vous déjà tenté, et pourquoi cela n'a-t-il pas suffi ?                | Faire émerger le problème réel, pas la solution imaginée |
| <b>T2 — Connaissance du patrimoine</b>  | Comment savez-vous aujourd'hui à quoi sert une table ? Qui sait ?<br>Que se passe-t-il si cette personne n'est pas là ? Existe-t-il une cartographie ? | Mesurer la dépendance aux experts                        |
| <b>T3 — Décision d'archivage</b>        | Comment décide-t-on aujourd'hui d'archiver ou de purger ? Qui valide ? Sur quels critères ?<br>Qu'est-ce qui vous empêche de décider ?                 | Identifier le point de blocage décisionnel               |
| <b>T4 — Contraintes non négociables</b> | Qu'est-ce qui ne doit jamais arriver ? Quelles obligations légales ou d'audit pèsent sur ces données ? Quelles interdictions techniques ?              | Recueillir les contraintes dures avant conception        |
| <b>T5 — Critère de réussite</b>         | À quoi verrez-vous que la solution vous a servi ? Sous quelle forme voulez-vous le résultat ? À qui le montrerez-vous ?                                | Définir le format de restitution attendu                 |

De la parole recueillie à l'exigence d'analyse — table de correspondance complète (résumée au § 2.1.1) :

| Information recueillie (entretien)                                       | Exigence d'analyse dérivée                                                                                                      | Traitée en     |
|--------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------|----------------|
| « On ne sait pas à quoi servent les tables »                             | Classer automatiquement chaque actif dans un domaine métier, <b>avec un niveau de confiance explicite</b>                       | C2.1.2, C2.1.4 |
| « Il faut un chiffrage, pas un inventaire »                              | Produire un coût annuel par domaine à partir de <b>tarifs sourcés</b> , et une projection de gain                               | C2.1.3, C2.2.2 |
| « Une classification fausse qui déclenche une action est pire que rien » | Exposer un marqueur <b>`review_required`</b> et ne jamais présenter une recommandation d'archivage sans son niveau de confiance | C2.2.1, C2.3.1 |
| « Archiver ≠ supprimer, il y a des durées légales »                      | Distinguer explicitement les stratégies <b>conservation réglementaire</b> / archivage froid / conservation critique             | C2.2.2         |

| Information recueillie (entretien)                | Exigence d'analyse dérivée                                                         | Traitée en     |
|---------------------------------------------------|------------------------------------------------------------------------------------|----------------|
| « Lecture seule, VPN, aucune écriture sur l'ERP » | Contrainte technique d'architecture, reportée au registre des contraintes          | § 2.1.7        |
| « Le résultat doit être présentable à un comité » | Restitution en <b>dashboard</b> visuel + export tableur, pas en sortie de terminal | C2.1.3, C2.2.1 |

**Traitement des entretiens.** Prise de notes pendant l'échange, reformulation validée en fin d'entretien, puis consolidation dans la table ci-dessus, revue avec le commanditaire. Les interlocuteurs sont désignés par leur rôle et non par leur nom, l'organisation n'étant pas nommée dans un livrable de certification.

## Annexe B — Plan d'analyse : matrice question → métrique → source → livrable

| A<br>x<br>e | Question métier                              | Métrique                           | Formule                                | Table source                     | Restitué dans                                |
|-------------|----------------------------------------------|------------------------------------|----------------------------------------|----------------------------------|----------------------------------------------|
| 1           | Quel métier porte le patrimoine ?            | Nb actifs et part par domaine      | COUNT(*), part relative                | asset_business_domain_prediction | Donut<br>Vue d'ensemble · § 2.3.1            |
| 1           | Peut-on se fier à la classification ?        | Bandes de confiance, taux de revue | Discrétisation, SUM(CASE ...)/COUNT(*) | idem                             | § 2.3.1<br>requête B · § 2.4.1               |
| 1           | Les domaines ont-ils des profils distincts ? | Médiane du nb de colonnes          | PERCENTILE_CONT(0.5)                   | mv_asset_inventory               | Boxplot · test H1                            |
| 2           | Où est le volume ?                           | Volume par domaine                 | SUM(size_mb) groupé                    | mv_asset_inventory × prédiction  | Barres<br>Vue d'ensemble · § 2.3.1           |
| 2           | Où est le coût ?                             | Coût annuel, part du coût          | volume_go × hot_usd_gb_year            | × dim_cost_params                | Pareto<br>Coûts & ROI · § 2.3.1<br>requête C |
| 2           | Que peut-on économiser ?                     | Économie annuelle, % économisable  | volume_archivable × (hot - archive)    | × mv_archivability_ranking       | § 2.3.1<br>requête C · R2                    |

| A<br>x<br>e | Question<br>métier                   | Métrique                            | Formule                                                         | Table source          | Restitué<br>dans                      |
|-------------|--------------------------------------|-------------------------------------|-----------------------------------------------------------------|-----------------------|---------------------------------------|
| 2           | Le chiffre est-il transposable ?     | Taux d'économie normalisé           | $(\text{hot} - \text{archive}) \times 1024$                     | dim_cost_params       | § 3.2.6                               |
| 3           | Combien cela vaut-il dans le temps ? | Coût cumulé, gain net, quantile P10 | Monte-Carlo sur le taux de croissance                           | mv_roi_summary        | Courbes Coûts & ROI · § 2.4.4         |
| 3           | Comment cela évolue-t-il ?           | Écart N-1                           | $\text{valeur}(\text{run } n) - \text{valeur}(\text{run } n-1)$ | snapshots historiques | Bloc « Comparaison N-1 » du dashboard |

**Métriques planifiées mais non restituées dans ce dossier.** Le score de ROI par actif et la comparaison N-1 sont calculés par le pipeline et consultables dans le dashboard, mais ne portent aucune conclusion : l'historique de runs est trop court pour qu'une évolution soit interprétable. Ils restent dans le plan parce qu'ils deviendront exploitables, pas parce qu'ils l'étaient au run 9.

#### Enchaînement d'exécution du run

|                                                                 |                                    |
|-----------------------------------------------------------------|------------------------------------|
| run_id = 9                                                      |                                    |
| 1. Extraction Oracle (lecture seule, VPN)                       | → raw_oracle                       |
| 2. Normalisation, modèle en étoile                              | → processed                        |
| 3. Classification par domaine (2 passes)                        | → asset_business_domain_prediction |
| 4. Scoring d'archivabilité → 7 stratégies                       | → mv_archivability_ranking         |
| 5. Rafraîchissement des tarifs (API Azure)                      | → dim_cost_params                  |
| 6. Agrégation coûts + simulation ROI Monte-Carlo                | → mv_roi_summary                   |
| 7. Tests d'hypothèses (scipy)                                   | → bloc2_tests_resultats.md         |
| 8. Restitution : dashboard Streamlit + export Excel 13 feuilles |                                    |

## Annexe C — Requêtes, résultats et contrôle de cohérence

La requête A (cartographie et volume par domaine) et le résultat de la requête C figurent au § 2.3.1. Les captures des pages Vue d'ensemble, Coûts & ROI et Test du modèle figurent aux § 2.3.3 et § 3.1.3.

**Synthèse des indicateurs du run 9** (renvoi du § 2.3.5) :

| Indicateur                   | Valeur                                         | Périmètre          |
|------------------------------|------------------------------------------------|--------------------|
| Actifs classés en 7 domaines | 167 260                                        | catalogue complet  |
| Domaine dominant en nombre   | Finance & Contrôle — 45,1 %<br>(75 495 actifs) | catalogue complet  |
| Domaine dominant en volume   | IT & Sécurité — 85,3 % (6 846 Mo)              | volumétrie mesurée |

| Indicateur                                         | Valeur                                | Périmètre                |
|----------------------------------------------------|---------------------------------------|--------------------------|
| Confiance <i>medium</i> / <i>low</i> / <i>high</i> | 54,2 % / 25,6 % / 20,2 %              | catalogue complet        |
| Actifs à réviser                                   | 27,1 % (45 269)                       | catalogue complet        |
| Justesse du classifieur                            | ≈ 75 % (revue humaine)                | modèle du run 9          |
| Patrimoine mesuré                                  | 7,84 Go sur 15 854 tables             | volumétrie mesurée       |
| Tarifs chaud / archive                             | 0,2120 / 0,0216 \$/Go/an — écart ×9,8 | dim_cost_params          |
| Coût annuel actuel                                 | 1,66 \$/an                            | volumétrie mesurée       |
| Économie possible                                  | 1,25 \$/an (−75,3 %)                  | volumétrie mesurée       |
| Taux d'économie normalisé                          | 195 \$/To archivé/an                  | transposable à l'échelle |
| Candidats à l'archivage froid                      | 6 854 actifs · 6,6 Go                 | actifs scorés            |

Calcul du test H1 et de sa taille d'effet (renvoi du § 2.3.2), scripts/bloc2\_hypothesis\_tests.py :

```
from scipy.stats import kruskal

groupes = [g["column_count"].dropna().values
            for _, g in df.groupby("business_domain_predicted")]
H, p = kruskal(*groupes)

# Taille d'effet epsilon2 : indispensable, car a n = 60 284
# la p-value seule serait significative pour un ecart negligeable.
n = sum(len(g) for g in groupes)
k = len(groupes)
epsilon2 = (H - k + 1) / (n - k)
print(f"H={H:.1f} p={p:.3g} epsilon2={epsilon2:.3f}")
# -> H=12783.3 p<0.001 epsilon2=0.212 (effet fort)
```

Requête B — bandes de confiance et taux de revue (renvoi du § 2.3.1) :

```
SELECT CASE WHEN confidence >= :seuil_high THEN 'high' -- seuils versionnés
           WHEN confidence >= :seuil_medium THEN 'medium' -- dans la config du run
           ELSE 'low' END                               AS bande_confiance,
COUNT(*)                                              AS nb_actifs,
ROUND(100.0 * COUNT(*) / SUM(COUNT(*)) OVER (), 1) AS part_pct,
SUM(CASE WHEN review_required THEN 1 ELSE 0 END)     AS dont_a_reviser
FROM   serving.asset_business_domain_prediction
WHERE  run_id = 9
GROUP BY 1
ORDER BY MIN(confidence) DESC;
```

Requête C — coût et gain par domaine, texte intégral (renvoi du § 2.3.1) :

```

WITH vol AS (
    -- volume total et volume archivable, par domaine
    SELECT p.business_domain_predicted AS domaine,
           SUM(inv.size_mb) / 1024.0 AS volume_go,
           SUM(CASE WHEN r.strategy LIKE 'ARCHIVAGE%'
                    THEN inv.size_mb ELSE 0 END) / 1024.0 AS volume_archivable_go
    FROM   serving.asset_business_domain_prediction p
    JOIN   serving.mv_asset_inventory inv ON inv.asset_id = p.asset_id AND inv.run_id =
p.run_id
    LEFT JOIN serving.mv_archivability_ranking r ON r.asset_id = p.asset_id AND r.run_id =
p.run_id
    WHERE  p.run_id = 9 GROUP BY 1
)
SELECT v.domaine,
       ROUND(v.volume_go, 4) AS total_size_gb,
       ROUND(v.volume_go * c.hot_usd_gb_year, 2) AS current_cost_usd_year,
       ROUND(v.volume_archivable_go
             * (c.hot_usd_gb_year - c.archive_usd_gb_year), 2) AS annual_savings_usd,
       ROUND(100.0 * v.volume_archivable_go
             * (c.hot_usd_gb_year - c.archive_usd_gb_year)
             / NULLIF(v.volume_go * c.hot_usd_gb_year, 0), 1) AS savings_pct,
       ROUND(100.0 * v.volume_go / SUM(v.volume_go) OVER (), 2) AS volume_share_pct,
       ROUND(100.0 * ROUND(v.volume_go * c.hot_usd_gb_year, 2)
             / SUM(ROUND(v.volume_go * c.hot_usd_gb_year, 2)) OVER (), 2)
             AS cost_share_pct,
       ROUND(100.0 * ROUND(v.volume_archivable_go
             * (c.hot_usd_gb_year - c.archive_usd_gb_year), 2)
             / SUM(ROUND(v.volume_archivable_go
             * (c.hot_usd_gb_year - c.archive_usd_gb_year), 2)) OVER (), 1)
             AS savings_share_pct
FROM   vol v CROSS JOIN serving.dim_cost_params c
WHERE  c.run_id = 9
ORDER BY current_cost_usd_year DESC;

```

Complément sur les trois colonnes de parts :

```

ROUND(100.0 * v.volume_go / SUM(v.volume_go) OVER (), 2) AS volume_share_pct,
ROUND(100.0 * ROUND(v.volume_go * c.hot_usd_gb_year, 2)
      / SUM(ROUND(v.volume_go * c.hot_usd_gb_year, 2)) OVER (), 2)
      AS cost_share_pct,
ROUND(100.0 * ROUND(v.volume_archivable_go
      * (c.hot_usd_gb_year - c.archive_usd_gb_year), 2)
      / SUM(ROUND(v.volume_archivable_go
      * (c.hot_usd_gb_year - c.archive_usd_gb_year), 2)) OVER (), 1)
      AS savings_share_pct

```

Noter que `cost\_share\_pct` divise des montants déjà arrondis au cent : c'est la raison de l'écart de 0,2 point entre part de coût et part de volume relevé au § 2.3.1.

**Chaîne de contrôle de cohérence, détaillée.** Chaque égalité ci-dessous a été vérifiée à la main entre deux écrans du dashboard alimentés par des vues distinctes :

| Contrôle     | Calcul                                  | Attendu | Écran de contrôle          |
|--------------|-----------------------------------------|---------|----------------------------|
| Volume total | Σ des 7 volumes par domaine = 7,8366 Go | 7,8 Go  | Carte « Patrimoine total » |




| Contrôle          | Calcul                                      | Attendu                  | Écran de contrôle            |
|-------------------|---------------------------------------------|--------------------------|------------------------------|
| Coût annuel       | $7,8366 \times 0,211968 = 1,661 \text{ \$}$ | 1,66 \$                  | Année 0 de la projection ROI |
| Taux de réduction | $1,25 / 1,66 = 75,3 \text{ \%}$             | badge « -75 % »          | Carte « Économie possible »  |
| Taux normalisé    | $(0,211968 - 0,0216) \times 1024 = 194,9$   | 195 \$/To/an             | Bandeau Vue d'ensemble       |
| Gain net N+5      | $14,50 - 3,31 = 11,19 \text{ \$}$           | médiane de la courbe     | Graphique gain net cumulé    |
| Ratio d'économie  | $14,50 / 3,31 = 4,38$                       | « $\approx \times 4,4$ » | § 2.4.4                      |
| Parts d'économie  | $1,18 / 1,25 = 94,4 \text{ \%}$             | 94,4 %                   | Colonne savings_share_pct    |

**Écarts d'arrondi identifiés.** La somme des volumes affichés vaut 8 024 Mo pour 8 024,7 mesurés. L'économie vaut 1,25 \$ en sommant les arrondis par domaine, 1,26 \$ en calcul direct sur l'écran ROI. Les parts de coût sont calculées sur des montants arrondis au cent, d'où l'écart de deux dixièmes de point avec les parts de volume. Aucun de ces écarts n'excède le cent ou le dixième de point.

### Annexe D — Rapport complet des tests statistiques

Fichier joint : bloc2\_tests\_resultats.md — sortie brute de scripts/bloc2\_hypothesis\_tests.py sur le run 9 (H0/H1, test, statistique, p-value, taille d'effet, interprétation pour chacune des quatre hypothèses, plus la note sur l'hypothèse écartée).

### Annexe E — Visualisations et note d'accessibilité



Page « Test du modèle » : saisie des métadonnées d'une table, domaine prédit (RH, 92,3 %) et distribution des probabilités calibrées sur les 7 classes. Le parti pris de représentation — afficher toute la distribution et pas

*seulement la classe gagnante — vaut pour les deux modèles du projet. Rappel de périmètre : le modèle interrogé en interactif sur cette page est le transformeur XLM-RoBERTa du Bloc 5, distinct du LinearSVC calibré qui a produit les 167 260 classifications du dossier.*

**Alternatives de représentation écartées** (renvoi du § 3.1.1) :

| Donnée                  | Alternative écartée             | Motif du rejet                                          |
|-------------------------|---------------------------------|---------------------------------------------------------|
| Répartition par domaine | Camembert 3D                    | Déforme les proportions perçues                         |
| Volume par domaine      | Barres verticales               | Libellés de domaines longs illisibles en oblique        |
| Concentration du coût   | Tableau trié                    | Exact, mais ne montre pas visuellement la concentration |
| Projection de ROI       | Courbe médiane unique           | Donne une fausse impression de précision                |
| Probabilités par classe | Affichage du seul label gagnant | Masque l'incertitude du modèle                          |

**Principes appliqués** (détail au § 3.1.5) : la couleur n'est jamais seule porteuse d'information (libellé + position + valeur affichée) ; aucune échelle rouge-vert, dégradés monochromes pour les intensités ; contraste texte/fond conforme au seuil WCAG AA de 4,5:1 ; encodage des comparaisons par la longueur (barres) et non par l'aire colorée ; toute valeur lue sur un graphique est disponible en tableau et en export.

**Correspondance avec les critères WCAG 2.1 visés**

| Critère | Intitulé                            | Mise en œuvre                                         | État                                                                                     |
|---------|-------------------------------------|-------------------------------------------------------|------------------------------------------------------------------------------------------|
| 1.4.1   | Utilisation de la couleur           | Libellé, position et valeur redondants avec la teinte | Couvert                                                                                  |
| 1.4.3   | Contraste minimal (AA)              | Texte sombre #0F172A sur fond clair                   | Couvert                                                                                  |
| 1.4.11  | Contraste des éléments non textuels | Bordures et séparateurs contrastés                    | Partiellement couvert                                                                    |
| 1.1.1   | Contenu non textuel                 | Alternative textuelle des graphiques                  | <b>Non couvert</b> — contourné par la disponibilité systématique des tableaux et exports |
| 2.1.1   | Clavier                             | Navigation complète au clavier du dashboard           | <b>Non couvert</b>                                                                       |

**Travaux d'accessibilité restant à mener** : palette validée pour les déficiences de la vision des couleurs, libellés alternatifs exposés aux lecteurs d'écran sur les graphiques Altair, parcours clavier complet, puis audit WCAG formel.

## Annexe F — Fiche recto de synthèse pour le décideur

**Le constat en une ligne.** Ce qui est nombreux dans ce patrimoine n'est pas ce qui est lourd : Finance & Contrôle porte 45 % des actifs mais 7 % du coût ; IT & Sécurité porte 21 % des actifs mais 85 % du coût et 94 % du potentiel d'économie.

**Deux chantiers, pas un.**

|                        | Levier A — Gouvernance                             | Levier B — Coût               |
|------------------------|----------------------------------------------------|-------------------------------|
| <b>Cible</b>           | Finance & Contrôle et domaines sous-documentés     | IT & Sécurité                 |
| <b>Gain</b>            | Qualité, auditable, moindre dépendance aux experts | 94,4 % de l'économie possible |
| <b>Porteur</b>         | Référents métier + analystes de gouvernance        | DSI / exploitation            |
| <b>Recommandations</b> | R1, R3, R4                                         | R2                            |

Les cinq recommandations, par priorité.

| Ordre | Reco                                                             | Constat chiffré                                                                    | Effort |
|-------|------------------------------------------------------------------|------------------------------------------------------------------------------------|--------|
| 1     | <b>R2</b> — Archivage froid IT & Sécurité, première vague        | 94,4 % de l'économie · $\approx 6,20$ Go archivables · écart de tarif $\times 9,8$ | Moyen  |
| 2     | <b>R4</b> — Documenter les domaines faibles ( <i>quick win</i> ) | H3 : l'absence de description dépend du domaine ( $V = 0,148$ )                    | Faible |
| 3     | <b>R1</b> — Valider Finance en priorité                          | 45,1 % des actifs · tables les plus complexes (médiane 17 colonnes)                | Moyen  |
| 4     | <b>R3</b> — Résorber les cas à réviser                           | 27,1 % des actifs · justesse du modèle $\approx 75$ %                              | Élevé  |
| 5     | <b>R5</b> — Sourcer et figer le modèle de coût                   | Croissance de 15 %/an postulée, non observée                                       | Faible |

Objections anticipées et réponses préparées (renvoi du § 3.2.7) :

| Objection probable du jury / commanditaire                                                  | Réponse                                                                                                                                                                                                                                                       |
|---------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| « Vos économies valent un dollar par an. »                                                  | Exact — 1,25 \$/an sur les 7,84 Go réellement mesurés (le coût total, lui, vaut 1,66 \$/an). C'est le périmètre d'un prototype. Le livrable transposable est le <b>taux normalisé de 195 \$/To archivé/an</b> et la méthode, pas le montant absolu (§ 3.2.6). |
| « Pourquoi le modèle n'est-il sûr qu'à 68 % en médiane ? »                                  | Parce qu'il est <b>calibré</b> (Platt scaling). Un modèle qui afficherait 95 % de confiance sur des noms de tables opaques, pour une justesse réelle de 75 %, serait sur-confiant donc dangereux (§ 2.4.1).                                                   |
| « Vos tests sont tous significatifs. N'est-ce pas l'effet de la taille de l'échantillon ? » | Si, et c'est la raison pour laquelle chaque test est accompagné d'une taille d'effet. H3 est significatif mais faible, $V = 0,148$ , et c'est reporté comme tel. Une cinquième hypothèse a d'ailleurs été écartée pour cette raison précise (§ 2.4.5).        |
| « Le taux de croissance de 15 % sort d'où ? »                                               | D'une hypothèse, pas d'une mesure. C'est la limite n° 1 de la simulation, publiée avec son quantile P10, et l'objet de la recommandation R5.                                                                                                                  |

| Objection probable du jury / commanditaire                                                               | Réponse                                                                                                                                                                                                                                                                                                                                                               |
|----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| « Vos parts par domaine reposent sur des étiquettes prédites. Quelle est leur justesse ? »               | Environ 75 %, validée par revue humaine (§ 2.4.1). Une étiquette sur quatre est fausse, ce qui interdit de citer les parts à la décimale et fonde tout le dispositif de revue. La conclusion structurante résiste néanmoins : sur le potentiel d'économie, le rapport de 20 à 1 entre IT & Sécurité et le domaine suivant n'est pas renversé par un bruit d'un quart. |
| « Pouvez-vous nommer cinq tables que vous recommandez d'archiver et prouver qu'elles sont techniques ? » | Pas depuis ce dossier : l'analyse est agrégée par domaine. La liste nominative existe dans mv_archivability_ranking et dans l'export tableur (feuille « top candidats »), et c'est exactement l'objet de la revue nominative posée en prérequis de R2. C'est une limite de granularité du dossier, pas du système.                                                    |

#### Les trois réserves à connaître avant de citer un chiffre.

1. **Justesse du classifieur ≈ 75 %** — une étiquette sur quatre est fausse. Ne pas citer les parts par domaine à la décimale ; ne rien archiver sans revue.
2. **Montants absolus non budgétaires** — 1,66 \$/an de coût et 1,25 \$/an d'économie sur 7,84 Go mesurés. Le chiffre transposable est **195 \$/To archivé/an**.
3. **Projection à 5 ans indicative** — le taux de croissance est une hypothèse. Exploitable à 2 ans (P10 à 6 % de la médiane), indicative à 5 ans (P10 à 16 %).

### Annexe G — Support de formation et de sensibilisation

Fichier joint : BLOC2\_support\_formation.docx / .md — six modules, objectifs pédagogiques, quiz de validation en 6 questions avec corrigé, et fiche de sensibilisation d'une page.

### Annexe H — Dictionnaire complet des indicateurs

| Indicateur             | Définition fonctionnelle                        | Formule technique                         | Table source                     | Unité    | Périmètre                   |
|------------------------|-------------------------------------------------|-------------------------------------------|----------------------------------|----------|-----------------------------|
| <b>Actifs classés</b>  | Objets de données rattachés à un domaine métier | COUNT(*)                                  | asset_business_domain_prediction | actifs   | catalogue complet (167 260) |
| <b>Domaines métier</b> | Nombre de classes de classification             | COUNT(DISTINCT business_domain_predicted) | idem                             | domaines | catalogue complet           |

| Indicateur                         | Définition fonctionnelle                                                             | Formule technique                                                        | Table source             | Unité     | Périmètre                                |
|------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------|--------------------------|-----------|------------------------------------------|
| <b>Part d'un domaine</b>           | Poids relatif d'un domaine en nombre d'actifs                                        | <code>COUNT(*) / SUM(COUNT(*)) OVER ()</code>                            | idem                     | %         | catalogue complet                        |
| <b>Confiance de classification</b> | Certitude du modèle sur le domaine attribué                                          | Probabilité calibrée (Platt) ou score de règle                           | ...prediction.confidence | 0–1       | catalogue complet                        |
| <b>Bande de confiance</b>          | Discretisation opérationnelle de la confiance en trois classes (high / medium / low) | Seuils paramétrés et versionnés dans score_business_domain.py            | idem                     | catégorie | catalogue complet — 20,2 / 54,2 / 25,6 % |
| <b>Taux de revue</b>               | Part des actifs à vérifier avant toute action                                        | <code>SUM(CASE WHEN review_required THEN 1 ELSE 0 END) / COUNT(*)</code> | idem                     | %         | catalogue complet                        |
| <b>Méthode de classification</b>   | Passe ayant produit la prédiction                                                    | <code>method ∈ {keyword, ml}</code>                                      | idem                     | catégorie | catalogue complet                        |
| <b>Version de modèle</b>           | Identifiant du modèle ayant scoré la ligne                                           | model_version                                                            | idem                     | texte     | catalogue complet                        |

| Indicateur                            | Définition fonctionnelle                                                              | Formule technique                                                | Table source                       | Unité    | Périmètre                                              |
|---------------------------------------|---------------------------------------------------------------------------------------|------------------------------------------------------------------|------------------------------------|----------|--------------------------------------------------------|
| <b>Justesse du classifieur</b>        | Part d'étiquettes jugées correctes en revue humaine — métrique de référence du modèle | Revue humaine sur échantillon, rapportée dans la fiche de modèle | artifacts/production_model_card.md | %        | ≈ 75 %<br>(run 9)                                      |
| <b>Accord avec l'annotateur</b>       | Part d'étiquettes identiques à l'annotation LLM de référence                          | Comparaison prédiction / corpus de référence                     | idem                               | %        | ≈ 89 %<br>— <b>non retenu comme mesure de justesse</b> |
| <b>Nombre de colonnes</b>             | Largeur structurelle d'un actif                                                       | column_count                                                     | mv_asset_inventory                 | colonnes | structure connue<br>(60 284)                           |
| <b>Complexité médiane par domaine</b> | Largeur typique des tables d'un domaine                                               | PERCENTILE_CONT(0.5) sur column_count                            | idem                               | colonnes | structure connue                                       |
| <b>Volume d'un actif</b>              | Espace disque occupé                                                                  | size_mb                                                          | mv_asset_inventory                 | Mo       | volumétrie mesurée<br>(15 854)                         |
| <b>Volume par domaine</b>             | Espace disque par domaine métier                                                      | SUM(size_mb) groupé par domaine                                  | idem × prédiction                  | Mo / Go  | volumétrie mesurée                                     |
| <b>Patrimoine total mesuré</b>        | Volumétrie totale réellement mesurée                                                  | SUM(size_mb) / 1024                                              | idem                               | Go       | volumétrie mesurée<br>(7,84 Go)                        |

| Indicateur                           | Définition fonctionnelle                                  | Formule technique                                     | Table source                               | Unité    | Périmètre                      |
|--------------------------------------|-----------------------------------------------------------|-------------------------------------------------------|--------------------------------------------|----------|--------------------------------|
| <b>Tarif stockage chaud</b>          | Prix du stockage actif, sourcé d'API                      | hot_usd_gb_year                                       | dim_cost_params                            | \$/Go/an | run (0,2120)                   |
| <b>Tarif archive</b>                 | Prix du stockage froid, sourcé d'API                      | archive_usd_gb_year                                   | idem                                       | \$/Go/an | run (0,0216)                   |
| <b>Coût annuel actuel</b>            | Coût du stockage chaud du périmètre                       | volume_go × hot_usd_gb_year                           | mv_asset_inventory × dim_cost_params       | \$/an    | volumétrie mesurée             |
| <b>Économie annuelle potentielle</b> | Gain d'un archivage des candidats identifiés              | volume_archivable_go × (hot - archive)                | mv_archivability_ranking × dim_cost_params | \$/an    | volumétrie mesurée             |
| <b>Pourcentage économisable</b>      | Part du coût d'un domaine qui peut être évitée            | économie / coût_actuel                                | idem                                       | %        | par domaine                    |
| <b>Part du coût</b>                  | Concentration du coût par domaine                         | coût_domaine / coût_total                             | idem                                       | %        | par domaine                    |
| <b>Part de l'économie</b>            | Concentration du potentiel de gain                        | économie_domaine / économie_totale                    | idem                                       | %        | par domaine                    |
| <b>Taux d'économie normalisé</b>     | Économie par téraoctet archivé — transposable à l'échelle | (hot - archive) × 1024                                | dim_cost_params                            | \$/To/an | indépendant de l'échelle (195) |
| <b>Score d'archivabilité</b>         | Propension à être archivé sans risque                     | Score composite (volumétrie, âge, lignage), base 45,0 | mv_archivability_ranking                   | 0–100    | volumétrie mesurée             |

| Indicateur                   | Définition fonctionnelle                    | Formule technique                                                       | Table source          | Unité     | Périmètre          |
|------------------------------|---------------------------------------------|-------------------------------------------------------------------------|-----------------------|-----------|--------------------|
| <b>Stratégie recommandée</b> | Action différenciée préconisée pour l'actif | Règles sur score, sensibilité et rétention → 7 stratégies               | idem                  | catégorie | volumétrie mesurée |
| <b>Score de ROI</b>          | Gain estimé rapporté à l'effort d'archivage | Score composite                                                         | mv_roi_summary        | 0–100     | volumétrie mesurée |
| <b>Coût cumulé projeté</b>   | Coût sur N années par scénario              | Cumul de $\text{coût\_annuel} \times (1 + g)^k$ , g tiré en Monte-Carlo | idem                  | \$        | projection         |
| <b>Gain net cumulé (P50)</b> | Économie cumulée médiane sur N années       | Médiane des tirages de $\Sigma(\text{coût\_sans} - \text{coût\_avec})$  | idem                  | \$        | projection         |
| <b>Intervalle P10–P90</b>    | Plage d'incertitude de la projection        | Quantiles 10 % et 90 % des tirages                                      | idem                  | \$        | projection         |
| <b>Écart N-1</b>             | Évolution d'un indicateur entre deux runs   | $\text{valeur}(\text{run\_n}) - \text{valeur}(\text{run\_n}-1)$         | snapshots historiques | Δ et %    | inter-runs         |

## Annexe I — Correspondance grille d'évaluation / dossier

| Compétence    | Critère de la grille                                                                 | Traité en                  |
|---------------|--------------------------------------------------------------------------------------|----------------------------|
| <b>C2.1.1</b> | Enjeux et problématique                                                              | § 2.1.4 · synthèse § 2.1.2 |
| <b>C2.1.1</b> | Contexte                                                                             | § 2.1.5 · synthèse § 2.1.2 |
| <b>C2.1.1</b> | Environnement                                                                        | § 2.1.6 · synthèse § 2.1.2 |
| <b>C2.1.1</b> | Contraintes (délai, logistique, coût, technique, réglementaire)                      | § 2.1.7 · synthèse § 2.1.2 |
| <b>C2.1.1</b> | <i>Entretiens exploratoires et informations stratégiques</i> (libellé de compétence) | § 2.1.1 · annexe A         |
| <b>C2.1.1</b> | <i>Périmètre, hors-périmètre et validation du besoin</i>                             | § 2.1.3 · § 2.1.1          |
| <b>C2.1.2</b> | Le plan décrit les axes et les métriques nécessaires                                 | § 2.2.2                    |



| Compétence    | Critère de la grille                                        | Traité en                                            |
|---------------|-------------------------------------------------------------|------------------------------------------------------|
| <b>C2.1.2</b> | Traduction de la problématique client en problème numérique | § 2.2.1                                              |
| <b>C2.1.3</b> | Plusieurs techniques d'analyse sont présentées              | § 2.3.1 à 2.3.4                                      |
| <b>C2.1.3</b> | Résultats justes obtenus rapidement                         | § 2.3.1 (résultats + contrôle de cohérence), § 2.3.5 |
| <b>C2.1.3</b> | Restitution sous forme de dashboard                         | § 2.3.3 + capture                                    |
| <b>C2.1.4</b> | Formulation d'une ou plusieurs hypothèses                   | § 2.4.3 (H1 à H4, H0/H1 explicites)                  |
| <b>C2.1.4</b> | Le test statistique associé                                 | § 2.4.3 (test justifié pour chaque hypothèse)        |
| <b>C2.1.4</b> | L'interprétation des résultats                              | § 2.4.3 (interprétation métier + taille d'effet)     |
| <b>C2.1.4</b> | Modélisation de relations entre variables                   | § 2.4.1 (LinearSVC calibré), H2 (corrélation)        |
| <b>C2.1.4</b> | Évaluation de la pertinence des résultats des simulations   | § 2.4.4 (Monte-Carlo, P10–P90, trois réserves)       |
| <b>C2.1.4</b> | Les résultats valident ou réfutent l'hypothèse initiale     | § 2.4.3 et § 2.4.5                                   |
| <b>C2.2.1</b> | Choix des outils et représentations justifié avec bénéfices | § 3.1.1 et § 3.1.2                                   |
| <b>C2.2.1</b> | Mise en forme claire et juste pour le public ciblé          | § 3.1.4                                              |
| <b>C2.2.1</b> | Prise en compte des situations de handicap                  | § 3.1.5                                              |
| <b>C2.2.2</b> | Présentation structurée, synthétique et argumentée          | § 3.2.1 à 3.2.5, § 3.2.8                             |
| <b>C2.2.2</b> | Préparation du discours et des arguments                    | § 3.2.7                                              |
| <b>C2.2.2</b> | Les recommandations éclairent la prise de décision          | § 3.2.5 (priorisation), § 3.2.6 (réserve d'échelle)  |
| <b>C2.3.1</b> | L'enjeu et le sujet de la formation sont présentés          | § 4.1.1                                              |
| <b>C2.3.1</b> | Analyse du besoin de montée en compétences                  | § 4.1.2                                              |
| <b>C2.3.1</b> | Support adapté permettant la montée en compétences          | § 4.1.4, § 4.1.5 · annexe G                          |
| <b>C2.3.2</b> | Description des sources de données (origine, périmètre)     | § 4.2.2                                              |
| <b>C2.3.2</b> | Description des méthodes de calcul                          | § 4.2.3                                              |
| <b>C2.3.2</b> | Description technique et fonctionnelle des indicateurs      | § 4.2.4 · annexe H                                   |
| <b>C2.3.2</b> | Compréhension, transmission et reproductibilité             | § 4.2.1, § 4.2.5                                     |

## Annexe J — Procédure de reproduction

```
# 1. Environnement
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt

# 2. Exécution complète du pipeline → nouveau run_id
python -m src.pipeline.run_all --config config/ep92u038.yaml

# 3. Rejouer les tests statistiques du dossier sur le run 9
python scripts/bloc2_hypothesis_tests.py --run-id 9

# 4. Régénérer l'export tableur 13 feuilles
python scripts/export_domain_model.py --run-id 9 --out domain_model_run9.xlsx

# 5. Ouvrir le dashboard
streamlit run app/streamlit_dashboard.py
```

Prérequis : accès en lecture à l'instance source (VPN) et dépendances du fichier `requirements.txt`.  
Les étapes 3 à 5 se rejouent sur un run existant sans réexécuter l'extraction.