

ANNEXES AU DOSSIER DE CERTIFICATION

Annexes

Titre visé : Ingénieur en science des données spécialisé en infrastructure data ou en apprentissage automatique — RNCP 39586 (niveau 7)

Projet : Solution de gouvernance et d'archivage intelligent des données d'un ERP
PeopleSoft (Oracle EP92U038)

Annexes A à I — livrables de pilotage du Bloc 3
Pièce jointe au dossier « Bloc 3 — Élaborer et piloter un projet data »

Candidat : HAOUARI Salem

Mastère 2 — filière IA & Data · YNOV

Date : 29/07/2026

Annexe A — Planning détaillé

Le projet a débuté le 9 mars 2026. Les dates de phase ne sont pas reconstruites : les premières sont établies par les runs journalisés dans `admin.pipeline_run`, les suivantes par l'historique Git, le dépôt ayant été formalisé en juin. La charge de l'annexe A.3, en revanche, est une estimation reconstituée, signalée comme telle.




Diagramme de Gantt du projet : six phases réelles de mars à août 2026, datées par les runs du pipeline et l'historique Git.

A.1 Phases et lots de travail

Phase	Période	Lots de travail	Jalon de vérification
P0 — Cadrage et collecte	09/03 → 31/03	Entretiens de cadrage · connexion Oracle · extraction du dictionnaire de données · premiers cycles de chargement	Runs 3 (13/03) et 4 (23/03)
P1 — Modélisation et analyse	01/04 → 31/05	Modèle en étoile · classification par domaine · comparaison inter-runs · projection de ROI	Runs 5 (22/04) et 6 (31/05)
P2 — Sûreté et fiabilité	01/06 → 09/06	Mécanismes de reprise · journal d’audit · masquage des données personnelles · calibration du modèle	Commits phase0, phase1
P3 — Apprentissage profond	09/06 → 19/06	Fine-tuning du transformeur, versions 1 et 3 · page de test interactif	Commits xlmr, page de test
P4 — Sécurité et sources externes	07/07 → 17/07	Tarifs par API · chiffrement pgcrypto · rôles séparés · refonte du dashboard · console SQL	Commits extract, security, console SQL
P5 — Certification	14/07 → 29/08	Dossiers des Blocs 1, 2, 3 et 5 · annexes · préparation de la soutenance	Dépôts des semaines 29, 31 et 34

A.2 Jalons externes de certification

Jalon	Échéance	Statut
Dépôt du Bloc 1, rendu écrit	Semaine 29 — 13 au 17/07/2026	Tenu
Dépôt du Bloc 2, rendu écrit	Semaine 31 — 27 au 31/07/2026	Tenu
Dépôt du Bloc 3, rendu écrit	Semaine 34 — 17 au 21/08/2026	En cours
Soutenance orale du bloc de spécialité	Semaines 36 à 40 — 01 au 29/09/2026	À venir

A.3 Charge estimée par phase

Le travail effectif représente **quatre semaines, soit environ 20 jours-homme**, réparties de façon discontinue sur les 173 jours calendaires du projet. La ventilation est **reconstituée a posteriori** à partir des dates de phase, des runs journalisés et de la densité de l'historique Git. Il ne s'agit pas d'un relevé de temps.

Phase	Charge estimée	Part du total
P0 — Cadrage et collecte	3 j·h	15 %
P1 — Modélisation et analyse	7 j·h	35 %
P2 — Sûreté et fiabilité	2 j·h	10 %
P3 — Apprentissage profond	2 j·h	10 %
P4 — Sécurité et sources externes	2 j·h	10 %
P5 — Certification	4 j·h	20 %
Total	20 j·h	100 %

La période compte 173 jours calendaires, soit environ 124 jours ouvrés hors congés : la charge correspond donc à un taux d'occupation de l'ordre de **16 %**. Le projet a avancé par sessions courtes séparées de périodes sans activité, dont la plus longue — dix-sept jours, du 20 juin au 6 juillet — sépare les phases P3 et P4. Au taux de référence de l'annexe C, ces 20 jours-homme représentent un équivalent-charge de 10 000 € ; le coût réellement engagé est nul.

A.4 Méthodologie de conduite

Kanban, en flux continu — *à faire, en cours, fait* — avec limitation du travail en cours, jalonné par les échéances de certification. Le choix et ses bénéfices sont argumentés au § 3.1.1 du dossier.

Annexe B — Matrice RACI du scénario d'industrialisation

Pour un déploiement chez un client, la solution serait portée par une équipe de trois à quatre personnes. R désigne celui qui réalise, A celui qui approuve, C celui qui est consulté, I celui qui est informé.

Activité	Chef de projet data	Ingénieur données	Ingénieur ML	Analyste métier
Cadrage et spécifications	A	C	C	R
Collecte et ETL Oracle	I	R	C	I
Modélisation ML et scoring	A	C	R	C
Dashboard et restitution	I	C	I	R
Sécurité et conformité RGPD	A	R	I	C

Activité	Chef de projet data	Ingénieur données	Ingénieur ML	Analyste métier
Recette et validation métier	A	I	I	R
Documentation projet	C	C	C	R

Équilibrage de la charge. Chaque membre porte un domaine principal en tant que réalisateur, tout en étant consulté sur les interfaces avec les domaines voisins, ce qui évite à la fois la surcharge d'un point de passage obligé et le cloisonnement de chacun dans son périmètre. La ventilation chiffrée figure en annexe C.4.

Annexe C — Chiffrage détaillé du déploiement

C.1 Charge et coût par lot

Lot	Charge	Coût	Rôle porteur
Cadrage et connexion à l'instance client	6 j·h	3 000 €	Chef de projet et analyste métier
Adaptation de la collecte et première exécution	10 j·h	5 000 €	Ingénieur données
Réentraînement et validation du classifieur	8 j·h	4 000 €	Ingénieur ML
Paramétrage du dashboard et des règles d'archivage	6 j·h	3 000 €	Analyste métier
Revue de sécurité et conformité RGPD	5 j·h	2 500 €	Ingénieur données
Recette, formation et documentation	5 j·h	2 500 €	Analyste métier et chef de projet
Sous-total charge	40 j·h	20 000 €	
Infrastructure : base managée et hébergement, 3 mois	—	600 €	
Provision pour aléas, 10 % de la charge et de l'infrastructure	—	2 060 €	
Budget indicatif		≈ 23 000 € HT	

Hypothèse de valorisation : taux journalier moyen de 500 € HT, ordre de grandeur du marché français pour des profils data confirmés en prestation. Ce taux est une hypothèse de chiffrage et non un tarif négocié.

Délai. Quarante jours-homme sur une équipe de trois à quatre intervenants à temps partiel représentent environ trois semaines de travail effectif. Les dépendances entre lots, la disponibilité des interlocuteurs du client et le temps de recette portent le délai calendaire à deux à trois mois.

C.2 Justification économique

Le budget ne se justifie pas par la seule économie de stockage. Au taux mesuré de 195 \$ par téraoctet archivé et par an, une base ERP de quelques téraoctets ne dégage que quelques centaines de dollars d'économie annuelle.

La justification repose sur le **coût évité de la cartographie manuelle**. Cartographier 167 260 actifs à la main, à raison de trente secondes par actif pour un expert du progiciel, représente environ 1 400 heures, soit de l'ordre de 175 jours-homme sur une base de 8 heures. Au même taux journalier, cela dépasse 85 000 € pour un seul patrimoine, soit près de quatre fois le budget de déploiement, et le résultat serait figé le jour de sa production alors que la solution se rejoue à chaque exécution. S'y ajoutent deux bénéfices non monétarisés : la réduction de la dépendance à quelques experts, et la capacité à répondre à une demande de conformité sur l'origine et la rétention des données.

C.3 Écart entre le prototype et l'industrialisation

	Prototype réalisé	Déploiement client
Charge	20 j·h	40 j·h
Coût engagé	0 €	≈ 23 000 € HT
Délai calendaire	173 jours, à 16 % d'occupation	2 à 3 mois, équipe à temps partiel

Le rapport de deux entre les deux charges s'explique par ce que le déploiement ajoute et par ce qu'il n'a plus à faire. Il n'y a plus de développement : le produit existe, et la charge de conception ne se refait pas. Mais il faut adapter la collecte à une instance de production et à sa volumétrie, réentraîner le classifieur sur le patrimoine du client, passer une revue de sécurité avec ses interlocuteurs, conduire une recette contradictoire et former les utilisateurs. Ces cinq postes, absents du prototype, constituent l'essentiel de la charge projetée.

C.4 Ventilation de la charge par rôle

Rôle	Lots portés	Charge	Part
Ingénieur données	Adaptation de la collecte · revue de sécurité	15 j·h	37,5 %
Analyste métier	Paramétrage du dashboard · part du cadrage · part de la recette	13 j·h	32,5 %
Ingénieur ML	Réentraînement et validation du classifieur	8 j·h	20,0 %
Chef de projet data	Part du cadrage · part de la recette et de la documentation	4 j·h	10,0 %
Total		40 j·h	100 %

La charge se répartit sur les quatre rôles, avec un écart en faveur de l'ingénieur données. Cet écart est assumé : sur un produit dont la valeur tient d'abord à la collecte et à la sécurisation d'une source ERP, ce sont ces deux lots qui concentrent la charge technique. Le chef de projet, à 10 %, intervient sur le cadrage et la recette, ses autres activités relevant du pilotage et non de la production. La répartition est un point de surveillance du plan de charge, non un équilibre à atteindre coûte que coûte.

Annexe D — Sommaire des spécifications

La documentation projet tient lieu de cahier des charges vivant (§ 2.3.2). Le tableau ci-dessous en donne le sommaire : les exigences fonctionnelles décrivent ce que le système doit faire, les exigences techniques comment il le fait. Chaque ligne renvoie au document qui la porte dans le dépôt.

D.1 Exigences fonctionnelles

Réf.	Exigence	Critère d'acceptation	Document
EF-1	Collecter les métadonnées de l'instance source sans écrire dessus	Réconciliation source / entrepôt à écart nul ; compte source en lecture seule vérifié	docs/A_connexion_preparation
EF-2	Rattacher chaque actif à un domaine métier	100 % des actifs classés, avec un niveau de confiance par actif	docs/B_classification_ml
EF-3	Signaler les classifications à vérifier	Marqueur de revue exposé et filtrable dans la restitution	docs/B_classification_ml
EF-4	Chiffrer le coût de stockage par domaine	Coût annuel calculé sur des tarifs sourcés et horodatés	docs/E1_gains_stockage
EF-5	Recommander une stratégie d'archivage par actif	Stratégie différenciée, distinguant conservation réglementaire et archivage	docs/D_regles_archivage
EF-6	Restituer sans installation côté utilisateur	Accès navigateur, export tableur et requêtes libres en lecture seule	docs/E4_repartition_couts

D.2 Exigences techniques

Réf.	Exigence	Critère d'acceptation	Document
ET-1	Architecture en couches, du brut au servi	Trois schémas distincts, la couche brute restant fidèle à la source	Dossier Bloc 1
ET-2	Rejouabilité de toute analyse	Identifiant de run porté par chaque table et filtré par chaque requête	docs/A_connexion_preparation
ET-3	Protection des données personnelles	Masquage dans les exports, chiffrement au repos	Dossier Bloc 1

Réf.	Exigence	Critère d'acceptation	Document
ET-4	Moindre privilège	Comptes de lecture et d'écriture séparés, vérifiés par la pratique	Dossier Bloc 1
ET-5	Substituabilité de la source	Instance déclarée en configuration, aucun identifiant en dur	config/
ET-6	Traçabilité du modèle déployé	Version de modèle portée par chaque prédiction, fiche de modèle à jour	artifacts/production_model_card.md

Annexe E — Compte rendu type de revue de fin de phase

Modèle appliqué à chaque jalon (§ 3.2.3). L'exemple ci-dessous est celui de la revue de clôture de la phase P1.

Rubrique	Contenu
Phase	P1 — Modélisation et analyse
Période	01/04 → 31/05/2026
Participants	Candidat, tuteur
Produit	Modèle en étoile, classification par domaine des 167 260 actifs, comparaison inter-runs, projection de ROI
Écart constaté	Durée de deux mois pour une phase cible d'un mois
Cause	Score d'archivabilité quasi constant, faute de signal d'usage dans la source
Décision prise	Reconstruire la recommandation d'archivage sur la volumétrie, la sensibilité et les obligations de rétention ; documenter la limite d'origine plutôt que la masquer
Écarté	Demande d'extension du périmètre d'accès à la source, délai incompatible avec les jalons
Reste ouvert	Quantification de l'empreinte évitée, reportée au plan RSE
Prochain jalon	P2 — Sécurité et fiabilité, clôture au 09/06

Les revues suivantes ont été tenues selon le même modèle. Leur trace écrite est constituée par les fichiers de suivi du dépôt : journal des runs, fiche de modèle et évaluation de maturité, mis à jour à chaque clôture de phase.

Annexe F — Grille de compétences et plan de formation

F.1 Compétences actuelles et requises pour l'équipe cible

Compétence	Niveau actuel	Niveau requis	Écart
SQL et modélisation dimensionnelle	Confirmé	Confirmé	—

Compétence	Niveau actuel	Niveau requis	Écart
ETL et orchestration	Intermédiaire	Confirmé	Modéré
ML classique	Confirmé	Confirmé	—
Apprentissage profond, transformeurs	Débutant	Confirmé	Fort, critique
Sécurité et RGPD	Intermédiaire	Confirmé	Modéré
Restitution et visualisation	Intermédiaire	Confirmé	Modéré

Commentaire. Le socle est acquis : les compétences qui portent l'essentiel de la valeur sont au niveau requis, ce qui rend le déploiement réaliste sans recrutement. L'écart critique est isolé sur l'apprentissage profond, compétence rare et longue à acquérir ; il a pesé dans la décision de conserver un modèle classique en production (annexe G). Les écarts modérés relèvent de la montée en compétence sur un outillage existant, et se combinent par la pratique accompagnée.

F.2 Plan de développement des compétences

Écart	Action de formation	Modalité	Priorité
Apprentissage profond	Formation aux transformeurs, complétée de programmation en binôme sur le modèle existant	En ligne et mentorat interne	Haute
ETL avancé	Montée en compétence sur l'orchestrateur : déploiements, planification, reprise sur incident	Documentation et atelier	Moyenne
Sécurité et RGPD	Sensibilisation RGPD et revue avec un juriste	Atelier et accompagnement juridique	Moyenne
Restitution	Bonnes pratiques de visualisation : accessibilité, choix des représentations	Auto-formation guidée	Basse

Prise en compte du handicap. Supports accessibles, avec contraste suffisant et sous-titrage des sessions enregistrées. Temps supplémentaire lors des évaluations. Possibilité de suivre à distance pour lever une contrainte de déplacement. Ces aménagements sont définis avec la personne concernée et le service des ressources humaines, et non appliqués par défaut.

Annexe G — Cas d'arbitrage : quel modèle mettre en production ?

Problématique. Le projet dispose de deux classifieurs. Faut-il promouvoir le transformeur deep learning en production à la place du modèle classique déjà intégré ?

G.1 Comparaison chiffrée

Critère	LinearSVC + Platt, en production	XLM-RoBERTa v3
Justesse	0,907	0,838
Macro-F1	0,869 en validation croisée, 0,892 en holdout	0,802

Critère	LinearSVC + Platt, en production	XLM-RoBERTa v3
Calibration	Correcte	0,011 d'erreur de calibration, excellente
Rappel sur les domaines réglementés	—	Finance 0,89 · RH 0,94 · Achats 0,91
Poids de déploiement	Quelques mégaoctets	2,1 Go, plus le moteur d'inférence
Intégration au traitement par lots	Oui, scoring des 167 260 actifs	Non, démonstration interactive seulement
Déterminisme et reproductibilité	Élevé	Moindre

G.2 Grille multicritère pondérée

Chaque option est notée de 1 à 5 sur cinq critères, pondérés selon leur importance pour un produit destiné à être installé chez des clients.

Critère	Poids	A — Transformeur	B — LinearSVC	C — Hybride
Justesse de classification	30 %	3	5	5
Coût et simplicité de déploiement	25 %	1	5	1
Intégration au pipeline existant	20 %	1	5	2
Calibration et fiabilité de la confiance	15 %	5	3	5
Maintenabilité et déterminisme	10 %	2	5	1
Score pondéré		2,30	4,70	3,00

G.3 Options et décision

Option A — Promouvoir le transformeur. Meilleure calibration et meilleur rappel sur les domaines réglementés, mais justesse inférieure, 2,1 Go à déployer chez chaque client, et absence d'intégration au traitement par lots.

Option B — Conserver le LinearSVC. *Retenue.* Meilleure justesse, quelques mégaoctets, comportement déterministe, déjà intégré au pipeline.

Option C — Faire cohabiter les deux modèles. Cumulerait les forces mais doublerait la maintenance et la surface de test.

Décision argumentée. Sur la justesse, métrique décisive pour l'usage, le LinearSVC devance le transformeur, 0,907 contre 0,838. Le coût de déploiement de ce dernier est disproportionné pour un produit dont l'argument commercial est d'être installable chez n'importe quel client PeopleSoft. Enfin, les deux modèles étant évalués contre les mêmes étiquettes de référence, promouvoir le transformeur sur cette base ne serait pas justifiable tant qu'une comparaison sur vérité terrain

humaine n’a pas été conduite. Le transformeur reste développé comme axe de recherche, rattaché au Bloc 5, et redeviendra promouvable si une comparaison équitable le justifie. La décision est tracée dans la documentation de classification et dans la fiche de modèle.

Annexe H — Plan d’actions RSE, sécurité, éthique et confidentialité

Sujet	Action	Statut	Délai
Confidentialité	Masquage des données personnelles dans les exports et chiffrement au repos en base	Réalisé	Phases P2 et P4
Sécurité	Accès Oracle en lecture seule ; comptes PostgreSQL séparés en lecture et écriture, moindre privilège	Réalisé	Phase P4
Éthique de l’IA	Publication de la justesse réelle du modèle, environ 75 % validée humainement, et non de l’accord avec l’annotateur automatique ; affichage systématique de la confiance	Réalisé	Phases P0 à P3
Environnement	Recommandations d’archivage réduisant le volume en stockage actif ; choix d’un modèle de production léger contre un transformeur de 2,1 Go	Réalisé	Phases P1 et P4
Confidentialité — suite	Externalisation des secrets et des clés vers un coffre dédié	À faire	Court terme, à l’industrialisation
Environnement — suite	Quantification de l’empreinte évitée, en kilowattheures par téraoctet archivé	À faire	Moyen terme
Éthique — suite	Évaluation sur un jeu de test étiqueté indépendant, avec matrice de confusion par domaine	À faire	Court terme

Arbitrage de priorisation. Face à des ressources limitées, la confidentialité et l’éthique ont été traitées avant l’optimisation fine de l’empreinte environnementale. Ces deux enjeux portent un risque immédiat, légal pour l’un et de confiance pour l’autre, alors que le bénéfice environnemental du projet est acquis par nature. Une donnée personnelle exposée est par ailleurs un dommage irréversible, là où une mesure d’empreinte différée reste rattrapable.

Annexe I — Correspondance grille d'évaluation / dossier

Compétence	Critère de la grille	Traité en
C3.1.1	La problématique	§ 2.1.1
C3.1.1	Les objectifs et les livrables du projet	§ 2.1.2
C3.1.1	Le cadre réglementaire	§ 2.1.3
C3.1.1	Les contraintes et les points de vigilance	§ 2.1.4 et § 2.1.5
C3.1.1	Les enjeux RSE	§ 2.1.6 · § 5.2
C3.1.2	Les ressources humaines nécessaires	§ 2.2.1
C3.1.2	Les ressources matérielles et logistiques	§ 2.2.2
C3.1.2	Un chiffrage du projet, coût et délai	§ 2.2.3 · annexes C.1 et C.4
C3.1.2	Une analyse de la faisabilité	§ 2.2.4
C3.1.3	Documentation en adéquation avec le cadrage, présentant l'ensemble des caractéristiques	§ 2.3.2 · annexe D
C3.1.3	Vocabulaire compréhensible par les parties prenantes	§ 2.3.1 et § 2.3.2
C3.2.1	Choix de la méthodologie justifié avec les bénéfices attendus	§ 3.1.1
C3.2.1	Outil de planification compatible avec la méthodologie	§ 3.1.1 · annexe A
C3.2.1	Planning découpé en phases, tâches ou lots	§ 3.1.3 · annexe A.1
C3.2.1	Visualisation des différentes phases	Diagramme de Gantt, § 3.1.3
C3.2.1	Tâches assignées selon les compétences, matrice RACI	§ 3.1.4 · annexe B
C3.2.1	Prise en compte des personnes en situation de handicap	§ 3.1.6
C3.2.1	Points de vigilance soulignés, chemin critique et compétences rares	§ 3.1.5 · § 2.1.5
C3.2.2	Outil de suivi en adéquation avec la méthodologie	§ 3.2.1
C3.2.2	Choix des indicateurs qualitatifs et quantitatifs argumenté	§ 3.2.2
C3.2.2	Suivi de l'avancement, des délais et des coûts	§ 3.2.2, valeurs relevées comprises
C3.2.2	Reportings et comptes rendus de réunion	§ 3.2.3 · annexe E
C3.3.1	Compétences à mobiliser identifiées	§ 4.1.1
C3.3.1	Grille d'évaluation commentée	§ 4.1.2 · annexe F.1
C3.3.1	Plan de développement établi et détaillé	§ 4.1.3 · annexe F.2
C3.3.1	Formations préconisées selon les besoins et les profils	§ 4.1.3
C3.3.1	Modalités adaptées aux spécificités liées au handicap	§ 4.1.4
C3.3.2	Charge de travail répartie de manière équilibrée	§ 4.2.2 · annexes B et C.4

Compétence	Critère de la grille	Traité en
C3.3.2	Outils collaboratifs et routines managériales détaillés et justifiés	§ 4.2.1 et § 4.2.3
C3.3.2	Contexte multiculturel et international	§ 4.2.4
C3.3.2	Personnes en situation de handicap prises en compte	§ 4.2.5
C3.3.3	Problématique exposée avec ses conséquences potentielles	§ 4.3.1 et § 4.3.2
C3.3.3	Options possibles détaillées	§ 4.3.1 et § 4.3.2 · annexe G.3
C3.3.3	Décision argumentée résolvant la problématique	§ 4.3.1 et § 4.3.2
C3.3.3	Outil d'aide à la décision	Grille multicritère, § 4.3.1 · annexe G.2
C3.3.3	Analyse de l'écart entre le prévisionnel et l'état à date	§ 4.3.2
C3.4.1	Choix de la méthodologie de recueil argumenté avec les bénéfices	§ 5.1.1
C3.4.1	Résultat d'une action de veille présenté	§ 5.1.2
C3.4.1	Impact engendré sur les pratiques métier	§ 5.1.2
C3.4.2	Enjeux RSE de la science des données détaillés	§ 5.2.1
C3.4.2	Arbitrages de priorisation précisés et justifiés	§ 5.2.2
C3.4.2	Plan précisant le sujet, l'action et les délais	§ 5.2.3 · annexe H