

DOSSIER ÉCRIT DE CERTIFICATION

Bloc 3 — Élaborer et piloter un projet data

Titre visé : Ingénieur en science des données spécialisé en infrastructure data ou en apprentissage automatique — RNCP 39586 (niveau 7)

Projet : Solution de gouvernance et d'archivage intelligent des données d'un ERP PeopleSoft (Oracle EP92U038)

Épreuve écrite individuelle — dossier de 20 pages maximum, hors annexes et page de garde
<https://github.com/Salem2025s/data-archiving-solution>

Candidat : HAOUARI Salem

Mastère 2 — filière IA & Data · YNOV

Date : 20/08/2026

Composition du rendu

Livrable	Fichier	Compétence
Dossier principal	BLOC3_Elaborer_Piloter_Projet.docx	C3.1.1 → C3.4.2
Annexes A à I	BLOC3_Annexes.docx	Livrables de pilotage

Sommaire

1. Contexte et présentation du projet	4
2. C3.1 — Cadrer et dimensionner.....	4
• C3.1.1 : Cadrage du projet	4
• C3.1.2 : Dimensionnement du projet.....	6
• C3.1.3 : Documentation projet.....	9
3. C3.2 — Planifier et suivre.....	10
• C3.2.1 : Planning et méthodologie	10
• C3.2.2 : Suivi de l'avancement	13
4. C3.3 — Constituer et piloter l'équipe	14
• C3.3.1 : Plan de développement des compétences	14
• C3.3.2 : Outils de communication et managériaux.....	16
• C3.3.3 : Cas d'arbitrage rencontrés.....	17
5. C3.4 — Veiller et agir de façon responsable	19
• C3.4.1 : Méthodologie de veille	20
• C3.4.2 : Plan d'actions RSE, sécurité, éthique et confidentialité.....	21
6. Conclusion	23
7. Annexes (hors décompte de pages)	24

1. Contexte et présentation du projet

Le projet vise à doter une organisation exploitant un ERP Oracle PeopleSoft, instance EP92U038, d'une solution capable de cartographier son patrimoine de données, d'en chiffrer le coût de stockage et de recommander une stratégie d'archivage. Il a été conçu comme un produit substituable d'un client à l'autre : la source n'est qu'un paramètre de configuration, et l'instance de référence sert de terrain de validation. Le commanditaire est la Direction des Systèmes d'Information, dont le besoin, recueilli en entretien de cadrage, tient en une phrase : la base de l'ERP grossit sans que personne sache ce qu'elle contient, ce qu'elle coûte, ni ce qui peut en être archivé sans risque.

La solution livrée comporte un pipeline d'extraction et de transformation, un entrepôt PostgreSQL en architecture médaillon, un classifieur de domaines métier, un moteur de scoring d'archivabilité et un dashboard décisionnel. Au terme du dernier run, elle a classé **167 260 actifs** en sept domaines métier, chiffré leur coût de stockage sur des tarifs sourcés et produit des recommandations d'archivage priorisées. Ce bloc ne revient pas sur ces réalisations : il documente la manière dont le projet a été cadré, dimensionné, planifié, suivi et arbitré, et la façon dont les enjeux de veille et de responsabilité y ont été traités.

2. C3.1 — Cadrer et dimensionner

2.1 — C3.1.1 : Cadrage du projet

Livrable : le cadrage du projet.

2.1.1 Problématique

Les décisions d'archivage se prennent au cas par cas, sans vision d'ensemble ni chiffrage, et reposent sur la connaissance de quelques personnes. Formulée en termes de projet, la question devient : **comment produire, de façon automatique et rejouable, une cartographie fiable d'un patrimoine ERP, en mesurer le coût par objet métier et recommander une stratégie d'archivage justifiée, sans jamais mettre en péril l'intégrité du système ni la conformité réglementaire ?**

2.1.2 Objectifs et livrables

Cinq objectifs, chacun adossé à un livrable produit et vérifiable. **Collecter et structurer les métadonnées de l'ERP** : pipeline ETL et entrepôt PostgreSQL en architecture médaillon (Bloc 1). **Classer automatiquement les tables par domaine métier** : classifieur de production et scoring persistés en base (Blocs 2 et 5). **Chiffrer les coûts et recommander l'archivage** : dashboard décisionnel et export tableur (Bloc 2). **Sécuriser la chaîne** : chiffrement des données personnelles, moindre privilège, accès source en lecture seule (Bloc 1). **Rendre les utilisateurs autonomes** : support de formation et documentation technique (Bloc 2).

2.1.3 Cadre réglementaire

Le projet manipule des métadonnées susceptibles de contenir des données personnelles : identifiants d'opérateurs, adresses électroniques présentes dans les journaux. Il relève donc du **RGPD**, dont les obligations ont été traitées dès la conception. Seules les métadonnées sont collectées, jamais le contenu métier des tables, ce qui satisfait le principe de minimisation. Les données personnelles sont masquées dans les exports et chiffrées au repos dans la base. Enfin, chaque exécution est journalisée et rejouable, ce qui assure la traçabilité.

S'y ajoute une obligation propre au métier de l'archivage, relevée en entretien avec le référent Finance: les durées légales de conservation interdisent de traiter toutes les données de la même manière. Archiver n'est pas supprimer, et la distinction devait apparaître explicitement dans les recommandations produites.

2.1.4 Contraintes

Type	Contrainte	Origine
Technique	Source accessible par VPN uniquement ; aucune écriture sur l'ERP ; noms de tables opaques ; volume élevé (plus de 160 000 actifs)	Entretien DBA
Réglementaire	RGPD sur les métadonnées ; durées légales de conservation à respecter	Entretien référent métier
Données	Absence de vérité terrain : aucune cartographie préexistante ne permet de valider les classifications	Constat de cadrage
Ressources	Une seule personne, à disponibilité partielle ; pas de budget d'infrastructure ; outils open source imposés	Contexte du projet
Délai	Échéances de certification fixes, non négociables (§ 3.1.2)	Modalités d'évaluation
Produit	Solution générique, base substituable, déployable chez d'autres clients PeopleSoft	Commanditaire

2.1.5 Points de vigilance et registre des risques

Les contraintes ci-dessus se traduisent en risques, suivis pendant toute la durée du projet.

Risque	Probabilité	Impact	Mesure de maîtrise	Statut
Recommander l'archivage d'une donnée mal classée	Moyenne	Critique	Marqueur review_required, confiance affichée sur chaque classification, aucune action automatique sur les données	Maîtrisé
Indisponibilité du VPN bloquant l'extraction	Moyenne	Élevé	Extraction incrémentale par préfixe, reprise sur incident, journalisation des runs	Maîtrisé
Absence de vérité terrain faussant l'évaluation du modèle	Élevée	Élevé	Corpus annoté puis corrigé humainement ; publication de la justesse réelle et non de l'accord avec l'annotateur	Maîtrisé, limite résiduelle documentée

Risque	Probabilité	Impact	Mesure de maîtrise	Statut
Compétence rare portée par une seule personne (transformers)	Élevée	Moyen	Modèle de production volontairement simple et interprétable ; le modèle profond reste un axe de recherche	Maîtrisé par la décision du § 4.3.1
Dérive du périmètre vers la technique au détriment du pilotage	Moyenne	Moyen	Découpage en phases jalonnées par les échéances de certification	Maîtrisé
Écriture accidentelle sur l'ERP de production	Faible	Critique	Compte Oracle en lecture seule, vérifié par la pratique	Éliminé

Le premier risque est le seul qui soit à la fois critique et non éliminable : une classification automatique se trompe, par construction, dans une proportion mesurable des cas. C'est lui qui a dicté le principe central du produit — **la solution recommande, elle n'exécute jamais** — et qui structure le cas d'arbitrage du § 4.3.1.

2.1.6 Enjeux RSE

Le projet porte un bénéfice environnemental intrinsèque : déplacer des données inactives d'un stockage actif vers un palier d'archive réduit la consommation énergétique associée, les paliers froids reposant sur des supports moins sollicités et moins répliqués à chaud. Le rapport de coût de 9,8 entre les deux paliers en donne un ordre de grandeur, sans que la proportionnalité entre prix et consommation soit établie : la quantification de l'empreinte réellement évitée reste une action à mener (§ 5.2.3).

Deux autres dimensions relèvent de la responsabilité et sont traitées au § 5.2 : l'**éthique de l'IA**, avec la publication de la performance réelle du modèle plutôt que d'une métrique flatteuse, et la **sobriété du modèle retenu**, un classifieur léger de quelques mégaoctets ayant été préféré à un transformeur de 2,1 Go dont l'entraînement et l'inférence sont bien plus coûteux.

***Critères couverts (C3.1.1).** Le cadrage identifie ✓ la problématique (§ 2.1.1), ✓ les objectifs et les livrables du projet (§ 2.1.2), ✓ le cadre réglementaire, RGPD et durées légales de conservation (§ 2.1.3), ✓ les contraintes, chacune rattachée à son origine, et les points de vigilance, formalisés en registre des risques avec probabilité, impact, mesure de maîtrise et statut (§ 2.1.4 et § 2.1.5), ✓ les enjeux RSE (§ 2.1.6). Le contexte et les enjeux sont posés au § 1, et le dimensionnement en délai et budget qui en découle au § 2.2.*

2.2 — C3.1.2 : Dimensionnement du projet

Livrable : le dimensionnement du projet.

Deux configurations sont dimensionnées séparément : le **projet réalisé**, un prototype conduit par une personne, et le **déploiement chez un client**, qui suppose une équipe. La seconde est une projection et le dossier la désigne comme telle partout où elle apparaît.

2.2.1 Ressources humaines

	Projet réalisé	Scénario d'industrialisation
Effectif	Une personne, plusieurs rôles : ingénierie de données, apprentissage automatique, analyse métier, sécurité	Équipe de 3 à 4 : chef de projet data, ingénieur données, ingénieur ML, analyste métier
Parties prenantes	Tuteur, référents métier et DBA, sollicités lors de points d'avancement périodiques	Commanditaire DSI, référents métier, exploitation, délégué à la protection des données
Disponibilité	Partielle et discontinue, en fonction des créneaux disponibles	Temps plein sur la durée du lot

La répartition des responsabilités du scénario d'industrialisation est formalisée en matrice RACI (§ 3.1.4 et annexe B).

2.2.2 Ressources matérielles et logistiques

Un poste de développement unique sous Python 3.13 et Docker Desktop. L'entrepôt tourne dans un conteneur PostgreSQL 16 local. L'accès à la source Oracle se fait par VPN, l'instance étant fournie. L'ensemble de l'outillage est open source — Python, PostgreSQL, Prefect, Streamlit, scikit-learn — ce qui ramène le coût de licence à zéro. Seul l'entraînement du modèle profond a nécessité un GPU, de façon ponctuelle et mutualisable.

2.2.3 Chiffrage : charge, coût et délai

Charge du projet réalisé. Le travail effectif représente **quatre semaines, soit environ 20 jours-homme**, réparties de façon discontinue sur les 173 jours calendaires du projet. La ventilation ci-dessous est **reconstituée a posteriori** à partir des dates de phase, des runs journalisés dans `admin.pipeline_run` et de la densité de l'historique Git. Il ne s'agit pas d'un relevé de temps.

Phase	Période calendaire	Charge estimée	Part
P0 — Cadrage et collecte	09/03 → 31/03	3 j·h	15 %
P1 — Modélisation et analyse	01/04 → 31/05	7 j·h	35 %
P2 — Sûreté et fiabilité	01/06 → 09/06	2 j·h	10 %
P3 — Apprentissage profond	09/06 → 19/06	2 j·h	10 %
P4 — Sécurité et sources externes	07/07 → 17/07	2 j·h	10 %
P5 — Certification	14/07 → 29/08	4 j·h	20 %
Total	09/03 → 29/08	20 j·h	100 %

L'écart entre la charge et le calendrier est le point important de ce chiffrage. Vingt jours-homme pour 173 jours calendaires, soit environ 124 jours ouvrés, représentent un taux d'occupation de l'ordre de **16 %**. Le projet n'a jamais avancé en continu, mais par sessions courtes séparées de périodes sans activité, dont la plus longue — dix-sept jours, du 20 juin au 6 juillet — sépare P3 et P4. Cette discontinuité est la contrainte de ressources du § 2.1.4 ; elle explique qu'une charge de quatre semaines s'étale sur près de six mois, et elle a directement déterminé le choix de méthodologie (§ 3.1.1).

Valorisation. Au taux de référence retenu ci-dessous, ces 20 jours-homme représentent un **équivalent-charge de 10 000 €** — un ordre de grandeur, non une dépense : le projet n’a engagé aucun coût réel. L’infrastructure est restée à zéro euro, l’outillage étant open source, l’exécution locale et l’instance source fournie ; le GPU de l’entraînement a été mobilisé ponctuellement sur une ressource existante, sans coût marginal.

Budget du scénario d’industrialisation. Le chiffrage ci-dessous vaut pour le déploiement de la solution chez un client, sur son instance PeopleSoft. Il ne s’agit pas de redévelopper le produit, qui existe, mais de l’installer, de l’adapter, de le sécuriser et d’en transférer l’usage.

Lot	Charge	Coût
Cadrage et connexion à l’instance client	6 j·h	3 000 €
Adaptation de la collecte et première exécution	10 j·h	5 000 €
Réentraînement et validation du classifieur	8 j·h	4 000 €
Paramétrage du dashboard et des règles d’archivage	6 j·h	3 000 €
Revue de sécurité et conformité RGPD	5 j·h	2 500 €
Recette, formation et documentation	5 j·h	2 500 €
Sous-total charge	40 j·h	20 000 €
Infrastructure : base managée et hébergement, 3 mois	—	600 €
Provision pour aléas, 10 % de la charge et de l’infrastructure	—	2 060 €
Budget indicatif		≈ 23 000 € HT

Hypothèse de valorisation : taux journalier moyen de 500 € HT, ordre de grandeur du marché français pour des profils data confirmés en prestation. Ce taux est une hypothèse de chiffrage, non un tarif négocié. Le détail par lot et par rôle porteur figure en annexe C.

Délai. Quarante jours-homme répartis sur une équipe de trois à quatre intervenants, mobilisés à temps partiel selon les lots, représentent environ trois semaines de travail effectif. Les dépendances entre lots — la collecte conditionne le réentraînement, qui conditionne la restitution —, la disponibilité des interlocuteurs du client et le temps de recette portent le délai calendaire à **deux à trois mois**.

Pourquoi 40 jours-homme quand le prototype en a coûté 20 ? Le rapport de deux s’explique par ce que le déploiement ajoute et par ce qu’il n’a plus à faire. Il n’y a plus de développement : le produit existe, et la charge de conception ne se refacture pas. Mais il faut adapter la collecte à une instance de production et à sa volumétrie, réentraîner le classifieur sur le patrimoine du client, passer une revue de sécurité avec ses interlocuteurs, conduire une recette contradictoire et former les utilisateurs — cinq postes absents du prototype. Le détail figure en annexe C.3.

2.2.4 Analyse de faisabilité

Faisabilité technique : démontrée. Le prototype fonctionne de bout en bout sur des données réelles — 167 260 actifs classés, coûts et ROI calculés, chaîne sécurisée en exploitation — et les risques du § 2.1.5 sont assortis de mesures effectives.

Faisabilité organisationnelle : conditionnée. Le déploiement suppose un accès en lecture à l'instance client et un référent métier disponible pour valider les classifications ; ces deux prérequis figurent au registre des risques du déploiement.

Faisabilité économique. Un budget de 23 000 € ne se justifie pas par la seule économie de stockage. Au taux mesuré de 195 \$ par téraoctet archivé et par an, une base ERP de quelques téraoctets ne dégage que quelques centaines de dollars d'économie annuelle : le retour sur investissement par ce seul canal serait hors de portée.

La justification repose sur un autre poste : le **coût évité de la cartographie manuelle**. Cartographier 167 260 actifs à la main, à trente secondes par actif pour un expert du progiciel, représente environ 1 400 heures, soit de l'ordre de 175 jours-homme sur une base de 8 heures, et plus de 85 000 € au même taux journalier. Le coût évité représente ainsi près de quatre fois le budget de déploiement, pour un seul patrimoine, et le résultat obtenu manuellement serait figé le jour de sa production alors que la solution se rejoue à chaque exécution. S'y ajoutent la réduction de la dépendance à quelques experts et la capacité à répondre à une demande de conformité. L'économie de stockage reste un bénéfice réel, significatif à grande échelle, mais elle complète le dossier économique au lieu de le fonder.

***Critères couverts (C3.1.2).** Le dimensionnement comporte ✓ les ressources humaines, projet réalisé et équipe cible, parties prenantes comprises (§ 2.2.1), ✓ les ressources matérielles et logistiques (§ 2.2.2), ✓ un chiffrage en coût et en délai — 20 jours-homme sur 173 jours calendaires et un coût engagé nul côté prototype, 40 jours-homme et 23 000 € HT sur deux à trois mois côté déploiement, l'écart étant justifié et l'hypothèse de taux explicitée (§ 2.2.3, annexe C) — et ✓ une analyse de faisabilité technique, organisationnelle et économique, cette dernière fondant le dossier sur le coût évité de la cartographie manuelle (§ 2.2.4).*

2.3 — C3.1.3 : Documentation projet

Livrable : la documentation projet.

2.3.1 Parties prenantes et registre associé

Adapter le vocabulaire suppose de savoir à qui l'on s'adresse et ce que chacun attend.

Partie prenante	Attente vis-à-vis du projet	Document qui la sert
Commanditaire DSI	Un chiffrage et une vision présentable en comité	Dashboard, dossiers de synthèse
Référent métier	Savoir quand se fier à une classification	Support de formation, dictionnaire des indicateurs
DBA et exploitation	Garantie qu'aucune écriture n'atteint l'ERP	Documentation technique, journal des runs
Développeur reprenant la solution	Comprendre, modifier, réexécuter	Documentation technique, procédure de reproduction
Jury de certification	Vérifier qu'un chiffre est traçable	Dossiers par bloc, fiche de modèle

2.3.2 Une documentation à deux registres

Chaque grande fonction du projet est documentée en deux versions : une **version métier**, au vocabulaire accessible aux décideurs et aux référents, et une **version technique**, qui descend au détail d'implémentation. C'est ce dédoublement qui permet de satisfaire des attentes aussi éloignées que celles d'un comité de direction et d'un développeur.

Le dépôt s'organise en conséquence. Un point d'entrée (README.md, docs/INDEX.md) donne l'installation et la lecture critique du projet. Les documents docs/A_... à docs/E4_..., systématiquement dédoublés en version métier et version technique, portent les spécifications fonctionnelles et techniques par fonction. S'y ajoutent les dossiers de synthèse par bloc pour le jury et le management, la fiche de modèle artifacts/production_model_card.md qui fait référence sur le modèle déployé, et l'évaluation de maturité docs/PRODUCTION_READINESS.md, présentée sous forme de feux.

Cette structure tient lieu de **cahier des charges vivant** : les spécifications fonctionnelles, ce que le système doit faire, et techniques, comment il le fait, sont versionnées avec le code et évoluent avec lui. Une spécification figée dans un document séparé aurait divergé du produit dès la première réorientation.

Le **sommaire des spécifications** figure en annexe D : six exigences fonctionnelles et six exigences techniques, chacune assortie de son critère d'acceptation et du document qui la porte. C'est ce qui permet de vérifier qu'une exigence a bien été satisfaite, et non seulement énoncée.

***Critères couverts (C3.1.3).** ✓ Les parties prenantes concernées sont identifiées, avec pour chacune son attente et le document qui y répond (§ 2.3.1). ✓ La documentation projet est en adéquation avec le cadrage et présente l'ensemble des caractéristiques du projet : le **sommaire des spécifications de l'annexe D** énumère six exigences fonctionnelles et six exigences techniques avec leur critère d'acceptation, complétées de la fiche de modèle, de l'évaluation de maturité et des dossiers de synthèse (§ 2.3.2). ✓ Elle est rédigée dans un vocabulaire compréhensible par les parties prenantes, grâce au dédoublement systématique en registre métier et registre technique.*

3. C3.2 — Planifier et suivre

3.1 — C3.2.1 : Planning et méthodologie

Livrable : le planning projet.

3.1.1 Choix de la méthodologie : Kanban

Le projet a été conduit en **Kanban**, en flux continu, et non en Scrum.

Deux raisons ont écarté Scrum. La première est la **discontinuité du travail** : avec vingt jours-homme étalés sur près de six mois, à un taux d'occupation d'environ 16 % (§ 2.2.3), aucun rythme d'itérations à durée fixe ne pouvait être tenu — un sprint suppose une capacité régulière, alors qu'ici deux semaines calendaires pouvaient ne contenir aucune journée de travail. Le flux continu du Kanban ne présuppose aucune cadence : une carte avance quand une session a lieu. La seconde raison tient à la nature exploratoire du projet, dont les priorités ont évolué au fil des découvertes —

le score d’archivabilité s’est révélé quasi constant, imposant de réorienter une partie de l’analyse — et à la proportionnalité, les rituels de Scrum étant dimensionnés pour une équipe.

Bénéfices attendus et obtenus : visualisation permanente de l’avancement, souplesse de repriorisation sans rompre un engagement de sprint, et limitation du travail en cours simultané, qui a évité l’éparpillement entre chantiers techniques.

L’outil de planification est un **tableau Kanban jalonné par les échéances de certification**, cohérent avec la méthodologie puisqu’il associe un flux continu à des jalons externes fixes. Le tableau comporte quatre colonnes — *à faire, en cours, en revue, fait* — avec une limite de deux cartes simultanées en colonne *en cours*, seuil au-delà duquel l’éparpillement entre chantiers techniques devenait sensible. Chaque carte correspond à un lot de travail du § 3.1.3 et se solde par un commit. Le planning qui en résulte est matérialisé sous forme de diagramme de Gantt (annexe A).

3.1.2 Jalons externes imposés

Le projet est contraint par quatre échéances non négociables, fixées par les modalités d’évaluation. Elles constituent l’ossature du planning.

Jalon	Échéance	Statut
Dépôt du Bloc 1, rendu écrit	Semaine 29 — 13 au 17/07/2026	Tenu
Dépôt du Bloc 2, rendu écrit	Semaine 31 — 27 au 31/07/2026	Tenu
Dépôt du Bloc 3, rendu écrit	Semaine 34 — 17 au 21/08/2026	En cours
Soutenance orale du bloc de spécialité	Semaines 36 à 40 — 01 au 29/09/2026	À venir

3.1.3 Découpage en phases et en lots

Le projet a débuté le 9 mars 2026. Le planning ci-dessous est daté par des traces : les premières phases par les runs journalisés dans `admin.pipeline_run`, les suivantes par l’historique Git, le dépôt ayant été formalisé en juin.

Phase	Période	Lots de travail	Jalon de vérification
P0 — Cadrage et collecte	09/03 → 31/03	Cadrage · connexion Oracle · extraction du dictionnaire · chargement	Runs 3 et 4
P1 — Modélisation et analyse	01/04 → 31/05	Modèle en étoile · classification · comparaison inter-runs · ROI	Runs 5 et 6
P2 — Sûreté et fiabilité	01/06 → 09/06	Reprise sur incident · audit · masquage · calibration	Commits phase0, phase1
P3 — Apprentissage profond	09/06 → 19/06	Fine-tuning du transformeur · page de test	Commits x1mr
P4 — Sécurité et sources externes	07/07 → 17/07	Tarifs API · pgcrypto · rôles séparés · dashboard	Commits extract, security
P5 — Certification	14/07 → 29/08	Dossiers des quatre blocs · annexes · soutenance	Dépôts S29, S31, S34




Diagramme de Gantt du projet : six phases réelles de mars à août 2026, datées par les runs du pipeline et l'historique Git.

3.1.4 Répartition des activités : matrice RACI

Le projet réalisé n'a pas comporté de répartition entre plusieurs personnes. Une matrice RACI a donc été établie pour le **scénario de déploiement**, où elle affecte chaque activité selon les compétences des rôles : R pour celui qui réalise, A pour celui qui approuve, C pour celui qui est consulté, I pour celui qui est informé.

L'affectation suit les compétences. L'**ingénieur données** réalise la collecte et l'ETL ainsi que la sécurité et la conformité. L'**ingénieur ML** réalise la modélisation et le scoring. L'**analyste métier** réalise le cadrage et les spécifications, le dashboard, la recette et la documentation. Le **chef de projet** approuve les livrables engageants — cadrage, modélisation, sécurité, recette — et reste informé du reste. Chaque rôle porte ainsi un domaine principal tout en étant consulté sur les interfaces, ce qui évite à la fois la surcharge d'une personne et le cloisonnement des compétences. **La matrice complète, à sept activités, figure en annexe B**, et sa traduction chiffrée en jours-homme en annexe C.4.

3.1.5 Chemin critique et points de vigilance

Le **chemin critique** relie l'accès à la source, l'extraction, la construction du modèle en étoile, la classification et enfin la restitution. Toute rupture en amont gèle l'ensemble de la chaîne : sans extraction, il n'y a ni classification ni chiffrage. La conséquence pratique est que la **disponibilité du VPN conditionne tout le projet**, ce qui a justifié d'investir tôt dans la résilience de la collecte — extraction incrémentale, reprise sur incident, journalisation.

Deux autres points de vigilance ont été suivis. La **compétence rare** que constitue le fine-tuning de transformeurs représente une fragilité dès lors qu'elle est portée par une seule personne ; elle a été traitée par une décision d'architecture, en gardant en production un modèle simple et interprétable (§ 4.3.1). Et le **jalon serré de la phase P5**, où trois dépôts se succèdent en cinq semaines, imposait de commencer la rédaction avant la fin des développements, ce qui explique le chevauchement de P4 et P5 dans le diagramme.

3.1.6 Prise en compte des personnes en situation de handicap

L'accessibilité a été traitée à deux niveaux. Sur le **livrable**, le dashboard applique des règles d'accessibilité visuelle : la couleur n'est jamais le seul vecteur d'information, les échelles d'intensité sont monochromes pour ne pas pénaliser les déficiences de la vision des couleurs, et le contraste respecte le seuil de niveau AA. Deux limites subsistent, la navigation clavier complète et les libellés alternatifs sur les graphiques, identifiées comme travaux à mener.

Sur l'**organisation du travail**, le scénario d'industrialisation prévoit des créneaux de réunion adaptés, une documentation écrite systématique qui permet le travail asynchrone plutôt que la seule transmission orale, et un poste de travail adapté. Ces mesures profitent d'ailleurs à toute l'équipe, en particulier lorsqu'elle est distribuée.

***Critères couverts (C3.2.1).** ✓ Le choix du Kanban est justifié avec ses bénéfices, par comparaison argumentée avec Scrum (§ 3.1.1). ✓ L'outil de planification — tableau à quatre colonnes avec limite de travail en cours, complété du Gantt — est compatible avec cette méthodologie. ✓ Le planning est découpé en six phases et en lots et ✓ permet d'en visualiser les phases, de la collecte à la restitution (§ 3.1.3). ✓ Les tâches sont assignées selon les compétences par une matrice RACI (§ 3.1.4, annexe B), ✓ qui tient compte des personnes en situation de handicap (§ 3.1.6). ✓ Les points de vigilance sont soulignés — chemin critique, compétence rare, jalonnement serré (§ 3.1.5) — et formalisés en registre des risques (§ 2.1.5).*

3.2 — C3.2.2 : Suivi de l'avancement

Livrable : un outil de suivi de projet et un tableau de bord.

3.2.1 Les trois outils de suivi

Le dispositif de suivi repose sur trois outils complémentaires, cohérents avec le pilotage en flux du Kanban.

Le **tableau Kanban** porte le flux courant, décrit au § 3.1.1. Trois outils l'alimentent et le tracent.

Git tient le journal exhaustif de l'avancement. Les commits, datés et structurés par préfixe (feat, fix, docs), matérialisent le flux : chaque commit correspond à une carte terminée. C'est la source qui permet de reconstituer la charge par phase.

La **table `admin.pipeline\_run`** trace chaque exécution du pipeline : identifiant de run, flux exécuté, statut en succès ou en échec, horodatages de début et de fin. Elle donne le suivi opérationnel et sert de preuve de datation pour les premières phases.

Le **dashboard Streamlit** constitue le tableau de bord vivant : il présente les indicateurs métier et l'historique des runs, et sert de support aux points d'avancement.

3.2.2 Indicateurs de suivi

Les indicateurs retenus couvrent les dimensions attendues d'un pilotage — avancement, respect des délais, maîtrise des coûts — et associent des mesures quantitatives à des appréciations qualitatives, faute de quoi le pilotage se ferait sur les seuls chiffres faciles à produire.

Indicateur	Type	Dimension	Ce qu'il pilote
Commits par phase	Quantitatif	Avancement	Progression du développement
Couverture de classification	Quantitatif	Avancement	Complétude de l'analyse
Statut des runs, succès ou échec	Quantitatif	Avancement	Santé opérationnelle du pipeline
Jalons tenus sur jalons prévus	Quantitatif	Délai	Respect des échéances de certification
Durée réelle d'une phase rapportée à sa durée cible	Quantitatif	Délai	Dérive du planning, phase par phase
Coût engagé, infrastructure et licences	Quantitatif	Coût	Maîtrise du budget : nul sur toute la durée du prototype
Taux de revue review_required	Quantitatif	Qualité	Fiabilité des résultats produits
Justesse et calibration du modèle	Quantitatif	Qualité	Performance réelle, non l'accord avec l'annotateur
Appréciation de fin de phase : la phase répond-elle à son objectif ?	Qualitatif	Qualité	Décision de clore ou de prolonger un lot
Retour des parties prenantes en point d'avancement	Qualitatif	Pilotage	Alerte précoce sur un désalignement métier

Valeurs relevées à la date de rédaction.

Indicateur	Valeur
Jalons de dépôt échus, tenus · phases closes	2 sur 2 · 5 sur 6, P5 en cours
Dérive de planning la plus marquée	P1, deux mois contre une cible d'un mois
Couverture de classification · taux de revue	167 260 actifs, soit tout le catalogue · 27,1 %
Justesse du modèle de production	Environ 75 %, validée humainement
Coût engagé	0 € sur toute la durée du prototype

La dérive de P1 est le seul écart de planning significatif. Elle tient à la réorientation du score d'archivabilité, et c'est elle qui a déclenché l'arbitrage du § 4.3.2.

L'association des deux types a une utilité concrète : le taux de revue alerte sur un risque que la seule justesse masquerait, un modèle pouvant être juste en moyenne tout en restant incertain sur les cas qui portent le plus d'enjeu.

3.2.3 Reporting et comptes rendus

Le suivi a donné lieu à deux formes de restitution.

Des **points d'avancement périodiques** avec le tuteur et l'équipe, préparés à partir du dashboard et de l'état du tableau Kanban. Chaque point suit le même ordre du jour : ce qui a avancé depuis la dernière fois, ce qui bloque, ce qui est décidé. Les décisions prises y sont consignées, ce qui a permis de tracer les deux arbitrages du § 4.3.

Des **revues de fin de phase**, à chaque jalon, dont le compte rendu prend la forme d'un état documenté du projet : ce que la phase a produit, l'écart constaté et sa cause, ce qui a été décidé, ce

qui a été écarté et pourquoi, ce qui reste ouvert. Le **compte rendu de la revue de clôture de P1** est reproduit en annexe E : c’est celui qui a acté la réorientation du § 4.3.2. Les fichiers de suivi du dépôt — journal des runs, fiche de modèle, évaluation de maturité — constituent la trace écrite de ces revues, et c’est à partir d’eux que les dossiers de certification ont été rédigés.

***Critères couverts (C3.2.2).** ✓ L’outil de suivi — Git, la table `admin.pipeline_run` et le dashboard — pilote le projet en cohérence avec le Kanban retenu (§ 3.2.1). ✓ Le choix des indicateurs qualitatifs et quantitatifs est argumenté, chacun rattaché à la dimension qu’il pilote. ✓ Ils couvrent l’avancement, le respect des délais et la maîtrise des coûts, et le tableau de bord en donne les valeurs relevées (§ 3.2.2). ✓ Des reportings et des comptes rendus de réunion sont réalisés, points d’avancement et revues de fin de phase, le compte rendu de clôture de P1 étant reproduit en annexe E (§ 3.2.3).*

4. C3.3 — Constituer et piloter l’équipe

Rappel de périmètre. Le projet a été mené par une seule personne. Le pilotage a porté sur les **parties prenantes**, comme le documente le § 4.2.1. Le dimensionnement d’équipe et le plan de compétences valent pour le **scénario de déploiement**, et sont désignés comme tels.

4.1 — C3.3.1 : Plan de développement des compétences

Livrable : un plan de développement des compétences.

4.1.1 Compétences à mobiliser

Le déploiement de la solution mobilise quatre familles de compétences : l’**ingénierie de données**, avec SQL, ETL et la connaissance d’Oracle et de PostgreSQL ; l’**apprentissage automatique**, pour la classification, la calibration et l’évaluation ; l’**analyse métier**, pour la modélisation par domaine et la restitution ; la **sécurité et la conformité**, pour le RGPD, le chiffrement et la gestion des accès.

4.1.2 Grille d’évaluation des compétences

La grille compare le niveau d’une équipe type de déploiement au niveau requis par le projet.

Compétence	Niveau actuel	Niveau requis	Écart
SQL et modélisation dimensionnelle	Confirmé	Confirmé	—
ETL et orchestration	Intermédiaire	Confirmé	Modéré
ML classique	Confirmé	Confirmé	—
Apprentissage profond, transformeurs	Débutant	Confirmé	Fort
Sécurité et RGPD	Intermédiaire	Confirmé	Modéré
Restitution et visualisation	Intermédiaire	Confirmé	Modéré

Commentaire de la grille. Trois enseignements en ressortent. Le socle est acquis : les compétences qui portent l’essentiel de la valeur, SQL, modélisation et ML classique, sont au niveau requis, ce qui rend le déploiement réaliste sans recrutement. L’écart critique est isolé sur l’**apprentissage profond**, qui est aussi la compétence la plus rare et la plus longue à acquérir ; c’est cet écart qui a pesé dans la décision de garder en production un modèle classique plutôt qu’un transformeur (§ 4.3.1), une décision qui a autant réduit un risque de compétence qu’un coût de déploiement. Les trois écarts

modérés, enfin, relèvent de la montée en compétence sur un outillage existant plutôt que d'un apprentissage nouveau : ils se combinent par la pratique accompagnée, pas par une formation longue.

4.1.3 Plan de développement et formations préconisées

Quatre actions couvrent les quatre écarts. **Priorité haute, l'apprentissage profond** : formation aux transformeurs complétée de programmation en binôme sur le modèle existant, en ligne et avec mentorat interne. **Priorité moyenne, l'ETL avancé** : montée en compétence sur l'orchestrateur — déploiements, planification, reprise sur incident — par la documentation et un atelier. **Priorité moyenne, la sécurité et le RGPD** : sensibilisation et revue avec un juriste, en atelier et avec accompagnement juridique. **Priorité basse, la restitution** : auto-formation guidée aux bonnes pratiques de visualisation, accessibilité comprise.

Le plan est séquencé selon la priorité : l'écart fort d'abord, parce qu'il conditionne l'évolution du produit, les écarts modérés ensuite, au fil des lots qui les mobilisent. Il s'articule avec le service des ressources humaines pour la partie formation externe et le suivi des acquis. La grille et le plan complets figurent en annexe F.

4.1.4 Prise en compte du handicap dans les modalités de formation

Les modalités sont adaptées aux situations de handicap : supports accessibles avec un contraste suffisant et un sous-titrage des sessions enregistrées, temps supplémentaire lors des évaluations, et possibilité de suivre à distance pour lever une contrainte de déplacement. Ces aménagements sont définis avec la personne concernée et le service des ressources humaines, et non appliqués par défaut.

***Critères couverts (C3.3.1).** ✓ Les compétences à mobiliser sont identifiées, en quatre familles (§ 4.1.1). ✓ Une grille des compétences actuelles et à acquérir est fournie et **commentée**, le commentaire reliant l'écart critique à une décision d'architecture (§ 4.1.2, annexe F). ✓ Un plan de développement adapté est établi et détaillé, séquencé par priorité (§ 4.1.3). ✓ Des formations sont préconisées selon les besoins du projet et les profils. ✓ Les modalités prennent en considération les spécificités liées au handicap, par aménagement des supports, du temps et des conditions de suivi (§ 4.1.4).*

4.2 — C3.3.2 : Outils de communication et managériaux

Livrable : les outils de communication et managériaux utilisés.

4.2.1 Le pilotage des parties prenantes

Le projet n'a pas comporté d'équipe à encadrer, mais des interlocuteurs à tenir informés, à consulter et à faire décider. C'est cette animation qui a été conduite.

Interlocuteur	Rôle dans le projet	Routine associée
Tuteur	Cadrage, arbitrages, validation des orientations	Points d'avancement périodiques
Équipe et collègues	Regard technique, retours d'usage	Échanges lors des points, sollicitations ponctuelles

Interlocuteur	Rôle dans le projet	Routine associée
Référents métier et DBA	Contraintes et validation du besoin	Entretiens de cadrage, puis consultation à la demande

Chaque point d'avancement suit le même ordre du jour, ce qui rend les échanges courts et les décisions traçables : avancement depuis le dernier point, blocages, décisions à prendre. Les arbitrages du § 4.3 ont été préparés et tranchés dans ce cadre.

4.2.2 Répartition de la charge dans le scénario d'industrialisation

La charge est répartie par la matrice RACI du § 3.1.4. La ventilation de la charge par rôle, détaillée en annexe C.4, montre une répartition effective sur les quatre rôles : 37,5 % pour l'ingénieur données, 32,5 % pour l'analyste métier, 20 % pour l'ingénieur ML et 10 % pour le chef de projet. L'écart en faveur de l'ingénieur données tient à la nature du produit, dont les lots de collecte et de sécurité concentrent la charge technique ; il est assumé et surveillé, l'équilibre strict n'étant pas un objectif en soi sur un projet de cette nature.

4.2.3 Outils collaboratifs et routines managériales

Outil ou routine	Usage	Justification
Git et revue de code	Collaboration technique et qualité	Traçabilité, revue par les pairs, historique partagé
Tableau Kanban	Visualisation du flux de travail	Cohérent avec la méthodologie ; la charge de chacun est visible de tous
Point d'avancement court	Suivi régulier	Léger, adapté à une équipe distribuée, décisions consignées
Revue de fin de phase	Validation d'un jalon	Décision collégiale, alignement sur la suite
Documentation partagée	Référentiel commun	Intégration rapide d'un arrivant, source de vérité unique

4.2.4 Contexte multiculturel et international

Une équipe data est fréquemment distribuée et internationale. Le mode de communication par défaut est **asynchrone**, le synchrone étant réservé aux décisions : c'est ce qui permet de travailler à travers des fuseaux horaires sans exclure personne. La **documentation prime sur la transmission orale**, ce qui neutralise les écarts de maîtrise de la langue de travail, un texte pouvant se relire à son rythme. Les **conventions sont explicitées** — langue partagée pour les commits et la documentation, formats de date et d'unité normalisés — parce que ce sont les implicites qui produisent les malentendus dans un contexte multiculturel.

4.2.5 Prise en compte du handicap

L'intégration prévoit un poste de travail adapté et des outils collaboratifs accessibles, compatibles avec les lecteurs d'écran et suffisamment contrastés. La primauté de l'écrit et de l'asynchrone, retenue pour le contexte international, sert directement l'accessibilité : elle laisse à chacun la maîtrise de son rythme et de son canal.

Critères couverts (C3.3.2). ✓ La charge est répartie sur l'ensemble de l'équipe par la matrice RACI, et la ventilation chiffrée de l'annexe C.4 le vérifie : 37,5 %, 32,5 %, 20 % et 10 % pour les quatre rôles, écart assumé et explicité (§ 4.2.2). ✓ Les outils collaboratifs et les routines managériales sont détaillés et justifiés, pour le pilotage des parties prenantes comme pour le scénario d'équipe (§ 4.2.1 et § 4.2.3). ✓ Les spécificités d'un contexte multiculturel et international sont intégrées (§ 4.2.4). ✓ Les personnes en situation de handicap sont prises en compte, sur le poste de travail comme sur les modes de communication (§ 4.2.5).

4.3 — C3.3.3 : Cas d'arbitrage rencontrés

Livrable : la présentation d'un cas d'arbitrage rencontré au cours du projet.

Deux arbitrages sont présentés. Le premier porte sur une décision d'architecture, le second sur un écart entre le prévisionnel et l'état réel du projet. Tous deux ont été tranchés en cours de projet.

4.3.1 Premier arbitrage : quel modèle mettre en production ?

La problématique. Le projet dispose de deux classifieurs : un LinearSVC calibré, léger et déjà intégré au pipeline, et un transformeur XLM-RoBERTa fine-tuné, plus récent. Faut-il promouvoir le transformeur en production ?

Les conséquences d'un mauvais choix. Promouvoir le transformeur sans gain réel alourdirait le produit de 2,1 Go et d'un moteur d'inférence supplémentaire, chez chaque client, pour une performance qui n'est pas établie comme supérieure. Écarter à tort un meilleur modèle priverait en revanche la solution d'un gain de qualité sur les domaines réglementés.

Les options.

Option	Avantages	Inconvénients
A — Promouvoir le transformeur	Meilleure calibration ; meilleur rappel sur les domaines réglementés	Justesse inférieure ; 2,1 Go à déployer ; non intégré au traitement par lots
B — Garder le LinearSVC	Meilleure justesse ; quelques mégaoctets ; déterministe ; déjà intégré	Calibration moins fine
C — Faire cohabiter les deux	Cumule les forces des deux modèles	Double la maintenance et la surface de test

L'outil d'aide à la décision. Les trois options ont été notées sur cinq critères pondérés selon leur importance pour un produit destiné à être installé chez des clients. Chaque option est notée de 1 à 5.

Critère	Poids	A — Transformeur	B — LinearSVC	C — Hybride
Justesse de classification	30 %	3	5	5
Coût et simplicité de déploiement	25 %	1	5	1
Intégration au pipeline existant	20 %	1	5	2

Critère	Poids	A — Transformeur	B — LinearSVC	C — Hybride
Calibration et fiabilité de la confiance	15 %	5	3	5
Maintenabilité et déterminisme	10 %	2	5	1
Score pondéré		2,3	4,7	3,0

La décision et son argumentation. L'option B est retenue. Trois raisons la fondent. Sur la justesse, la métrique décisive pour l'usage, le LinearSVC devance le transformeur. Le coût de déploiement de ce dernier, 2,1 Go et un moteur d'inférence, est disproportionné pour un produit dont l'argument est d'être installable chez n'importe quel client PeopleSoft. Enfin, les deux modèles étant évalués contre les mêmes étiquettes de référence, promouvoir le transformeur sur cette base ne serait pas justifiable tant qu'une comparaison sur vérité terrain humaine n'a pas été conduite.

La comparaison chiffrée complète des deux modèles figure en annexe G.

La décision résout la problématique sur les deux plans. Elle fixe le modèle de production, ce qui débloque le déploiement, et elle rattache le transformeur au Bloc 5 comme axe de recherche, promouvable si une comparaison équitable le justifie. Elle est tracée dans la documentation de classification et dans la fiche de modèle.

4.3.2 Second arbitrage : un indicateur qui ne discrimine pas

La problématique. En phase P1, l'analyse a révélé que le score d'archivabilité était quasi constant : la grande majorité des actifs portaient la valeur de base, faute de signal d'usage exploitable dans la source. L'indicateur devait pourtant être au cœur de la recommandation d'archivage. L'écart entre le prévisionnel et l'état réel du projet était donc frontal, et il s'est traduit par un dépassement de charge sur P1, la phase la plus longue du planning.

Les conséquences d'un mauvais choix. Publier le score tel quel aurait donné une recommandation d'apparence quantitative et de contenu vide. Chercher à obtenir le signal manquant supposait une extension du périmètre d'accès à la source, hors de portée dans les délais. Abandonner la recommandation d'archivage aurait vidé le projet de sa finalité.

Les options et la décision. Trois voies s'ouvraient : obtenir les statistiques d'accès aux tables, ce qui dépendait d'une autorisation externe et d'un délai incompatible avec les jalons ; publier le score en l'état, au prix d'une recommandation non fondée ; ou **réorienter la recommandation vers des critères effectivement disponibles**. C'est la troisième qui a été retenue. La recommandation d'archivage a été reconstruite sur la volumétrie, la sensibilité de la donnée et les obligations de rétention, et éclatée en sept stratégies différenciées plutôt qu'en un score unique. La limite d'origine, elle, est documentée comme telle dans le dossier du Bloc 2 et n'est pas présentée comme un résultat.

Cet arbitrage illustre la logique de suivi décrite au § 3.2.2 : c'est la dérive de planning sur P1, deux mois pour une phase cible d'un mois, qui a rendu la décision nécessaire, et le registre des risques qui en avait anticipé la cause, l'absence de signal d'usage dans la source.

Critères couverts (C3.3.3). ✓ La problématique nécessitant un arbitrage est exposée avec ses conséquences potentielles, pour les deux cas (§ 4.3.1 et § 4.3.2). ✓ Les options sont détaillées, trois par cas, avec avantages et inconvénients. ✓ La décision est argumentée et résout la problématique : elle fixe le modèle de production dans le premier cas, reconstruit la recommandation d'archivage dans le second. Un **outil d'aide à la décision** est mobilisé, grille multicritère pondérée (§ 4.3.1), et le second arbitrage procède de **l'analyse de l'écart entre le prévisionnel et l'état à date** (§ 4.3.2).

5. C3.4 — Veiller et agir de façon responsable

5.1 — C3.4.1 : Méthodologie de veille

Livrable : une méthodologie de veille.

5.1.1 Choix de la méthodologie de recueil

La veille combine trois canaux, choisis pour leur rapport entre le signal obtenu et l'effort consenti.

La **veille technique** porte sur la littérature et les bibliothèques du domaine — calibration des modèles, fonctions de perte adaptées aux classes déséquilibrées, transformeurs multilingues — par les publications de référence et les journaux de version, qui signalent les changements de comportement avant qu'ils ne cassent un pipeline.

La **veille réglementaire et tarifaire** consomme des sources externes jouables plutôt que des synthèses : l'API publique de tarification du fournisseur de stockage pour les coûts, les textes de référence pour le cadre juridique. Le critère de choix est la vérifiabilité, car une source interrogeable par programme peut être citée, datée et réinterrogée, ce qu'une note de blog ne permet pas.

La **veille outillée** automatise partiellement le premier niveau : le module de collecte tarifaire rafraîchit les coûts à la demande, ce qui transforme une veille manuelle et oubliable en dépendance versionnée du projet.

Bénéfice attendu : des décisions techniques et économiques ancrées dans des sources réelles et actualisables, plutôt que dans des constantes figées au moment du développement.

5.1.2 Résultat d'une action de veille et impact sur les pratiques métier

Première action. La veille technique sur la calibration des modèles a conduit à mesurer l'erreur de calibration et à adopter une confiance graduée plutôt qu'une valeur forfaitaire. **Impact sur les pratiques métier** : les scores de confiance affichés au décideur sont devenus interprétables. Un score de 90 % signifie désormais qu'environ 90 % des classifications de ce niveau sont correctes, ce qui change la manière dont l'analyste priorise ses vérifications, et donne au dispositif de revue une base chiffrée exploitable.

Seconde action. La veille tarifaire a remplacé des coûts de stockage estimés, de l'ordre de 0,276 \$ par gigaoctet et par an, par des tarifs relevés sur l'API du fournisseur, soit 0,2120 \$ pour le stockage actif et 0,0216 \$ pour l'archive. **Impact sur les pratiques métier** : tout le calcul de retour sur investissement du Bloc 2 repose désormais sur des valeurs sourcées, datées et jouables, donc opposables à un contrôle de gestion.

Critères couverts (C3.4.1). ✓ Le choix de la méthodologie de recueil de l'information est argumenté avec les bénéfices attendus : trois canaux complémentaires — technique, réglementaire et tarifaire, outillé — avec pour critère de sélection la vérifiabilité et la rejouabilité des sources, et une automatisation partielle qui inscrit la veille dans le code plutôt que dans une intention (§ 5.1.1). ✓ Le résultat de deux actions de veille est présenté et permet d'identifier ✓ l'impact engendré sur les pratiques métier : interprétabilité des scores de confiance pour la première, fiabilisation de l'ensemble du chiffrage économique pour la seconde (§ 5.1.2).

5.2 — C3.4.2 : Plan d'actions RSE, sécurité, éthique et confidentialité

Livrable : un plan d'actions relatif aux enjeux RSE, de sécurité, d'éthique et de confidentialité.

5.2.1 Les enjeux de la science des données pour ce projet

Environnement. Le stockage de données inactives consomme de l'énergie en continu. L'archivage vers un palier froid réduit cette empreinte, et le rapport de coût de 9,8 entre les deux paliers en donne une mesure indirecte. À cela s'ajoute la sobriété du modèle : un classifieur de quelques mégaoctets consomme, à l'entraînement comme à l'inférence, sans commune mesure avec un transformeur de 2,1 Go.

Confidentialité. Les métadonnées collectées peuvent contenir des données personnelles, ce qui place le projet dans le champ du RGPD.

Éthique de l'intelligence artificielle. Un modèle qui surévalue sa propre performance induit le décideur en erreur, et l'erreur porte ici sur des décisions d'archivage potentiellement irréversibles. C'est la raison pour laquelle la performance publiée est la justesse mesurée et non la métrique la plus favorable.

Sécurité. L'accès à une base de production est en soi un risque, qu'il faut réduire au strict nécessaire.

Dimension sociale. La responsabilité sociétale ne se limite pas à l'environnement. Trois volets sont traités ailleurs dans ce dossier et rattachés ici : l'accessibilité du livrable et des conditions de travail (§ 3.1.6), l'adaptation des modalités de formation aux situations de handicap (§ 4.1.4), et l'intégration d'un contexte multiculturel par la primauté de l'écrit et de l'asynchrone (§ 4.2.4).

5.2.2 Arbitrages de priorisation

Face à des ressources limitées, la **confidentialité et l'éthique ont été traitées en premier**, avant l'optimisation fine de l'empreinte environnementale. Ces deux enjeux portent un risque immédiat, légal pour l'un et de confiance pour l'autre, alors que le bénéfice environnemental du projet est acquis par nature : archiver réduit la consommation, que l'on mesure ce gain ou non. Une donnée personnelle exposée constitue en outre un dommage irréversible, là où une mesure d'empreinte différée reste rattrapable.

5.2.3 Le plan d'actions

Sujet	Action mise en œuvre	Statut	Délai
Confidentialité	Masquage des données personnelles dans les exports et chiffrement au repos en base	Réalisé	Phases P2 et P4
Sécurité	Accès Oracle en lecture seule ; comptes PostgreSQL séparés, moindre privilège	Réalisé	Phase P4
Éthique de l'IA	Publication de la justesse réelle, environ 75 % validée humainement, et non de l'accord avec l'annotateur ; confiance affichée systématiquement	Réalisé	Phases P0 à P3
Environnement	Archivage réduisant le volume en stockage actif ; modèle de production léger préféré à un transformeur de 2,1 Go	Réalisé	Phases P1 et P4
Confidentialité — suite	Externalisation des secrets et des clés vers un coffre dédié	À faire	Au premier déploiement client, lot « sécurité et conformité »
Éthique — suite	Évaluation sur un jeu de test étiqueté indépendant, matrice de confusion par domaine	À faire	Sous 3 mois, avant toute promotion de modèle
Environnement — suite	Quantification de l'empreinte évitée, en kWh par téraoctet archivé	À faire	Sous 6 mois, une fois l'historique de runs disponible

Quatre actions sur sept sont réalisées et vérifiables dans le dépôt ; les trois restantes portent une échéance. Le plan complet, avec le statut de chaque ligne, figure en annexe H.

Critères couverts (C3.4.2). ✓ Les enjeux de la science des données en termes de RSE sont détaillés, sur les quatre dimensions attendues : environnement, confidentialité, éthique de l'IA et sécurité (§ 5.2.1). ✓ Les arbitrages de priorisation retenus pour établir le plan d'actions sont précisés et justifiés, par le caractère immédiat et irréversible du risque plutôt que par l'ampleur du bénéfice (§ 5.2.2). ✓ Le plan d'actions précise, pour chaque ligne, ✓ le sujet traité, ✓ l'action mise en œuvre et ✓ le délai, complétés du statut de réalisation (§ 5.2.3).

6. Conclusion

Le projet a été conduit de bout en bout, du cadrage à la livraison, par une personne à disponibilité partielle, avec l'appui de parties prenantes sollicitées à intervalles réguliers.

Cadrer et dimensionner. Problématique, objectifs, cadre RGPD, contraintes et enjeux RSE sont posés, les points de vigilance formalisés en registre des risques. Le dimensionnement distingue le réalisé — quatre semaines de travail effectif, soit 20 jours-homme étalés sur 173 jours calendaires, pour un coût engagé nul — du projeté pour un déploiement client — 40 jours-homme et un budget indicatif de 23 000 € HT. L'analyse de faisabilité établit que le dossier économique repose sur le coût évité de la cartographie manuelle, non sur la seule économie de stockage.

Planifier et suivre. Le Kanban est justifié par la discontinuité du travail et par la nature exploratoire du projet. Le planning est daté par les runs du pipeline et l'historique Git, découpé en six phases et en lots, jalonné par quatre échéances externes dont les deux échues sont tenues. Le suivi couvre l'avancement, les délais et les coûts, et s'accompagne de points d'avancement et de revues de fin de phase.

Constituer et piloter. Le plan de compétences isole un écart critique, l'apprentissage profond, et le relie à une décision d'architecture. Deux arbitrages sont documentés : le choix du modèle de production, tranché par une grille multicritère pondérée, et la réorientation de la recommandation d'archivage, née d'un écart entre le prévisionnel et le réel.

Veiller et agir de façon responsable. La veille est outillée et ses résultats ont modifié des pratiques : scores de confiance devenus interprétables, coûts estimés remplacés par des tarifs sourcés. Quatre des sept actions du plan RSE sont réalisées et vérifiables, les trois autres datées.

Une même règle a guidé ces décisions : aucun dispositif automatique ne décide seul de ce qui est irréversible. Elle explique le choix d'un modèle simple plutôt que d'un modèle plus lourd, la revue humaine imposée sur les classifications incertaines, et le fait que la solution recommande sans jamais exécuter.

Annexes (hors décompte de pages)

Les annexes font l'objet d'un document séparé, BLOC3_Annexes.docx.

- **A. Planning détaillé** — phases P0 à P5, diagramme de Gantt, jalons de certification, charge par phase.
- **B. Matrice RACI** — équipe cible du scénario d'industrialisation.
- **C. Chiffrage détaillé** — charge et coût par lot, justification économique, ventilation par rôle.
- **D. Sommaire des spécifications** — exigences fonctionnelles et techniques, critères d'acceptation.
- **E. Compte rendu type de revue de fin de phase** — modèle appliqué, exemple de la clôture de P1.
- **F. Grille de compétences et plan de formation** — niveaux actuels et requis, actions, modalités, priorités.
- **G. Cas d'arbitrage** — comparaison chiffrée des deux modèles et grille multicritère pondérée.
- **H. Plan d'actions RSE, sécurité, éthique et confidentialité** — sujets, actions, statuts, délais.
- **I. Correspondance grille d'évaluation / dossier** — chaque critère rapporté à son paragraphe.